

Exercício Prático – Análise Exploratória de Dados com Python

Aplicação: análise de reservas de hotéis

Contexto do problema

Você faz parte da equipe de análise de dados de uma empresa do setor hoteleiro. A empresa possui um histórico de reservas e deseja compreender melhor o comportamento da demanda, dos cancelamentos, dos preços e dos diferentes perfis de clientes antes de desenvolver modelos de mineração de dados.

Sua tarefa é realizar uma análise exploratória utilizando Python. O objetivo não é construir um modelo preditivo, mas conhecer o conjunto de dados, identificar problemas de qualidade, caracterizar distribuições e descobrir relações que possam ser investigadas posteriormente.

Dataset: Hotel Booking Demand, com registros de reservas de um hotel resort e de um hotel urbano.

Disponível em: <https://www.kaggle.com/datasets/jessemostipak/hotel-booking-demand>

Objetivos

- Identificar os objetos e atributos do conjunto de dados.
- Classificar os atributos de acordo com sua natureza.
- Investigar problemas de qualidade dos dados.
- Utilizar estatísticas descritivas para caracterizar os dados.
- Construir e interpretar visualizações adequadas a diferentes tipos de atributos.
- Identificar possíveis outliers e discutir seu significado.
- Investigar relações entre atributos e diferenças entre grupos.
- Formular conclusões a partir das evidências encontradas.

1. Carregamento e conhecimento inicial dos dados

Carregue o arquivo CSV fornecido pelo professor e inspecione sua estrutura.

```
import pandas as pd
```

```
df = pd.read_csv('hotel_bookings.csv')
df.head()
df.shape
df.info()
```

1. Quantas instâncias e quantos atributos existem?
2. Quais atributos são numéricos e quais são categóricos?
3. Quais atributos são binários?
4. Quais atributos representam características da reserva, do cliente, da estadia e do hotel?

2. Qualidade dos dados

Investigue valores ausentes, registros duplicados e a quantidade de valores distintos.

```
df.isnull().sum()
df.duplicated().sum()
df.nunique()
```

5. Existem valores faltantes? Em quais atributos e em que quantidade?
6. Existem registros duplicados?
7. Quais atributos possuem grande quantidade de valores distintos?
8. Quais problemas de qualidade precisam ser considerados antes de uma análise posterior?

3. Estatística descritiva

Calcule média, mediana, mínimo, máximo, quartis, amplitude, IQR e desvio padrão para os principais atributos numéricos. Utilize inicialmente `df.describe()`.

```
df.describe()
```

Dê atenção especialmente a `lead_time`, `stays_in_weekend_nights`, `stays_in_week_nights`, `adults`, `children`, `babies`, `previous_cancellations`, `booking_changes`, `days_in_waiting_list`, `adr` e `total_of_special_requests`.

4. Visualizações e perguntas de investigação

Produza cada gráfico indicado abaixo. Todos devem possuir título, identificação dos eixos e legenda quando necessária. Depois de construir cada gráfico, responda às perguntas associadas, usando o gráfico como principal evidência.

Gráfico 1 – Distribuição do tempo de antecedência das reservas

O que fazer: Construir um histograma de `lead_time`.

- Eixo x: `lead_time` (dias).
- Eixo y: frequência.
- Escolha uma quantidade de bins que permita observar a distribuição claramente.

Perguntas para responder com o gráfico:

1. Em que faixa de antecedência está concentrada a maior parte das reservas?
2. A distribuição parece simétrica ou assimétrica?
3. Existe uma cauda longa para valores elevados?
4. Há indícios de valores extremos?
5. O que o formato sugere sobre o planejamento das reservas?

Gráfico 2 – Distribuição do preço médio diário (ADR)

O que fazer: Construir um histograma de `adr`.

- Eixo x: ADR.
- Eixo y: frequência.
- Não remova automaticamente valores extremos antes de construir o gráfico.

Perguntas para responder com o gráfico:

6. Em qual faixa de preço está concentrada a maior parte das reservas?
7. A distribuição apresenta assimetria?
8. Existem valores muito afastados da concentração principal?
9. A média parece representar bem o preço típico? Compare com a mediana.
10. Que cuidados devem ser tomados ao utilizar ADR em análises posteriores?

Gráfico 3 – Boxplot do ADR por tipo de hotel

O que fazer: Comparar a distribuição de adr entre Resort Hotel e City Hotel usando boxplots.

- Eixo x: tipo de hotel.
- Eixo y: ADR.
- Mantenha os possíveis outliers visíveis.

Perguntas para responder com o gráfico:

11. Qual tipo de hotel apresenta maior mediana?
12. Qual apresenta maior dispersão?
13. Os intervalos interquartis são semelhantes?
14. Há mais valores extremos em um dos grupos?
15. Os preços dos dois hotéis apresentam comportamentos semelhantes?

Gráfico 4 – Cancelamentos por tipo de hotel

O que fazer: Construir um gráfico de barras com reservas canceladas e não canceladas para cada tipo de hotel.

- Agrupe por hotel e is_canceled.
- Use barras agrupadas ou empilhadas.
- Se possível, faça também uma versão percentual para comparar os hotéis.

Perguntas para responder com o gráfico:

16. Qual hotel possui maior número absoluto de cancelamentos?
17. Qual apresenta maior proporção de cancelamentos?
18. Por que apenas o número absoluto pode levar a uma interpretação equivocada?
19. O comportamento de cancelamento parece diferir entre os hotéis?

Gráfico 5 – Cancelamento e antecedência da reserva

O que fazer: Comparar a distribuição de lead_time entre reservas canceladas e não canceladas com boxplots.

- Eixo x: situação da reserva.
- Eixo y: lead_time.
- Mantenha os outliers visíveis.

Perguntas para responder com o gráfico:

20. Qual grupo apresenta maior mediana de antecedência?
21. Qual apresenta maior dispersão?
22. As reservas canceladas parecem ter sido feitas com maior antecedência?
23. O gráfico fornece evidência de uma possível relação entre antecedência e cancelamento?
24. Que hipótese sobre cancelamentos poderia ser investigada depois?

Gráfico 6 – Demanda ao longo do ano

O que fazer: Construir um gráfico de barras da quantidade de reservas por mês de chegada, separando os tipos de hotel.

- Use arrival_date_month.
- Mantenha os meses em ordem cronológica.

- Diferencie os hotéis por cor ou agrupamento.

Perguntas para responder com o gráfico:

25. Quais meses apresentam maior volume de reservas?
26. Existem períodos de baixa demanda?
27. O padrão é semelhante nos dois hotéis?
28. Em quais períodos as diferenças são mais evidentes?
29. Que implicação isso poderia ter para planejamento de capacidade ou preços?

Gráfico 7 – Relação entre antecedência e preço

O que fazer: Construir um scatter plot de lead_time × adr.

- Eixo x: lead_time.
- Eixo y: ADR.
- Use transparência se houver sobreposição.
- Opcionalmente, diferencie os tipos de hotel por cor.

Perguntas para responder com o gráfico:

30. É possível observar uma tendência entre antecedência e preço?
31. A relação parece positiva, negativa ou inexistente?
32. O padrão é diferente entre os hotéis?
33. Há regiões de grande concentração?
34. Existem pontos que fogem do padrão geral?

Gráfico 8 – Relação entre duração da estadia e preço

O que fazer: Criar total_nights = stays_in_weekend_nights + stays_in_week_nights e fazer um scatter plot com ADR.

- Eixo x: total_nights.
- Eixo y: ADR.
- Opcionalmente, diferencie os tipos de hotel.

Perguntas para responder com o gráfico:

35. Como o preço varia com o aumento da duração?
36. Existe uma tendência clara?
37. Há grande concentração em determinadas durações?
38. Existem reservas com duração muito diferente da maioria?
39. O comportamento parece diferente entre os hotéis?

Gráfico 9 – Solicitações especiais por perfil de cliente

O que fazer: Construir um gráfico de barras mostrando a média de special_requests por customer_type.

- Eixo x: customer_type.
- Eixo y: média de special_requests.
- Identifique claramente os grupos.

Perguntas para responder com o gráfico:

40. Qual tipo de cliente apresenta maior média?
41. Qual apresenta menor média?
42. As diferenças entre os grupos parecem relevantes?
43. Que interpretação de negócio poderia ser levantada a partir desse padrão?

5. Investigação de outliers

Escolha dois atributos numéricos que apresentem indícios de valores extremos nos gráficos. Calcule Q1, Q3 e IQR e determine os limites pela regra de $1,5 \times \text{IQR}$.

```
IQR = Q3 - Q1
limite_inferior = Q1 - 1.5 * IQR
limite_superior = Q3 + 1.5 * IQR
```

9. Quantos registros são classificados como possíveis outliers?
10. Os valores identificados aparecem também nos boxplots?
11. Você removeria esses registros? Justifique considerando o contexto das reservas.

6. Correlação entre atributos numéricos

Calcule a matriz de correlação e escolha relações para investigar visualmente.

```
df.corr(numeric_only=True)
```

12. Quais pares apresentam as maiores correlações em módulo?
13. As correlações mais fortes são coerentes com os scatter plots?
14. Existe alguma correlação que possa ser enganosa por causa da natureza do atributo ou do contexto?
15. Escolha uma relação que mereceria investigação em uma etapa posterior e explique por quê.

7. Síntese: o que os dados revelam?

Apresente de 5 a 7 achados relevantes sobre o conjunto. Cada achado deve ser sustentado por uma evidência observada em um gráfico ou por uma medida estatística.

Finalize indicando três questões que poderiam ser investigadas em uma próxima etapa de mineração de dados, como previsão de cancelamento, segmentação de clientes ou previsão de demanda.

8. Entrega

- Jupyter Notebook (.ipynb) contendo todo o código utilizado.
- Todos os gráficos solicitados, com títulos, eixos e legendas quando necessários.
- Respostas às perguntas associadas a cada gráfico.
- Síntese final com os principais achados.
- Notebook executado integralmente, sem células com erro.