

hotel_booking

August 26, 2026

```
[1]: import pandas as pd

df = pd.read_csv("hotel_bookings.csv")
```

1 1 carregamento e conhecimento inicial dos dados

```
[2]: df.head()
```

```
[2]:
```

	hotel	is_canceled	lead_time	arrival_date_year	arrival_date_month	\
0	Resort Hotel	0	342	2015	July	
1	Resort Hotel	0	737	2015	July	
2	Resort Hotel	0	7	2015	July	
3	Resort Hotel	0	13	2015	July	
4	Resort Hotel	0	14	2015	July	

	arrival_date_week_number	arrival_date_day_of_month	\
0	27	1	
1	27	1	
2	27	1	
3	27	1	
4	27	1	

	stays_in_weekend_nights	stays_in_week_nights	adults	...	deposit_type	\
0	0	0	2	...	No Deposit	
1	0	0	2	...	No Deposit	
2	0	1	1	...	No Deposit	
3	0	1	1	...	No Deposit	
4	0	2	2	...	No Deposit	

	agent	company	days_in_waiting_list	customer_type	adr	\
0	NaN	NaN	0	Transient	0.0	
1	NaN	NaN	0	Transient	0.0	
2	NaN	NaN	0	Transient	75.0	
3	304.0	NaN	0	Transient	75.0	
4	240.0	NaN	0	Transient	98.0	

	required_car_parking_spaces	total_of_special_requests	reservation_status	\
--	-----------------------------	---------------------------	--------------------	---

0	0	0	Check-Out
1	0	0	Check-Out
2	0	0	Check-Out
3	0	0	Check-Out
4	0	1	Check-Out

reservation_status_date	
0	2015-07-01
1	2015-07-01
2	2015-07-02
3	2015-07-02
4	2015-07-03

[5 rows x 32 columns]

```
[3]: df.shape
```

```
[3]: (119390, 32)
```

```
[4]: df.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 119390 entries, 0 to 119389
Data columns (total 32 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   hotel                                119390 non-null  str
1   is_canceled                          119390 non-null  int64
2   lead_time                            119390 non-null  int64
3   arrival_date_year                    119390 non-null  int64
4   arrival_date_month                   119390 non-null  str
5   arrival_date_week_number             119390 non-null  int64
6   arrival_date_day_of_month            119390 non-null  int64
7   stays_in_weekend_nights              119390 non-null  int64
8   stays_in_week_nights                 119390 non-null  int64
9   adults                               119390 non-null  int64
10  children                             119386 non-null  float64
11  babies                               119390 non-null  int64
12  meal                                 119390 non-null  str
13  country                              118902 non-null  str
14  market_segment                       119390 non-null  str
15  distribution_channel                  119390 non-null  str
16  is_repeated_guest                     119390 non-null  int64
17  previous_cancellations                 119390 non-null  int64
18  previous_bookings_not_canceled        119390 non-null  int64
19  reserved_room_type                    119390 non-null  str
20  assigned_room_type                    119390 non-null  str
21  booking_changes                       119390 non-null  int64
```

```

22 deposit_type          119390 non-null  str
23 agent                 103050 non-null  float64
24 company               6797 non-null   float64
25 days_in_waiting_list  119390 non-null  int64
26 customer_type         119390 non-null  str
27 adr                   119390 non-null  float64
28 required_car_parking_spaces  119390 non-null  int64
29 total_of_special_requests  119390 non-null  int64
30 reservation_status     119390 non-null  str
31 reservation_status_date  119390 non-null  str
dtypes: float64(4), int64(16), str(12)
memory usage: 29.1 MB

```

1. Quantas instâncias e quantos atributos existem? o dataset possui 119390 instâncias e com 32 atributos cada
2. Quais atributos são numéricos e quais são categóricos? numéricos: `is_canceled`, `lead_time`, `arrival_date_year`, `arrival_date_week_number`, `arrival_date_day_of_month`, `stays_in_weekend_nights`, `stays_in_week_nights`, `adults`, `children`, `babies`, `is_repeated_guest`, `previous_cancellations`, `previous_bookings_not_canceled`, `booking_changes`, `agent`, `company`, `days_in_waiting_list`, `adr`, `required_car_parking_spaces`, `total_of_special_requests`

categóricos: `hotel`, `arrival_date_month`, `meal`, `country`, `market_segment`, `distribution_channel`, `reserved_room_type`, `assigned_room_type`, `deposit_type`, `customer_type`, `reservation_status`, `reservation_status_date`.
3. Quais atributos são binários? tem 2 atributos binários: `is_canceled` e `is_repeated_guest`
4. Quais atributos representam características da reserva, do cliente, da estadia e do hotel? Hotel: `hotel`. Reserva: `is_canceled`, `lead_time`, `deposit_type`, `reservation_status`, `reservation_status_date`, `booking_changes`, `days_in_waiting_list`, `distribution_channel`, `market_segment`. Cliente: `adults`, `children`, `babies`, `customer_type`, `country`, `is_repeated_guest`, `previous_cancellations`, `previous_bookings_not_canceled`. Estadia: `stays_in_weekend_nights`, `stays_in_week_nights`, `arrival_date_year`, `arrival_date_month`, `arrival_date_week_number`, `arrival_date_day_of_month`, `meal`, `reserved_room_type`, `assigned_room_type`, `adr`, `required_car_parking_spaces`, `total_of_special_requests`.

2 2 qualidade dos dados

```

[5]: # ausentes
missing = df.isnull().sum()
missing[missing > 0]
print(missing[missing > 0])

```

```

children      4
country      488
agent      16340

```

```
company      112593
dtype: int64
```

```
[6]: print(f"duplicados: {df.duplicated().sum()}")
```

```
duplicados: 31994
```

```
[7]: df.nunique().sort_values()
```

```
[7]: hotel                2
     is_canceled          2
     is_repeated_guest    2
     arrival_date_year    3
     deposit_type         3
     reservation_status   3
     customer_type        4
     babies               5
     meal                 5
     distribution_channel  5
     children             5
     required_car_parking_spaces  5
     total_of_special_requests  6
     market_segment       8
     reserved_room_type   10
     arrival_date_month   12
     assigned_room_type   12
     adults               14
     previous_cancellations  15
     stays_in_weekend_nights  17
     booking_changes      21
     arrival_date_day_of_month  31
     stays_in_week_nights  35
     arrival_date_week_number  53
     previous_bookings_not_canceled  73
     days_in_waiting_list  128
     country              177
     agent                333
     company              352
     lead_time            479
     reservation_status_date  926
     adr                  8879
dtype: int64
```

5. Existem valores faltantes? Em quais atributos e em que quantidade? sim: company 112593, agent 16340, country 488 e children 4
6. Existem registros duplicados? sim, existem 31994 registros duplicados
7. Quais atributos possuem grande quantidade de valores distintos? adr 8994, reservation_status_date: 926, lead_time: 479, company: 352, agent: 333

8. Quais problemas de qualidade precisam ser considerados antes de uma análise posterior? alta ausência em company, agent e country, diárias com valores negativos ou zerados

3 3 estatística descritiva

```
[8]: cols_destaque = [
    'lead_time', 'stays_in_weekend_nights', 'stays_in_week_nights',
    'adults', 'children', 'babies', 'previous_cancellations',
    'booking_changes', 'days_in_waiting_list', 'adr',
    'total_of_special_requests'
]

desc = df[cols_destaque].describe().T

median = df[cols_destaque].median()
rangee = desc['max'] - desc['min']
irq = desc['75%'] - desc['25%']

desc['median'] = median
desc['range'] = rangee
desc['irq'] = irq

desc
```

```
[8]:
```

	count	mean	std	min	25%	\
lead_time	119390.0	104.011416	106.863097	0.00	18.00	
stays_in_weekend_nights	119390.0	0.927599	0.998613	0.00	0.00	
stays_in_week_nights	119390.0	2.500302	1.908286	0.00	1.00	
adults	119390.0	1.856403	0.579261	0.00	2.00	
children	119386.0	0.103890	0.398561	0.00	0.00	
babies	119390.0	0.007949	0.097436	0.00	0.00	
previous_cancellations	119390.0	0.087118	0.844336	0.00	0.00	
booking_changes	119390.0	0.221124	0.652306	0.00	0.00	
days_in_waiting_list	119390.0	2.321149	17.594721	0.00	0.00	
adr	119390.0	101.831122	50.535790	-6.38	69.29	
total_of_special_requests	119390.0	0.571363	0.792798	0.00	0.00	

	50%	75%	max	median	range	irq
lead_time	69.000	160.0	737.0	69.000	737.00	142.00
stays_in_weekend_nights	1.000	2.0	19.0	1.000	19.00	2.00
stays_in_week_nights	2.000	3.0	50.0	2.000	50.00	2.00
adults	2.000	2.0	55.0	2.000	55.00	0.00
children	0.000	0.0	10.0	0.000	10.00	0.00
babies	0.000	0.0	10.0	0.000	10.00	0.00
previous_cancellations	0.000	0.0	26.0	0.000	26.00	0.00
booking_changes	0.000	0.0	21.0	0.000	21.00	0.00
days_in_waiting_list	0.000	0.0	391.0	0.000	391.00	0.00

adr	94.575	126.0	5400.0	94.575	5406.38	56.71
total_of_special_requests	0.000	1.0	5.0	0.000	5.00	1.00

4 4 visualizacoes e perguntas de investigaçã


```
[9]: import seaborn as sns
import matplotlib.pyplot as plt

sns.set_theme(style="whitegrid", palette="muted")
```

4.1 grafico 1 - distribuicao do tempo de antecedencia das reservas

```
[10]: sns.histplot(data=df, x=df["lead_time"], bins=60, kde=True)
plt.axvline(df['lead_time'].median(), color='red', label=f'mediana_
↳({df["lead_time"].median():0f} d)')
plt.axvline(df['lead_time'].mean(), color='green', label=f'média_
↳({df["lead_time"].mean():0f} d)')
plt.legend()
```

[10]: <matplotlib.legend.Legend at 0x7f4dd11a6c50>



```
[11]: lt = df["lead_time"]
print(lt.median())
print(lt.mean())
print(max(lt))
```

69.0

104.01141636652986


737

1. Em que faixa de antecedência está concentrada a maior parte das reservas? entre 0 e 30 dias, com pico no dia 0
2. A distribuição parece simétrica ou assimétrica? é assimétrica à direita (positiva), com média (104 dias) superior à mediana (69 dias)
3. Existe uma cauda longa para valores elevados? sim, estende-se até mais de 700 dias
4. Há indícios de valores extremos? sim, há várias reservas feitas entre 400 e 737 dias de antecedência
5. Há indícios de valores extremos? a maioria dos clientes planeja a curto prazo (menos de 2 meses), enquanto reservas longas são casos específicos

4.2 grafico 2 -distribuicao do preco medio diario

```
[12]: plt.figure(figsize=(12, 4))
sns.histplot(data=df, x=df["adr"], bins=50, kde=True)
plt.axvline(df['adr'].median(), color='red', label=f'mediana ({df["adr"].
↪median():1f} €)')
plt.axvline(df['adr'].mean(), color='green', label=f'média ({df["adr"].mean():
↪1f} €)')
plt.legend()
```

[12]: <matplotlib.legend.Legend at 0x7f4dd1008110>



```
[13]: adr = df["adr"]
print(adr.median())
```

```

print(adr.mean())
print(max(adr))

adr_desc = adr.describe().T
# irq = adr_desc['75%'] - adr_desc['25%']
print(adr_desc['25%'])
print(adr_desc['75%'])

```

```

94.575
101.83112153446687
5400.0
69.29
126.0

```

6. Em qual faixa de preço está concentrada a maior parte das reservas? entre 69 € e 126 €, com mediana de 94,5 €
7. A distribuição apresenta assimetria? 7 sim, assimetria positiva à direita
8. Existem valores muito afastados da concentração principal? sim, há um valor isolado extremo de 5400 € e valores negativos/zerados
9. A média parece representar bem o preço típico? Compare com a mediana. a mediana 94,5 €) representa melhor o valor típico, pois a média (101,8 €) é puxada por preços altos
10. Que cuidados devem ser tomados ao utilizar ADR em análises posteriores? filtrar valores negativos/zerados e tratar o outlier de 5400 €

5 grafico 3 - boxplot do adr por tipo de hotel

```
[14]: # snsboxplot(data=df, x='hotel', y='adr')
```

```

[15]: plt.figure(figsize=(10, 7))


sns.boxplot(data=df, x="hotel", y="adr")

plt.yscale("log")
plt.ylabel("log adr")

plt.show()

df.groupby('hotel')['adr'].describe()

```

```
[15]:
```


	count	mean	std	min	25%	50%	75%	max
hotel								
City Hotel	79330.0	105.304465	43.602954	0.00	79.2	99.9	126.0	5400.0
Resort Hotel	40060.0	94.952930	61.442418	-6.38	50.0	75.0	125.0	508.0

11. Qual tipo de hotel apresenta maior mediana? o city hotel com 999 vs 750 do resort
12. Qual apresenta maior dispersão? o resort hotel irq de 750 vs 468 do city
13. Os intervalos interquartis são semelhantes? não, diferença considerável
14. Há mais valores extremos em um dos grupos? sim, ambos tem, mas o city hotel tem mais outliers, incluindo o valor de 5400 €
15. Os preços dos dois hotéis apresentam comportamentos semelhantes? não, os preços apresentam uma notória diferença, o que reflete a dinâmica típica de cada mercado, hotelaria urbana x lazer

6 gráfico 4 - cancelamentos por tipo de hotel


```
[16]: sns.countplot(data=df, x="hotel", hue="is_canceled")
```

```
[16]: <Axes: xlabel='hotel', ylabel='count'>
```



```
[17]: df_pct = (  
    pd.crosstab(df['hotel'], df['is_canceled'], normalize='index') * 100  
    )  
  
    df_pct.plot(kind='bar', stacked=True)
```

```
[17]: <Axes: xlabel='hotel'>
```



```
[18]: print(df.groupby('hotel')['is_canceled'].mean())
      print()
      print(df.groupby('hotel')['is_canceled'].value_counts())
```

```
hotel
City Hotel      0.417270
Resort Hotel    0.277634
Name: is_canceled, dtype: float64
```

```
hotel      is_canceled
City Hotel  0          46228
           1          33102
Resort Hotel 0          28938
           1          11122
Name: count, dtype: int64
```


16. Qual hotel possui maior número absoluto de cancelamentos? o city hotel 33102 vs 11122 do

resort

17. Qual apresenta maior proporção de cancelamentos? o city hotel 41,7% vs 27,8% do resort
18. Por que apenas o número absoluto pode levar a uma interpretação equivocada? porque o city hotel tem muito mais reservas no total, o percentual confirma que sua taxa de evasão relativa é realmente maior
19. O comportamento de cancelamento parece diferir entre os hotéis? sim, o cancelamento é significativamente mais frequente no City Hotel

7 gráfico 5 - cancelamento e antecedência da reserva

```
[19]: sns.boxplot(data=df, x='is_canceled', y='lead_time')
plt.show()
df.groupby('is_canceled')['lead_time'].describe()
```



```
[19]:
```

	count	mean	std	min	25%	50%	75%	max
is_canceled								
0	75166.0	79.984687	91.109888	0.0	9.0	45.0	124.0	737.0
1	44224.0	144.848815	118.624829	0.0	48.0	113.0	214.0	629.0

20. Qual grupo apresenta maior mediana de antecedência? o grupo de cancelados mediana de 113 dias vs 49 dias dos não cancelados

21. Qual apresenta maior dispersão? o grupo de cancelados irq de 166 dias vs 115 dias dos não cancelados
22. As reservas canceladas parecem ter sido feitas com maior antecedência? sim, a distribuição das canceladas é superior
23. O gráfico fornece evidência de uma possível relação entre antecedência e cancelamento? sim, mostra forte relação positiva: quanto maior a antecedência, maior a probabilidade de cancelamento
24. Que hipótese sobre cancelamentos poderia ser investigada depois? reservas feitas com muita antecedência têm maior incerteza por parte do cliente, levando ao cancelamento posterior, talvez mais tempo se vai cancelar ou não, se a pessoa compra mais perto do dia não tem muito tempo para pensar


8 gráfico 6 - demanda ao longo do ano por tipo de hotel

```
[20]: meses = ['January', 'February', 'March', 'April', 'May', 'June', 'July', 'August', 'September', 'October', 'November', 'December']

plt.figure(figsize=(13,5))

sns.countplot(data=df, x='arrival_date_month', order=meses, hue='hotel')
```

```
[20]: <Axes: xlabel='arrival_date_month', ylabel='count'>
```




25. Quais meses apresentam maior volume de reservas? julho e agosto
26. Existem períodos de baixa demanda? sim, novembro, dezembro e janeiro
27. O padrão é semelhante nos dois hotéis? sim no pico de verão, mas o city hotel mantém demanda alta também na primavera e outono
28. Em quais períodos as diferenças são mais evidentes? na primavera e outono (maio, junho, setembro, outubro), onde o city hotel supera amplamente o resort
29. Que implicação isso poderia ter para planejamento de capacidade ou preços? criar promoções no inverno, ou reduzir os funcionarios nesse periodo

9 gráfico - relação entre antecedência e preço

```
[21]: plt.figure(figsize=(10,5))
sns.scatterplot(data=df, x='lead_time', y='adr', hue='hotel')
plt.ylim(-10,500)
```

```
[21]: (-10.0, 500.0)
```



- 30. É possível observar uma tendência entre antecedência e preço? não há tendência clara
- 31. A relação parece positiva, negativa ou inexistente? praticamente inexistente
- 32. O padrão é diferente entre os hotéis? não significativamente, ambos mantêm faixas de preços estáveis ao longo do tempo
- 33. Há regiões de grande concentração? sim, em lead time de 0 a 300 dias com ADR entre 50 € e 250 €
- 34. Existem pontos que fogem do padrão geral? sim, o valor isolado de 5400 € e reservas com mais de 500 dias


10 gráfico 8 - relação entre duração da estadia e preço

```
[22]: df['total_nights'] = df['stays_in_weekend_nights'] + df['stays_in_week_nights']

plt.figure(figsize=(10, 5))
sns.scatterplot(data=df, x='total_nights', y='adr', hue='hotel')

plt.ylim(0, 550)
plt.xlim(0, 30)
```

[22]: (0.0, 30.0)




35. Como o preço varia com o aumento da duração? o preço diário permanece estável para estadias comuns e reduz levemente em estadias muito longas
36. Existe uma tendência clara? média/fraca, diárias muito caras ocorrem apenas em estadias curtas (1 a 4 noites)
37. Há grande concentração em determinadas durações? sim, entre 1 e 7, com picos fortes entre 1 e 4
38. Existem reservas com duração muito diferente da maioria? sim, algumas estadias de ~15 a mais de 30 noites
39. O comportamento parece diferente entre os hotéis? sim, o city hotel foca em estadias curtas (1-3 noites), enquanto o resort possui mais estadias de 7 e 14 noites

11 gráfico 9 - solicitações especiais por perfil de cliente

```
[23]: sns.barplot(  
    data=df,  
    x="customer_type",  
    y="total_of_special_requests",  
)
```

[23]: <Axes: xlabel='customer_type', ylabel='total_of_special_requests'>



40. Qual tipo de cliente apresenta maior média? contract
41. Qual apresenta menor média?
transient-party
42. As diferenças entre os grupos parecem relevantes? sim, clientes contract fazem quase o dobro de pedidos especiais quando comparados a transient-party
43. Que interpretação de negócio poderia ser levantada a partir desse padrão? o hotel deve priorizar o atendimento prévio das solicitações dos clientes contract, pois atender a essas preferências é bom para manter contratos corporativos valiosos e garantir a fidelidade desses hóspedes

12 5 investigacao de outliers

```
[24]: def outliers_iqr(col):
    Q1 = df[col].quantile(0.25)
    Q3 = df[col].quantile(0.75)
    IQR = Q3 - Q1
    lim_inf = Q1 - 15 * IQR
    lim_sup = Q3 + 15 * IQR
    n_out = len(df[(df[col] < lim_inf) | (df[col] > lim_sup)])
```



```
print(f"{col}: Q1={Q1:.2f}, Q3={Q3:.2f}, IQR={IQR:.2f} | Limites: [{lim_inf:
↪.2f}, {lim_sup:.2f}] | Outliers: {n_out} ({n_out/len(df)*100:.2f}%)")
```

```
outliers_iqr('adr')
outliers_iqr('lead_time')
```

adr: Q1=69.29, Q3=126.00, IQR=56.71 | Limites: [-781.36, 976.65] | Outliers: 1 (0.00%)


lead_time: Q1=18.00, Q3=160.00, IQR=142.00 | Limites: [-2112.00, 2290.00] | Outliers: 0 (0.00%)

9. Quantos registros são classificados como possíveis outliers? adr: 3793 registros (3,18%) acima de 211,05 € lead_time: 3005 registros (2,52%) acima de 376 dias
10. Os valores identificados aparecem também nos boxplots?
sim, são exatamente os pontos desenhados fora das linhas dos boxplots
11. Você removeria esses registros? Justifique considerando o contexto das reservas
Apenas erros/anomalias claros como o ADR = 5400 € e valores negativos Os demais representam reservas verdade de alta temporada e grandes eventos que não devem ser descartadas

13 6 correlação entre atributos numéricos

```
[25]: mat = df.corr(numeric_only=True)
plt.figure(figsize=(20,20))
sns.heatmap(mat, annot=True, fmt='2f', cmap='coolwarm', linewidths=0.5,
↪vmin=-1, vmax=1)
```

[25]: <Axes: >



12. Quais pares apresentam as maiores correlações em módulo?
total_nights com stays_in_week_nights = 0,94 (obviamente) total_nights com stays_in_wekeend_nights = 0,76 (obviamente)
13. As correlações mais fortes são coerentes com os scatter plots?
foras as triviais, sim, por exemplo o lead_time e is_canceled, adults e adr, etc
14. Existe alguma correlação que possa ser enganosa por causa da natureza do atributo ou do contexto?
sim, as variaveis binárias/categóricas
15. Escolha uma relação que mereceria investigação em uma etapa posterior e explique por quê a relação entre vagas de estacionamento e cancelamento: clientes que solicitam estacionamento

raramente cancelam (-0,20), sendo um possível preditor de presença confirmada

14 síntese: o que os dados revelam?

15 Principais Achados:

1. Antecedência e Cancelamento: Reservas tendem a ser mais canceladas quanto mais tempo foram reservadas
2. Diferenças entre Hotéis: O City Hotel tem maior preço mediano e maior taxa de cancelamento
3. Sazonalidade: Pico de demanda no verão europeu (Julho e Agosto) e forte queda no inverno (Novembro a Janeiro)
4. Pedidos Especiais: Clientes Contract demandam quase o dobro de solicitações em relação a Clientes
5. Qualidade dos Dados: Presença de 94% de nulos em company, outlier de 5400 € em ADR e reservas com 0 pessoas
6. Vaga de Garagem: Solicitação de estacionamento é um forte indicativo de que a reserva não será cancelada

16 3 ideias para projetos futuros de mineracao de dados:

1. Detecção de Fraude e Reservas “Fantasma”: Como identificar padrões de reservas falsas ou especulativas, feitas por robôs, agências ou concorrentes que bloqueiam os quartos com muita antecedência e cancelam de última hora para manipular o estoque de preços do hotel?
2. Otimização de Políticas de Cancelamento Dinâmicas: Em vez de apenas prever se o cliente vai cancelar, qual deve ser a taxa de depósito obrigatória ou a política de reembolso ideal personalizada para cada cliente no momento da reserva para minimizar a taxa de desistência sem perder a venda?
3. Previsão de Demanda e Preço Dinâmico: Modelo de séries temporais para prever ocupação e sugerir tarifas ideais por temporada.

[]: