

pre_processing

September 2, 2026

```
[1]: import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
```

```
[2]: df = pd.read_csv("hotel_bookings.csv")
df.head()
```

```
[2]:      hotel  is_canceled  lead_time  arrival_date_year  arrival_date_month \
0  Resort Hotel           0        342             2015             July
1  Resort Hotel           0        737             2015             July
2  Resort Hotel           0         7             2015             July
3  Resort Hotel           0         13             2015             July
4  Resort Hotel           0         14             2015             July
```

```
      arrival_date_week_number  arrival_date_day_of_month \
0                             27                          1
1                             27                          1
2                             27                          1
3                             27                          1
4                             27                          1
```

```
      stays_in_weekend_nights  stays_in_week_nights  adults  ...  deposit_type \
0                             0                     0      2  ...  No Deposit
1                             0                     0      2  ...  No Deposit
2                             0                     1      1  ...  No Deposit
3                             0                     1      1  ...  No Deposit
4                             0                     2      2  ...  No Deposit
```

```
      agent  company  days_in_waiting_list  customer_type  adr \
0      NaN      NaN                     0      Transient  0.0
1      NaN      NaN                     0      Transient  0.0
2      NaN      NaN                     0      Transient  75.0
3  304.0      NaN                     0      Transient  75.0
4  240.0      NaN                     0      Transient  98.0
```

```
      required_car_parking_spaces  total_of_special_requests  reservation_status \
0                                 0                           0              Check-Out
```

1	0	0	Check-Out
2	0	0	Check-Out
3	0	0	Check-Out
4	0	1	Check-Out

	reservation_status_date
0	2015-07-01
1	2015-07-01
2	2015-07-02
3	2015-07-02
4	2015-07-03

[5 rows x 32 columns]


1 3. tratamiento de valores ausentes

```
[3]: nulls = df.isnull().sum()
nulls[nulls > 0]
```

```
[3]: children      4
country      488
agent      16340
company      112593
dtype: int64
```

```
[4]: sns.countplot(data=df, x="children")
print(df['children'].describe())
print(df['children'].mode()[0])
```

```
count      119386.000000
mean         0.103890
std          0.398561
min          0.000000
25%          0.000000
50%          0.000000
75%          0.000000
max          10.000000
Name: children, dtype: float64
0.0
```



```
[5]: df['children'] = df['children'].fillna(0)
df['children'].isnull().sum()
```


```
[5]: np.int64(0)
```

```
[6]: print(df['country'].count())
print(df['country'].isnull().sum())
```

```
118902
488
```

```
[7]: top = df['country'].value_counts().head(10)
top.plot(kind='bar')
```

```
[7]: <Axes: xlabel='country'>
```



```
[8]: df['country'] = df['country'].fillna('PRT')  
df['country'].isnull().sum()
```

```
[8]: np.int64(0)
```

2 questões

1. Quais dois atributos foram escolhidos e qual estratégia foi utilizada para tratar os valores ausentes de cada um?
 - foi escolhido 'country' e 'children', e a estratégia utilizada foi substituir pela moda
2. Quantos valores ausentes foram eliminados ou substituídos após o tratamento?
 - foram tratados 488 em country e 4 em children
3. Por que a estratégia escolhida é adequada para cada atributo?
 - country: por ser um atributo com pouquíssimos valores nulos proporcionais ~0.4% do total, substituir pelo valor mais frequente não vai alterar o padrão predominante
 - children: mesma justificativa da anterior, com menos ainda ~0.003% dos totais, e >90% das reservas tinham 0 crianças, então é justificável trocar por 0

3 4. remocao de registros duplicados

```
[9]: df.duplicated().sum()
```

```
[9]: np.int64(32013)
```

```
[10]: df = df.drop_duplicates()
```

4 questões

1. Quantos registros foram removidos e quantas instâncias permanecem no conjunto após a remoção?
 - tinham 32.013 instancias duplicadas, restaram 87.377 instancias

5 5. criação e transformação de atributos

```
[11]: df['total_nights'] = df['stays_in_weekend_nights'] + df['stays_in_week_nights']
```

```
[12]: df['total_nights'] = (  
    df['stays_in_weekend_nights'] +  
    df['stays_in_week_nights']  
)  
  
df['stay_length'] = pd.cut(  
    df['total_nights'],  
    bins=[0, 2, 5, float('inf')],  
    labels=['curta', 'media', 'longa'],  
    right=True  
)  
  
df['stay_length'].value_counts()
```

```
[12]: stay_length  
media    38151  
curta    32915  
longa    15660  
Name: count, dtype: int64
```

```
[13]: df.groupby('stay_length')['adr'].describe()
```


```
[13]:
```

	count	mean	std	min	25%	50%	75%	\
stay_length								
curta	32915.0	101.099516	58.720846	0.00	65.8300	94.59	129.00	
media	38151.0	110.951108	48.586229	0.00	78.0000	103.50	135.15	
longa	15660.0	110.570271	57.323309	-6.38	69.0975	98.36	141.46	

	max
stay_length	
curta	5400.0
media	402.0
longa	450.0

```
[14]: sns.barplot(data=df, x='stay_length', y='adr')
```

```
[14]: <Axes: xlabel='stay_length', ylabel='adr'>
```



6 questões

5. Quantas reservas pertencem a cada categoria de stay_length?

- curta = 32915
- média = 38151
- longa = 15660

7. Qual categoria representa a maior parte das reservas?

- média

8. Compare a distribuição de adr entre as três categorias de duração. Qual grupo apresenta o maior ADR médio?
- a categoria média

7 6. normalização

```
[15]: df['adr_normalized'] = ((df['adr'] - df['adr'].min()) / (df['adr'].max() -  
    ↪df['adr'].min()))  
  
df['adr_normalized'].describe()
```

```
[15]: count      87377.000000  
mean          0.020850  
std           0.010174  
min           0.000000  
25%          0.014498  
50%          0.019325  
75%          0.025966  
max           1.000000  
Name: adr_normalized, dtype: float64
```

8 questões

8. Após a normalização, qual é o menor e o maior valor de adr_normalized? Explique o que significa transformar o atributo adr para essa nova escala.
- a normalização mapeia os valores de adr para uma nova escala entre 0 e 1, com a proporção entre eles, o maior vai ser mapeado para 1.0 e o menor para 0.0

9 7. comparação final

```
[16]: old_df = pd.read_csv("hotel_bookings.csv")  
  
comparison = pd.DataFrame({  
    "Característica": [  
        "Número de instâncias",  
        "Número de atributos",  
        "Valores ausentes nos atributos escolhidos (country + children)",  
        "Registros duplicados"  
    ],  
    "Antes": [  
        old_df.shape[0],  
        old_df.shape[1],  
        old_df['country'].isnull().sum() + df['children'].isnull().sum(),  
        old_df.duplicated().sum()  
    ],  
})
```

```

    "Depois": [
        df.shape[0],
        df.shape[1],
        df['country'].isnull().sum() + df['children'].isnull().sum(),
        df.duplicated().sum()
    ]
})

print(comparison.to_string(index=False))

```

	Característica	Antes	Depois
	Número de instâncias	119390	87377
	Número de atributos	32	35
Valores ausentes nos atributos escolhidos (country + children)		488	0
	Registros duplicados	31994	0

O que foi necessário modificar nos dados para que eles estivessem mais adequados para uma etapa posterior de Mineração de Dados? - tratamentos de dados incompletos/faltantes, com substituição por valores coerente - eliminação de redundância, com a remoção de mais de 32 mil registros duplicados - criação de outra feature total_nights para a realização de uma categorização/discretização facilitando a extração de padrões - padronização de escala, na normalização de dados para o intervalo [0,1]