Questionário – Mineração de Dados

QUESTIONÁRIO – MINERAÇÃO DE DADOS

Este questionário tem como objetivo revisar os principais conceitos e métodos estudados na disciplina e preparar você para a avaliação.

A prova terá caráter predominantemente prático, envolvendo a interpretação de dados, escolha e aplicação de métodos de Mineração de Dados, análise de resultados e tomada de decisões a partir dos experimentos realizados. Por isso, não basta identificar a alternativa correta: é necessário compreender os conceitos e saber justificar as decisões tomadas.

Orientações

Para cada questão:

- Leia atentamente o enunciado e todas as alternativas.
- Marque a alternativa que você considera correta.
- Justifique sua resposta, explicando por que a alternativa escolhida está correta.
- Utilize os conceitos, propriedades, fórmulas, características dos algoritmos e resultados de experimentos estudados em aula para fundamentar sua resposta.
- Sempre que a questão envolver um algoritmo ou método, procure relacionar sua resposta ao seu funcionamento, às suas hipóteses, aos parâmetros e às situações em que ele pode ou não ser adequado.
- Não é necessário produzir textos longos. Uma boa justificativa deve ser objetiva, tecnicamente correta e suficiente para demonstrar que o conceito foi compreendido.

Relação com a prova

- Durante a prova, você poderá precisar:
- interpretar um conjunto de dados;
- identificar o tipo e as características dos atributos;
- escolher técnicas de preparação dos dados;
- selecionar medidas de similaridade ou distância;
- escolher um algoritmo de classificação adequado;
- configurar parâmetros de um modelo;
- interpretar métricas de avaliação;
- analisar resultados de experimentos;
- identificar problemas como overfitting e underfitting;
- comparar diferentes modelos;

- justificar uma escolha metodológica.

Portanto, ao responder este questionário, não se preocupe apenas em acertar a alternativa. Procure responder como se estivesse explicando para outra pessoa por que aquela é a resposta correta e quais conceitos sustentam sua decisão.

Recomendação: tente resolver inicialmente sem consultar o material. Depois, revise suas respostas utilizando as anotações, notebooks e códigos desenvolvidos durante a disciplina.

1. Fundamentos: tipos de atributos

1. Qual das alternativas abaixo descreve corretamente a hierarquia de tipos de atributos do mais simples ao mais complexo em termos de operações permitidas?

A) Binário → Numérico → Nominal → Ordinal.

B) Nominal → Ordinal → Intervalar → Razão.

C) Razão → Intervalar → Ordinal → Nominal.

D) Ordinal → Binário Assimétrico → Nominal → Intervalar.

2. Um atributo como 'Grau de Instrução' (Fundamental, Médio, Superior) é classificado como qual tipo e por quê?

A) Nominal, pois representa categorias sem qualquer relação de hierarquia ou grandeza.

B) Numérico de razão, pois podemos dizer que o Superior é três vezes o Fundamental.

C) Ordinal, pois os valores possuem uma ordem significativa entre si, mas a distância exata entre os níveis não é quantificada.

D) Binário assimétrico, pois o valor 'Superior' é o mais importante para a análise.

3. Qual a principal diferença entre atributos de escala intervalar e escala de razão?

A) Atributos de escala intervalar são sempre qualitativos, enquanto os de razão são sempre quantitativos.

B) Atributos de razão possuem um ponto zero inerente e significativo, permitindo dizer que um valor é o dobro de outro.

C) Escala de razão aceita apenas números inteiros, enquanto a intervalar aceita decimais.

D) Atributos intervalares são usados apenas para medir tempo e datas históricas.

4. Como os atributos ordinais são tratados para que possam ser utilizados em algoritmos

baseados em distância numérica?

A) Eles são mapeados para seus postos (ranks) e então normalizados para o intervalo $[0, 1]$.

B) Eles são convertidos em atributos nominais, descartando a informação de ordem.

C) Eles são transformados em vetores de frequência de palavras.

D) Eles são elevados ao quadrado para enfatizar a diferença entre os níveis mais altos.

5. Como se define a dissimilaridade para um atributo binário simétrico entre dois objetos?

A) É a razão entre o número de atributos onde os valores são diferentes e o número total de atributos binários.

B) É a diferença entre o número de matches positivos e o número de matches negativos.

C) É sempre zero se ambos os objetos possuírem pelo menos um valor '1'.

D) É a soma dos logaritmos das probabilidades de cada estado ocorrer individualmente.

6. Em mineração de dados, o que define um atributo binário simétrico?

A) O atributo pode ser invertido (trocar 0 por 1) sem alterar a média aritmética.

B) Ele só pode ser processado por algoritmos que utilizam o teorema de Bayes.

C) Ambos os seus estados (0 e 1) são igualmente importantes e carregam o mesmo peso informativo.

D) O atributo possui a mesma frequência de ocorrência para o valor 0 e para o valor 1.

7. Qual é a distinção crucial entre atributos binários simétricos e assimétricos no cálculo de proximidade?

A) O cálculo para binários simétricos ignora completamente os 'mismatches'.

B) Atributos assimétricos exigem obrigatoriamente a normalização por desvio padrão.

C) Em atributos assimétricos, a coincidência do valor '0' (ausência) é considerada irrelevante e não entra no cálculo de similaridade.

D) Atributos simétricos só permitem valores 'true' ou 'false', enquanto assimétricos permitem valores nulos.

2. Estatística descritiva e visualização

11. Em um conjunto de dados de salários: $30, 36, 47, 50, 52, 52, 56, 60, 63, 70, 70, 110$ (em milhares), qual é o valor da mediana e por que ela é útil?

A) 58 e é útil por representar o ponto de equilíbrio matemático exato da soma.

B) 54 e é útil por ser menos sensível a valores extremos (como 110) do que a média.

C) 52 e é útil por ser o valor mais frequente no conjunto de dados.

D) 70 e é útil por representar o valor médio entre o mínimo e o máximo.

12. Se uma distribuição de dados é 'positivamente inclinada' (positively skewed), qual é a relação típica entre média, mediana e moda?

A) $Mediana < Moda < Média$

B) $Média = Mediana = Moda$

C) $Média < Mediana < Moda$

D) $Moda < Mediana < Média$

13. Qual a diferença fundamental entre variância e desvio padrão como medidas de dispersão?

A) A variância é imune a outliers, enquanto o desvio padrão é fortemente afetado por eles.

B) A variância só pode ser calculada para dados positivos, enquanto o desvio padrão aceita dados negativos.

C) O desvio padrão mede a tendência central, enquanto a variância mede apenas a amplitude.

D) O desvio padrão está na mesma unidade que os dados originais, facilitando a interpretação, enquanto a variância está em unidades quadráticas.

14. O que o 'intervalo interquartil' (IQR) mede e como ele ajuda na detecção de outliers?

A) Mede a dispersão dos 50% centrais dos dados; valores muito além de $1,5 \times IQR$ dos quartis são considerados potenciais outliers.

B) Mede a frequência do valor que aparece exatamente no centro do histograma.

C) Mede a média dos desvios quadráticos em relação à média aritmética.

D) Mede a distância total entre o menor e o maior valor do conjunto de dados.

3. Preparação, limpeza e integração de dados

15. No algoritmo k-Nearest-Neighbor (KNN), qual é o efeito comum de selecionar um valor de k muito pequeno em um conjunto de dados com ruído?

A) O erro de treinamento aumentará significativamente devido à generalização excessiva.

B) O modelo torna-se excessivamente sensível ao ruído local, aumentando o risco de overfitting.

C) As fronteiras de decisão tornam-se mais suaves e menos complexas.

D) O algoritmo ignorará outliers, focando apenas na tendência global dos dados.

16. No processo de integração de dados, qual problema ocorre quando um mesmo conceito possui nomes diferentes em bases distintas?

A) Redundância de tuplas duplicadas.

B) Problema de identificação de entidade.

C) Conflito de valores de dados.

D) Inconsistência de integridade referencial.

17. Qual técnica de limpeza de dados é considerada a mais robusta para lidar com valores ausentes ao aproveitar as correlações entre atributos?

A) Ignorar a tupla inteira sempre que houver um atributo faltando.

B) Utilizar o valor mais provável determinado por ferramentas de inferência como indução de árvores de decisão ou formalismo Bayesiano.

C) Substituir todos os valores ausentes por uma constante global como 'Desconhecido'.

D) Preencher com a média global do atributo para todos os registros.

18. Ao lidar com dados 'sujos' onde muitos registros de renda estão ausentes, qual estratégia de limpeza é preferível se a distribuição da renda por classe for assimétrica

(skewed)?

A) Preencher com a média global de todos os clientes no banco de dados.

B) Preencher com a mediana dos valores daquela classe.

C) Ignorar todas as tuplas que possuem o valor de renda ausente.

D) Substituir todos os valores ausentes por zero.

19. Como a técnica de 'Binning' auxilia no tratamento de dados ruidosos em atributos numéricos?

A) Ao converter todos os números negativos em valores absolutos positivos.

B) Ao identificar e remover automaticamente registros que são outliers estatísticos.

C) Ao agrupar valores em 'baldes' e substituí-los pela média ou mediana do balde, suavizando flutuações irrelevantes.

D) Ao duplicar os registros raros para equilibrar a representação das classes.

20. Como a técnica de 'smoothing by bin means' atua na redução de ruído nos dados?

A) Ela agrupa dados qualitativos em categorias hierárquicas superiores.

B) Ela divide os dados ordenados em 'caixas' (bins) e substitui cada valor pela média dos valores contidos naquela caixa.

C) Ela remove permanentemente os valores que estão nos extremos (caudas) da distribuição.

D) Ela utiliza regressão linear para forçar os dados a se ajustarem a uma reta perfeita.

21. Ao comparar a eficácia de algoritmos com dados ruidosos, por que o Naive Bayes é frequentemente considerado mais robusto ao ruído do que o KNN?

A) O Naive Bayes usa probabilidades agregadas de todo o conjunto de dados, enquanto o KNN é afetado pelo ruído de vizinhos locais específicos.

B) O KNN exige que os dados sejam linearmente separáveis para funcionar com ruído.

C) Árvores de decisão sempre superam o Naive Bayes em dados com ruído devido à poda.

D) O Naive Bayes elimina automaticamente os outliers durante a fase de treinamento.

22. Em relação à eficácia com dados ruidosos, por que modelos de Árvores de Decisão podem sofrer mais do que SVMs se não forem devidamente ajustados?

A) Árvores de decisão exigem que o ruído seja normalizado antes do treinamento.

B) As árvores tendem a criar sub-divisões muito específicas para cada outlier (overfitting), enquanto o SVM foca na margem de separação global.

C) As árvores de decisão não suportam atributos numéricos ruidosos.

D) O SVM ignora completamente os vetores de suporte se eles forem ruidosos.

4. Similaridade, dissimilaridade e medidas de distância

23. Cenário: Você precisa classificar documentos de texto em categorias temáticas. Os dados são vetores de frequência de termos esparsos e de alta dimensão. Qual métrica de similaridade e algoritmo seriam ideais?

A) Distância de Manhattan com KNN ($k = 100$).

B) Similaridade de Cosseno com Naive Bayes Multinomial.

C) Distância Euclidiana com Árvore de Decisão.

D) Correlação de Pearson com Clustering Hierárquico.

24. Dadas as tuplas de atributos numéricos $A = (22, 1, 42, 10)$ e $B = (20, 0, 36, 8)$, qual é a distância Euclidiana entre esses dois objetos?

A) 6

B) $\sqrt{11}$

C) $\sqrt{45} \approx 6,71$

D) 11

25. Qual é a principal aplicação da medida de dissimilaridade de Minkowski no contexto de mineração de dados?

A) Agir como uma generalização que inclui as distâncias Euclidiana e de Manhattan dependendo do parâmetro h.

B) Calcular a similaridade entre documentos de texto baseada apenas na presença de

palavras.

C) Determinar a correlação estatística entre duas variáveis aleatórias.

D) Medir a distância entre atributos ordinais sem convertê-los para numéricos.

26. A distância de Manhattan é frequentemente preferida à Euclidiana em quais situações específicas?

A) Em cenários onde o movimento é restrito a caminhos em eixos ortogonais, como o traçado de ruas em uma cidade.

B) Quando se deseja penalizar de forma extrema as grandes diferenças em um único atributo.

C) Para calcular a similaridade entre faces humanas em imagens digitais.

D) Sempre que os dados forem esparsos e representarem frequências de termos.

27. Para calcular a dissimilaridade entre dois objetos descritos por atributos nominais, qual fórmula é utilizada?

A) O coeficiente de correlação de Pearson entre os vetores de estado.

B) A raiz quadrada da soma das diferenças de categorias elevadas ao quadrado.

C) $d(i, j) = \frac{p-m}{p}$, onde m é o número de matches e p o total de atributos.

D) A contagem absoluta de quantos atributos são nulos em ambos os objetos.

28. O coeficiente de Jaccard é uma medida de similaridade aplicada preferencialmente a qual tipo de dado?

A) Atributos ordinais com muitos níveis hierárquicos.

B) Atributos binários assimétricos.

C) Imagens de satélite em formato raster.

D) Atributos numéricos de alta variância.

29. Ao lidar com atributos de tipos mistos em um banco de dados, qual é o procedimento padrão para calcular uma matriz de dissimilaridade única?

A) Ignorar todos os atributos não numéricos para simplificar o cálculo Euclidiano.

B) Criar uma matriz de dissimilaridade separada para cada tipo e somar os valores finais sem normalização.

C) Processar todos os atributos juntos, normalizando-os para uma escala comum entre $0,0$ e $1,0$.

D) Converter todos os atributos em binários (one-hot encoding) e usar apenas a distância de Jaccard.

5. K-Nearest Neighbor (KNN)

30. O que diferencia fundamentalmente um classificador k-nearest-neighbor (KNN) de métodos como árvores de decisão ou máquinas de vetores de suporte (SVM)?

A) O KNN é um aprendiz preguiçoso (lazy learner) que armazena os dados de treinamento e adia a generalização até encontrar uma tupla de teste.

B) O KNN assume que todos os atributos são condicionalmente independentes em relação à classe.

C) O KNN utiliza funções de base radial para projetar dados em dimensões superiores antes da classificação.

D) O KNN constrói uma árvore hierárquica baseada no ganho de informação para particionar o espaço de atributos.

31. Por que a normalização de atributos numéricos, como 'renda' e 'idade', é considerada um passo crítico antes de aplicar o classificador KNN?

A) Para converter atributos ordinais em valores numéricos contínuos.

B) Para evitar que atributos com escalas maiores dominem injustamente o cálculo da distância.

C) Para reduzir a dimensionalidade do espaço de características e acelerar o cálculo.

D) Para garantir que a média de cada atributo seja exatamente zero.

32. Qual é a principal desvantagem computacional do classificador KNN em comparação com algoritmos de 'aprendizado ávido' (eager learners)?

A) O tempo de treinamento é extremamente longo devido à construção de árvores complexas.

B) Ele requer o cálculo de gradientes descendentes em múltiplas iterações.

C) A fase de poda (pruning) consome muita memória RAM em grandes conjuntos de dados.

D) O custo de classificação é alto, pois exige a busca em toda a base de treinamento para cada novo teste.

6. Árvores de decisão

33. Na construção de uma Árvore de Decisão, o que o conceito de 'Entropia' busca medir ao selecionar um atributo para divisão?

A) A impureza ou desordem dos dados em uma partição.

B) O número total de ramos que a árvore terá após a divisão.

C) A distância euclidiana média entre os pontos de classes diferentes.

D) A correlação linear entre o atributo preditor e a classe alvo.

34. Qual é o objetivo principal da técnica de 'poda posterior' (postpruning) em algoritmos de árvore de decisão como o CART?

A) Remover ramos que capturaram ruído ou anomalias nos dados de treinamento para melhorar a generalização.

B) Garantir que a árvore seja sempre estritamente binária.

C) Interromper o crescimento da árvore assim que um limite de profundidade é atingido.

D) Aumentar a precisão no conjunto de treinamento através da criação de regras mais específicas.

35. Como o método RainForest aborda o desafio da escalabilidade na indução de árvores de decisão em grandes bases de dados?

A) Utilizando amostragem aleatória simples para treinar a árvore em apenas 1% dos dados.

B) Convertendo toda a base de dados em uma matriz de adjacência densa.

C) Mantendo estruturas AVC-set que resumem a contagem de classes por valor de atributo, evitando carregar todos os dados na memória.

D) Aplicando transformações de Wavelet para comprimir os atributos numéricos.

7. Métodos de ensemble

36. Qual é a principal distinção no funcionamento dos algoritmos de ensemble Bagging e Boosting?

A) O Boosting utiliza apenas amostragem com reposição, enquanto o Bagging ignora a distribuição dos dados.

B) O Bagging treina modelos em paralelo de forma independente, enquanto o Boosting treina modelos sequencialmente, onde cada novo modelo tenta corrigir os erros do anterior.

C) O Bagging requer que todos os classificadores base sejam árvores de decisão, enquanto o Boosting aceita qualquer algoritmo.

D) O Boosting utiliza votos com pesos iguais para todos os modelos, enquanto o Bagging atribui pesos maiores a modelos mais precisos.

37. Como o algoritmo Random Forest expande o conceito de Bagging para melhorar a diversidade entre as árvores?

A) Ele utiliza apenas atributos ordinais para garantir que as árvores sejam sempre binárias.

B) Ele introduz a seleção aleatória de um subconjunto de atributos em cada nó para determinar a melhor divisão.

C) Ele obriga que cada árvore seja treinada em um cluster diferente gerado por k-means.

D) Ele remove automaticamente os outliers antes de construir cada árvore individual.

38. Cenário: Um banco quer prever a inadimplência de clientes. Os dados históricos têm pouquíssimos exemplos de inadimplentes (classe minoritária). Qual estratégia de ensemble é mais agressiva para melhorar a detecção dessa classe?

A) Uso de uma única árvore de decisão profunda.

B) Boosting (como o AdaBoost).

C) Votação Majoritária Simples.

D) Bagging simples.

8. Naive Bayes

39. Qual é a suposição simplificadora do classificador Naive Bayes e como ela afeta sua aplicação?

A) Assume que a distância entre os objetos é irrelevante para a predição da classe.

B) Assume que os dados seguem uma distribuição perfeitamente normal, o que impede seu uso em dados binários.

C) Assume que o hiperplano de separação deve passar pela origem do sistema de coordenadas.

D) Assume a independência condicional de classe, o que simplifica o cálculo de probabilidades mas pode ignorar correlações importantes.

40. Se um atributo categórico no Naive Bayes apresenta uma probabilidade de zero para uma determinada classe no conjunto de treinamento, qual é a consequência no cálculo da probabilidade posterior?

A) O valor zero será substituído pela média global de todas as classes.

B) O classificador ignorará esse atributo e usará apenas os restantes para a média.

C) A classe será automaticamente selecionada como a mais provável devido à raridade.

D) A probabilidade posterior total daquela classe será anulada (tornando-se zero), independentemente dos outros atributos.

41. Qual das seguintes situações representa um cenário ideal para o uso do classificador Naive Bayes?

A) Cenários que exigem a modelagem de fronteiras de decisão não-lineares complexas com poucos dados.

B) Problemas de regressão numérica onde o objetivo é prever um valor contínuo exato.

C) Classificação de textos em larga escala, onde o volume de dados é imenso e os atributos (palavras) são tratados como independentes.

D) Conjuntos de dados onde há forte correlação linear e dependência entre todas as variáveis de entrada.

9. Support Vector Machines (SVM)

42. O que define o 'Hiperplano de Margem Máxima' (MMH) em um modelo de Support Vector Machines (SVM)?

A) É o hiperplano que separa as duas classes garantindo a maior distância possível até os pontos de treinamento mais próximos.

B) É a linha média que passa pelo centro geográfico de todos os dados de ambas as classes.

C) É uma curva polinomial que envolve todos os dados da classe minoritária.

D) É um plano que minimiza a soma dos erros quadráticos de todos os pontos classificados incorretamente.

43. Em uma Máquina de Vetores de Suporte (SVM), qual é a função dos 'vetores de suporte'?

A) Eles funcionam como os vizinhos mais próximos no cálculo da distância de Manhattan.

B) Eles representam a média aritmética de cada classe no espaço multidimensional.

C) Eles são vetores artificiais criados para preencher lacunas de dados ausentes.

D) Eles são as tuplas de treinamento mais próximas do hiperplano que definem sua posição e margem.

44. Como o 'truque do kernel' (kernel trick) permite que o SVM lide com dados que não são linearmente separáveis?

A) Ele aplica uma função de logaritmo para suavizar a distribuição de outliers.

B) Ele divide o conjunto de dados em pequenos subconjuntos que são linearmente separáveis individualmente.

C) Ele reduz o número de atributos até que os dados possam ser separados por uma linha simples.

D) Ele calcula produtos escalares em um espaço de maior dimensão sem precisar transformar explicitamente os dados.

10. Outros conceitos

45. Cenário: Você possui um conjunto de dados médico com 50 atributos complexos e correlações desconhecidas. A precisão é vital, mas os médicos precisam entender o porquê de cada diagnóstico. Qual algoritmo é mais adequado?

A) KNN com $k = 1$.

B) Rede Neural Artificial.

C) Árvore de Decisão.

D) Máquina de Vetores de Suporte (SVM).

46. Cenário: Uma empresa de e-commerce precisa classificar milhões de transações em tempo real para detectar fraudes. O sistema recebe um fluxo constante de novos dados. Qual abordagem minimiza o custo de treinamento contínuo?

A) Treinamento de SVM com Kernel Polinomial.

B) Indução de Árvore de Decisão.

C) Ensemble de Boosting (AdaBoost).

D) Aprendizagem preguiçosa (como o KNN).

47. Cenário: Você está trabalhando com um conjunto de dados de bioinformática onde o número de atributos (genes) é muito maior que o número de amostras (pacientes) e os dados não são linearmente separáveis. Qual técnica é recomendada?

A) Regressão Linear.

B) Naive Bayes simples.

C) SVM com truque de Kernel (Kernel trick).

D) Cálculo de moda global para predição.