

Introdução a Mineração de Dados




Profª. Lívia Almada



UNIVERSIDADE
FEDERAL DO CEARÁ
CAMPUS QUIXADÁ

INTRODUÇÃO

Grande quantidade de dados
comerciais e científicos



Por quê Mineração de Dados?



Volume de Dados

Muitos dados estão sendo coletados e armazenados continuamente.



Pressão Competitiva

Forte concorrência de mercado exigindo decisões rápidas e inteligentes.



Supercomputação

Disponibilidade de computadores cada vez mais baratos e poderosos.



Altas Velocidades

Dados sendo gerados, transmitidos e acumulados em ritmo frenético.



Customização

Foco em melhorias constantes e no desenvolvimento de produtos personalizados.



Apoio Científico

Data mining auxiliando na análise de datasets e na formulação de hipóteses.

Grandes oportunidades para melhorar a produtividade em todas as esferas da vida

McKinsey Global Institute

Big data: The next frontier for innovation, competition, and productivity

Big data—a growing torrent

\$600 to buy a disk drive that can store all of the world's music

5 billion mobile phones in use in 2010

30 billion pieces of content shared on Facebook every month

40% projected growth in global data generated per year vs. **5%** growth in global IT spending

235 terabytes data collected by the US Library of Congress in April 2011

15 out of 17 sectors in the United States have more data stored per company than the US Library of Congress

Big data—capturing its value

\$300 billion potential annual value to US health care—more than double the total annual health care spending in Spain

€250 billion potential annual value to Europe's public sector administration—more than GDP of Greece

\$600 billion potential annual consumer surplus from using personal location data globally

60% potential increase in retailers' operating margins possible with big data


140,000–190,000 more deep analytical talent positions, and

1.5 million more data-savvy managers needed to take full advantage of big data in the United States

Grandes oportunidades para resolver os principais problemas da sociedade



Improving health care and reducing costs



Predicting the impact of climate change



Finding alternative/ green energy sources



Reducing hunger and poverty by increasing agriculture production

O que é Mineração de Dados?



Extração de Conhecimento

Consiste na obtenção **não trivial** de **informações implícitas** dos dados.

Visa revelar conhecimento previamente desconhecido e com alto potencial de utilidade prática.



Exploração e Análise

Processamento inteligente através de meios **automáticos ou semi-automáticos**.

Varredura de imensas bases de dados para descobrir **padrões significativos** e tendências ocultas.

O que é Mineração de Dados?



Fonte: tradução adaptada de (FAYYAD *et al.* 1996a)

O que **não** é Mineração de Dados?



Não é Data Mining

Procurar o número de telefone no catálogo telefônico.

Consultar um mecanismo de pesquisa da Web para obter informações sobre "Amazon".




É Data Mining

Certos nomes são mais predominantes em alguns locais dos EUA (ex: O'Brien, O'Rourke, O'Reilly na área de Boston).

Agrupar documentos semelhantes retornados pelo mecanismo de pesquisa de acordo com seu contexto (ex: floresta amazônica vs Amazon.com).

Origens da Mineração de Dados





Database Technology, Parallel Computing, Distributed Computing

Tarefas da Mineração de Dados


Métodos Preditivos: Uso de algumas variáveis para prever valores futuros de outras variáveis.

Métodos Descritivos: Encontrar padrões interpretáveis que descrevem os dados.

LISE DE SÉRIE TEMPORAL E PREDIÇÃO DE TEMPERATURA



Classificação




Encontra um modelo para o atributo de classe como uma função dos valores de outros atributos.

Ex. Baseado nos atributos, prever se uma pessoa sobreviveu ou não ao Titanic

<https://www.kaggle.com/c/titanic>

Classificação

Modelo baseado em árvore para prever o problema do Titanic



Exemplos de tarefas de classificação

- ▶ Classificar transações com cartão de crédito como legítimas ou fraudulentas
- ▶ Classificar coberturas de terras (massas de água, áreas urbanas, florestas, etc.) usando dados de satélite
- ▶ Categorizar notícias como finanças, clima, entretenimento, esportes, etc
- ▶ Previsão de células tumorais como benignas ou malignas
- ▶ Classificar estruturas secundárias de proteína

Exemplos de tarefas de classificação

- ▶ Classificar transações com cartão de crédito como legítimas ou fraudulentas
- ▶ Classificar coberturas de terras (massas de água, áreas urbanas, florestas, etc.) usando dados de satélite
- ▶ Categorizar notícias como finanças, clima, entretenimento, esportes, etc
- ▶ Previsão de células tumorais como benignas ou malignas
- ▶ Classificar estruturas secundárias de proteína

Regressão

Prediz o valor de uma determinada variável de **valor contínuo** com base nos valores de outras variáveis, assumindo um modelo linear ou não linear de dependência.


Exemplo: Prever o preço de uma casa

<https://www.kaggle.com/c/house-prices-advanced-regression-techniques>




Clusterização

Encontrar grupos de objetos de forma que os objetos em um grupo sejam similares (ou relacionados) uns aos outros e diferentes (ou não relacionados a) objetos em outros grupos.



Clusterização



Análise Associativa

Dado um conjunto de registros, cada um contendo algum número de itens de uma determinada coleção

Produzir regras de dependência que prevêm a ocorrência de um item com base nas ocorrências de outros itens.



<i>TID</i>	<i>Items</i>
1	Bread, Coke, Milk
2	Beer, Bread
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Coke, Diaper, Milk

Rules Discovered:

{Milk} --> {Coke}

{Diaper, Milk} --> {Beer}

Análise Associativa




An Example Subspace Differential Coexpression Pattern from lung cancer dataset

Three lung cancer datasets [Bhattacharjee et al. 2001], [Stearman et al. 2005], [Su et al. 2007]

Desvios/Anomalias/Detecção de mudanças

Detectar desvios significativos do comportamento normal



Fonte imagens:

https://scikit-learn.org/stable/modules/outlier_detection.html

<https://veja.abril.com.br/economia/como-funcionam-as-novas-fraudes-com-cartao-de-credito/>

Referências

Adaptação dos slides do livro Introduction to Data Mining, 2nd Edition

Tan, Steinbach, Karpatne, Kumar

