Universidade Federal do Ceará - Campus Quixadá
Professor: Renan Gomes Vieira
Disciplina: Aprendizado de Máquina 2026.2

Exercícios: Conceitos Básicos de AM

1. Porque precisamos de métodos de aprendizado de máquina para resolver determinados problemas do mundo real?
2. Explique com suas próprias palavras os seguintes termos: *etapa de treinamento*, *modelo*, *dados de treino*, *dados de teste*, *parâmetros de um modelo*.
3. Defina problemas de *regressão* e *classificação*. Dê três exemplos de cada no mundo real.
4. Você acha que grandes modelos de linguagem (Gemini, ChatGPT, Claude) se encaixam em problemas de *classificação*, *regressão* ou outro? Os problemas que tais modelos se propõem a resolver, podem ser classificamos como um problema *supervisionado*, *não-supervisionado* ou *semi-supervisionado* ou outro?
5. Defina ruído na modelagem de problemas de aprendizado de máquina e sua importância na definição dos limites dos resultados.
6. Considere os valores reais y e os valores estimados $\hat{y}$ produzidos por um modelo de regressão.

i	y (real)	$\hat{y}$ (estimado)
1	2.0	2.5
2	3.5	3.0
3	4.0	4.2
4	5.5	5.0
5	6.0	6.3

   - Calcule o erro (error) de cada observação:

$$e_i = y_i - \hat{y}_i$$

   - Calcule a **soma quadrática dos erros** (*Sum of Squared Errors – SSE*):

$$SSE = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

   - Calcule o **erro root-mean-square** (*Root-Mean-Square Error – RMS*):

$$RMS = \sqrt{\frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2}$$

7. Qual o papel de uma função de um erro no treinamento de um modelo e como a regularização se relaciona com essa função?

8. Considere que você trabalha em uma equipe de ciência de dados responsável por analisar diferentes tipos de dados coletados em uma organização. Em cada situação abaixo, há dados disponíveis e um objetivo analítico possível.

   Para cada cenário:

   - Indique um exemplo de **modelo de predição** (prediction model) que poderia ser utilizado.
   - Indique um exemplo de **modelo de inferência** (inference model) que poderia ser utilizado.
   - Explique brevemente qual seria o objetivo em cada caso.

   (a) **Educação**: Uma universidade possui dados de estudantes contendo, *notas em disciplinas*, *frequência às aulas*, *participação em atividades acadêmicas*, *histórico escolar*. A instituição deseja analisar esses dados para entender melhor o desempenho acadêmico dos estudantes.

   (b) **Saúde**: Um hospital possui dados de pacientes contendo, *idade*, *pressão arterial*, *nível de colesterol*, *histórico de doenças*, *ocorrência ou não de doença cardíaca*. A instituição deseja analisar esses dados para apoiar decisões médicas e entender melhor os fatores associados a doenças cardíacas.

   (c) **Comércio eletrônico**: Uma empresa de e-commerce possui dados de usuários contendo, *histórico de compras*, *produtos visualizados*, *tempo de navegação*, *cliques em anúncios*. A empresa deseja analisar esses dados para entender melhor o comportamento dos usuários e melhorar suas estratégias de negócio.

9. Qual a importância de entender e saber que há um *erro irredutível* e um *erro redutível* ao projetar modelos de aprendizado de máquina?

10. Busque exemplos de métodos paramétricos e não-paramétricos e busque sintetizar a relação entre a quantidade de parâmetros dos métodos não-paramétricos e o tamanho do conjunto de dados.

11. Para cada um dos itens de (a) a (d), indique se, em geral, esperaríamos que o desempenho de um método de aprendizado estatístico **flexível** fosse **melhor** ou **pior** do que o de um método **inflexível**. Justifique sua resposta.

    (a) O tamanho da amostra n é extremamente grande, e o número de preditores p é pequeno.

    (b) O número de preditores p é extremamente grande, e o número de observações n é pequeno.

    (c) A relação entre os preditores e a resposta é altamente não linear.

    (d) A variância dos termos de erro, isto é, $\sigma^2 = \text{Var}(\epsilon)$, é extremamente alta.

Questões para entregar: 2, 4, 6, 10, 11.