Universidade Federal do Ceará - Campus Quixadá
Professor: Renan Gomes Vieira
Disciplina: Aprendizado de Máquina - 2026.2

Lista de Exercícios: Viés-Variância, KNN, Modelos Lineares, Logística e Bayes

1. Considere a decomposição viés-variância.

   (a) Forneça um esboço das curvas típicas de **viés ao quadrado**, **variância**, **erro de treinamento**, **erro de teste** e **erro de Bayes** (ou **erro irredutível**) em um único gráfico, à medida que passamos de métodos de aprendizagem estatística menos flexíveis para abordagens mais flexíveis. O eixo x deve representar o grau de flexibilidade do método, e o eixo y deve representar os valores de cada curva. Deve haver cinco curvas. Certifique-se de identificar cada uma delas.

   (b) Explique por que cada uma das cinco curvas possui o formato apresentado no item (a).

2. Conforme estudamos em aula, o algoritmo KNN pode ser utilizado tanto para problemas de classificação quanto de regressão.

   (a) Explique com suas palavras a diferença básica entre como o KNN calcula sua estimativa na classificação e como ele calcula na regressão.

   (b) Suponha que, para um ponto de teste, os $K = 3$ vizinhos mais próximos tenham os seguintes valores de resposta contínua de treinamento: $y_1 = 4$, $y_2 = 5$ e $y_3 = 9$. Qual será o valor predito pelo KNN usando a média simples?

   (c) O que acontece com a flexibilidade do KNN quando usamos um valor de K muito pequeno (por exemplo, $K = 1$) em comparação a um K muito grande (por exemplo, K igual ao número total de observações)? Qual dos dois casos tem maior risco de sofrer *overfitting*?

3. Considere que estamos usando o KNN para regressão com ponderação pela distância.

   (a) Qual é a intuição de atribuir pesos inversamente proporcionais à distância aos vizinhos em vez de usar uma média simples?

   (b) Suponha que estamos prevendo o valor de um imóvel e os dois vizinhos mais próximos ($K = 2$) estão a distâncias $d_1 = 1$ e $d_2 = 2$, com preços $y_1 = 300$ mil e $y_2 = 600$ mil. Se usarmos o peso $w_i = \frac{1}{d_i}$, qual será o preço estimado do imóvel?

4. Suponha que temos um conjunto de dados com cinco preditores, $X_1 = \text{GPA}$, $X_2 = \text{QI}$, $X_3 = \text{Nível}$ (1 para graduado no ensino superior e 0 para graduado no ensino médio), $X_4 = \text{interação entre GPA e QI}$, e $X_5 = \text{interação entre GPA e Nível}$.

   A variável resposta é o salário inicial após a graduação (em milhares de dólares). Suponha que usamos mínimos quadrados para ajustar o modelo, e obtemos $\hat{\beta}_0 = 50$, $\hat{\beta}_1 = 20$, $\hat{\beta}_2 = 0.07$, $\hat{\beta}_3 = 35$, $\hat{\beta}_4 = 0.01$, $\hat{\beta}_5 = -10$.

   (a) Qual alternativa está correta, e por quê?

i. Para um valor fixo de QI e GPA, graduados no ensino médio ganham mais, em média, do que graduados no ensino superior.

ii. Para um valor fixo de QI e GPA, graduados no ensino superior ganham mais, em média, do que graduados no ensino médio.

iii. Para um valor fixo de QI e GPA, graduados no ensino médio ganham mais, em média, do que graduados no ensino superior, desde que o GPA seja suficientemente alto.

iv. Para um valor fixo de QI e GPA, graduados no ensino superior ganham mais, em média, do que graduados no ensino médio, desde que o GPA seja suficientemente alto.

(b) Faça a predição do salário de um graduado no ensino superior com QI igual a 110 e GPA igual a 4.0.

5. Eu coleto um conjunto de dados ($n = 100$ observações) contendo um único preditor e uma resposta quantitativa. Em seguida, ajusto aos dados um modelo de regressão linear, bem como uma regressão cúbica separada, isto é,

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \varepsilon.$$

(a) Suponha que a relação verdadeira entre X e Y seja linear, isto é,

$$Y = \beta_0 + \beta_1 X + \varepsilon.$$

Considere a soma dos quadrados dos resíduos no conjunto de treinamento (*training RSS*) para a regressão linear e também o *training RSS* para a regressão cúbica. Esperamos que um deles seja menor que o outro, esperamos que sejam iguais, ou não há informação suficiente para dizer? Justifique sua resposta.

(b) Responda ao item (a) usando o *test RSS* em vez do *training RSS*.

(c) Suponha que a relação verdadeira entre X e Y não seja linear, mas não sabemos o quanto ela se afasta de uma relação linear. Considere o *training RSS* para a regressão linear e também o *training RSS* para a regressão cúbica. Esperamos que um deles seja menor que o outro, esperamos que sejam iguais, ou não há informação suficiente para dizer? Justifique sua resposta.

(d) Responda ao item (c) usando o *test RSS* em vez do *training RSS*.

6. Na aula sobre regressão linear e polinomial, discutimos que modelos muito flexíveis podem ter coeficientes que crescem excessivamente, levando ao sobreajuste (*overfitting*).

(a) Qual é a ideia geral por trás dos métodos de regularização (como Ridge e Lasso)?

(b) Qual a principal diferença entre o método Ridge e o método Lasso no que diz respeito aos coeficientes estimados quando aplicamos uma penalidade forte?

7. Em problemas de classificação binária ($Y \in \{0, 1\}$), usamos a regressão logística para garantir que as previsões representem probabilidades válidas entre 0 e 1, dada pela fórmula:

$$p(X) = P(Y = 1 \mid X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}}.$$

(a) Por que não é recomendado simplesmente ajustar uma reta de regressão linear comum para tentar prever probabilidades de uma classe?

(b) Suponha que um modelo de regressão logística foi ajustado para prever se um cliente vai comprar um produto ($Y = 1$), tendo como resultado os coeficientes $\beta_0 = -2$ e $\beta_1 = 0.5$, onde X é a quantidade de visitas ao site. Se um cliente visitou o site 4 vezes ($X = 4$), calcule a probabilidade prevista $p(X)$.

(c) Adotando o limiar de decisão de 0.5 (isto é, prevê 1 se $p(X) \geq 0.5$ e 0 caso contrário), qual seria a previsão para esse cliente?

8. Em relação à regressão logística com múltiplos preditores:

(a) O que chamamos de "fronteira de decisão" entre as duas classes? Essa fronteira na regressão logística é reta (linear) ou curva?

(b) Diferente da regressão linear simples, na regressão logística não usamos uma fórmula fechada direta para encontrar os coeficientes β. Como esses parâmetros costumam ser encontrados pelos algoritmos computacionais?

9. Considere um classificador Naive Bayes para decidir se um e-mail é **spam** (S) ou **não spam (ham,** H**)**. Para cada e-mail, observamos duas variáveis binárias:

- $X_1 \in \{0, 1\}$: presença da palavra `gratis` (1 se presente, 0 se ausente);
- $X_2 \in \{0, 1\}$: presença da palavra `reuniao` (1 se presente, 0 se ausente).

Suponha o seguinte conjunto de treinamento:

E-mail	**Classe** (Y)	X_1 (`gratis`)	X_2 (`reuniao`)
1	spam	1	0
2	spam	1	0
3	spam	1	0
4	ham	0	1
5	ham	1	1
6	ham	0	0

Deseja-se classificar um novo e-mail que possui ambas as palavras: $X_1 = 1$ e $X_2 = 1$.

(a) Calcule as probabilidades a priori $P(Y = \text{spam})$ e $P(Y = \text{ham})$.

(b) Sem usar suavização, observe que a palavra `reuniao` ($X_2 = 1$) nunca apareceu na classe spam no treino ($P(X_2 = 1 \mid \text{spam}) = 0$). Explique por que isso faz com que a probabilidade final do e-mail ser spam vire zero, ignorando o fato de que ele contém a palavra `gratis`.

(c) Para corrigir isso, aplique a **suavização de Laplace** com $\alpha = 1$:

$$\hat{P}(X_j = 1 \mid Y = k) = \frac{N_{kj} + 1}{N_k + 2},$$

onde N_{kj} é o número de vezes que a palavra apareceu na classe k e N_k é o total de e-mails da classe k. Calcule as novas probabilidades:

$$P(X_1 = 1 \mid \text{spam}), \quad P(X_2 = 1 \mid \text{spam}), \quad P(X_1 = 1 \mid \text{ham}), \quad P(X_2 = 1 \mid \text{ham}).$$

(d) Usando a premissa de independência do Naive Bayes e as probabilidades com Laplace calculadas no item (c), calcule o escore (não normalizado) para cada classe:

$$P(Y = \text{spam}) \times P(X_1 = 1 \mid \text{spam}) \times P(X_2 = 1 \mid \text{spam})$$

e

$$P(Y = \text{ham}) \times P(X_1 = 1 \mid \text{ham}) \times P(X_2 = 1 \mid \text{ham}).$$

Com base nesses valores, qual é a classe prevista para o novo e-mail?

10. Sobre a premissa fundamental do classificador Naive Bayes:

(a) Qual é a principal hipótese (suposição) feita pelo Naive Bayes a respeito dos preditores dentro de uma mesma classe? Por que dizemos que ela é "ingênua" (*naive*)?

(b) Mesmo quando essa hipótese de independência não é perfeitamente verdadeira na prática, por que o Naive Bayes ainda costuma funcionar bem em problemas com muitas variáveis (como classificação de textos)? Relacione sua resposta com o equilíbrio viés-variância.