Introdução ao Aprendizado de Máquina

Prof. Renan Gomes Vieira

Universidade Federal do Ceará - Campus Quixadá
[QXD0176] Aprendizado de Máquina

2026.2

Sumário

1. Aprendizado de Máquina 2026.2
2. Introdução ao Aprendizado de Máquina
3. Exemplo: Ajuste de curva polinomial

Aprendizado de Máquina 2026.2

Carga Horária, Avaliações e Regras

- **QXD0176**: Aprendizado de máquina
  - Pré-Requisito: [QXD0010] Estrutura de Dados
  - Pré-Requisito: [QXD0012] Probabilidade e Estatística
- **Carga Horária**: 64h
  - 48h teórica: 20–21 aulas expositivas, avaliações, com suas correções e discussões.
  - 16h prática: Resolução, aplicação e desenvolvimento de atividades em sala/laboratório.
- **Horários**:
  - Quinta: 08h-10h (T02) | 10h-12h
  - Sexta: 08h-10h (T02) | 10h-12h (T01)
- **Avaliações**: 3 avaliações parciais escritas em sala + pontos extras.
  - N = AP + EX
  - AP: Avaliações parciais em sala (8 pontos)
  - EX: Entrega de listas + miniteste em sala (2 pontos)

Avaliações, Listas de Exercícios e Minitestes

- As **aulas de exercício** serão utilizadas para resolução e discussão das listas.
- De cada lista, **algumas serão selecionadas para envio** antes da prova, **valendo 1 ponto**.
  - **Envios fora do prazo não serão considerados**.
- Na aula de exercício **antes das avaliações** haverá um **miniteste consultado** (anotações pessoais e exercícios), com uma única questão derivada da lista de exercícios resolvidas / discutidas no dia, **valendo 1 ponto**.

Critérios de aprovação

- Para aprovação, será adotado os critérios estabelecidos no regimento da UFC:
  - Presença de 75%
  - Média final: M = (N1 + N2 + N3)/ 3, M $\geq$ 7
  - Avaliação Final: (M + AF) / 2 $\geq$ 5
- Faltas **não** serão abonadas: *Conforme Regimento Geral da UFC, art. 113, "Na verificação da assiduidade, será aprovado o aluno que frequentar 75% (setenta e cinco por cento) ou mais da carga horária da disciplina,* ***vedado o abono de faltas****."*
- **Contestações sobre faltas** na chamada devem ser feitas ainda no mesmo dia. **Não serão consideradas contestações posteriormente**.

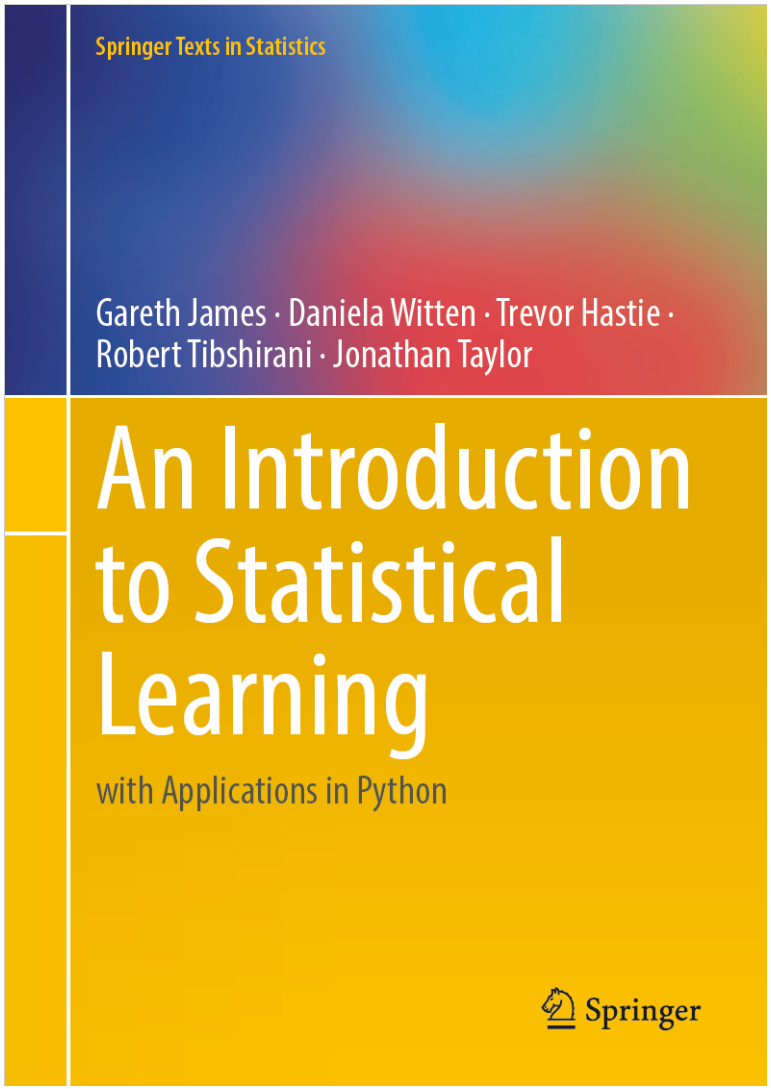
Ementa

1. Introdução
2. Extração de Características.
3. Árvores de Decisão.
4. Aprendizagem Baseada em Instâncias.
5. Aprendizagem Bayesiana.
6. Redes Neurais Artificiais.
7. Máquinas de Vetor de Suporte.
8. Tópicos Avançados em Aprendizagem de Máquina.
9. Projeto de Sistemas Inteligentes.

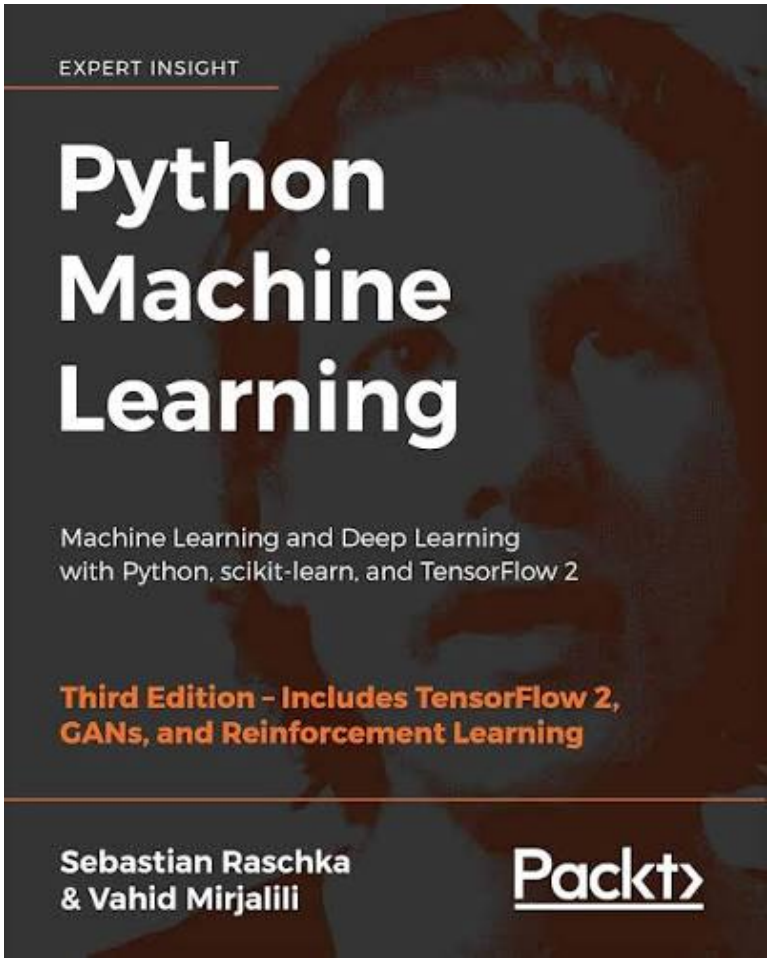
Bibliografia Básica

1. **JAMES, Gareth; WITTEN, Daniela; HASTIE, Trevor; TIBSHIRANI, Robert; TAYLOR, Jonathan. An introduction to statistical learning: with applications in Python. Cham: Springer, 2023. (Springer Texts in Statistics). ISBN 978-3-031-38747-0. DOI: 10.1007/978-3-031-38747-0.**
2. THEODORIDIS, Sergios; KOUTROUMBAS, Konstantinos. Pattern recognition. 4th ed. Burlington, MA: Academic Press, 2009. ISBN 9781597492720.
3. BISHOP, Christopher M. Pattern recognition and machine learning. New York, NY: Springer, 2006. xx, 738 p. (Information science and statistics). ISBN 9780387310732 (enc.).

Bibliografia Básica

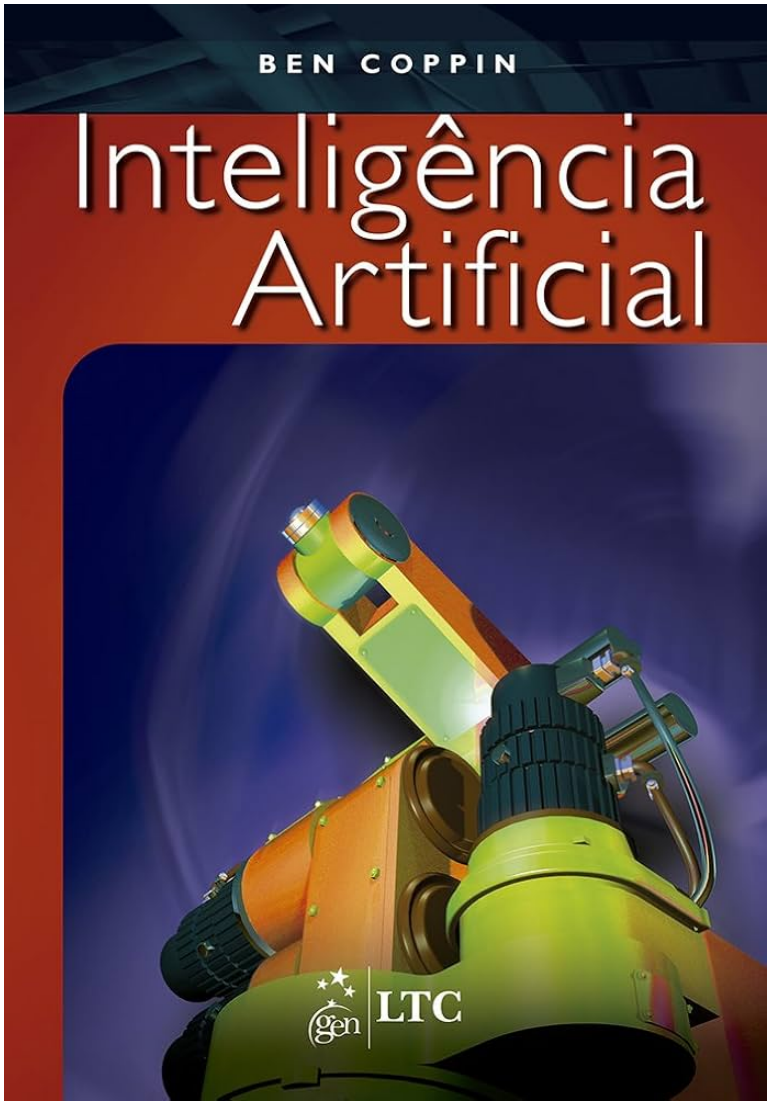


(a) ISLP, James et. al.

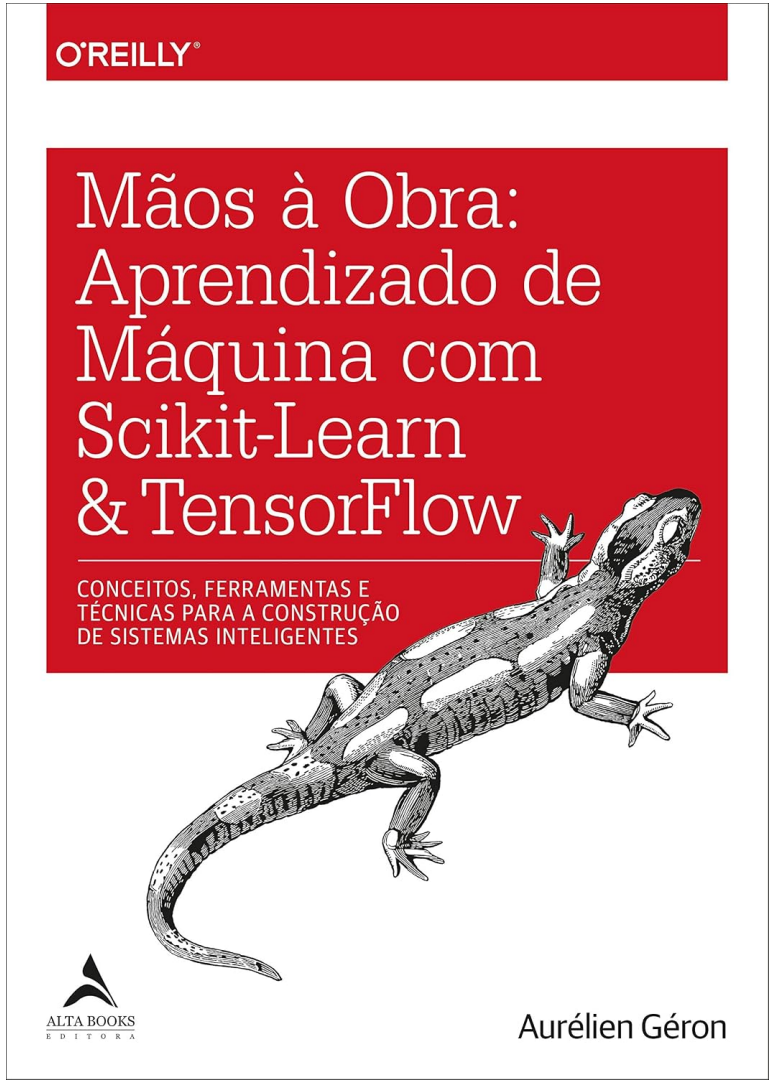


(b) PML, Sebastian Rashcka, Vahid Mirjalili

Bibliografia Básica

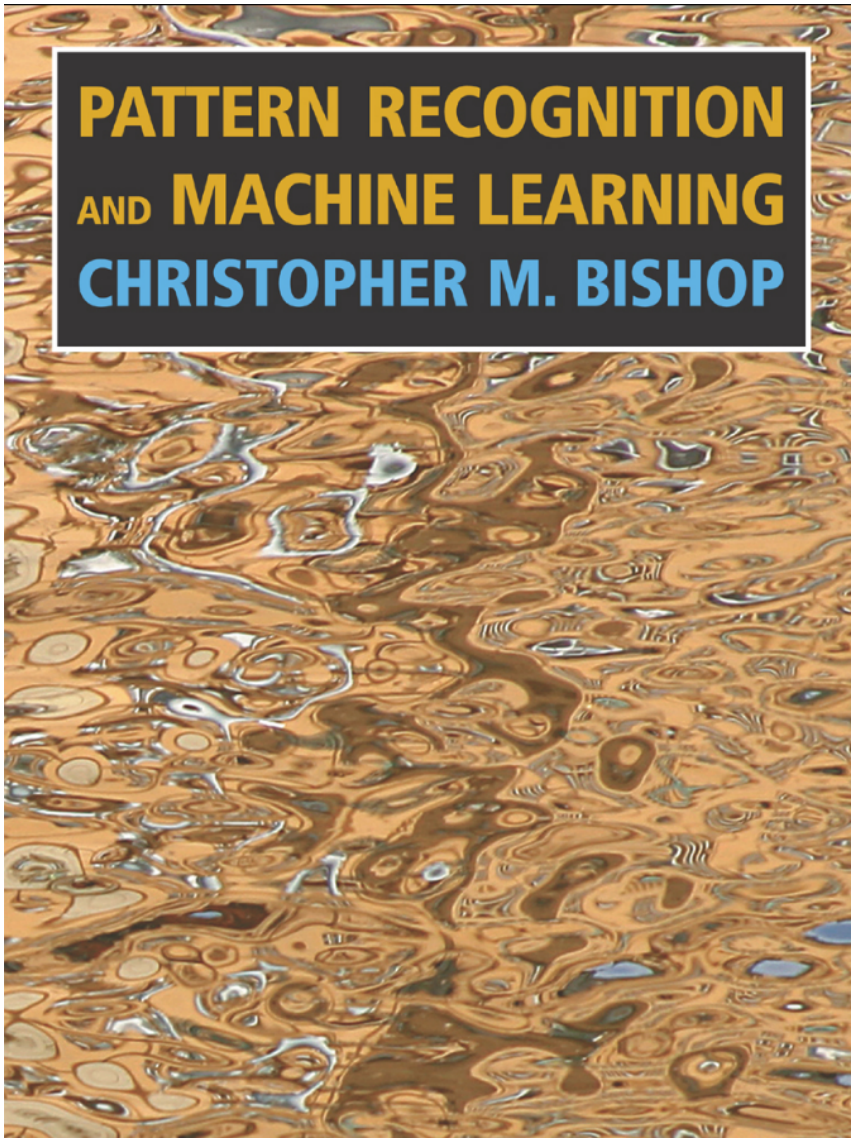


(a) IA, Ben Coppin

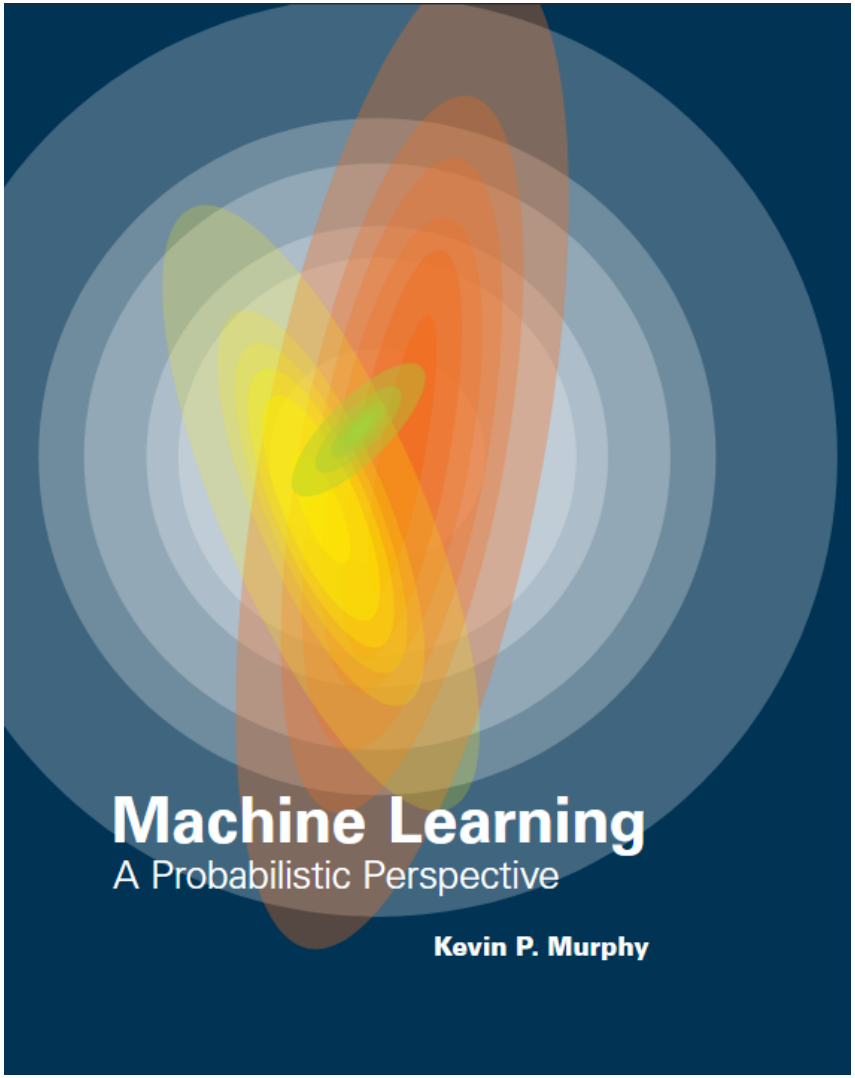


(b) MaOAM, Aurélien Géron

Bibliografia Básica



(a) PRML, Bishop



(b) MLPA, Murphy

Introdução ao Aprendizado de Máquina

Aprendizado de máquina

O conjunto de métodos que podem automaticamente **detectar padrões** em dados e então usar padrões descobertos para **predizer o futuro** ou para desempenhar outros tipos de **tomada de decisão**. [5]

Reconhecimento de Padrões

É o campo que está interessado em automaticamente descobrir regularidades em dados através do uso de algoritmos computacionais e com o uso de tais regularidades para tomar ações como classificar dados em diferentes categorias [1].

Exemplo: Reconhecimento de dígitos manuscritos

Vamos considerar o exemplo de reconhecer dígitos manuscritos.

- Cada dígito corresponde a uma imagem de 28×28 pixels, que pode ser representado por um vetor $\mathbf{x}$ de 784 números reais.
- O objetivo é construir uma máquina que recebe o vetor $\mathbf{x}$ e produza a identidade do dígito 0,...,9 como saída.

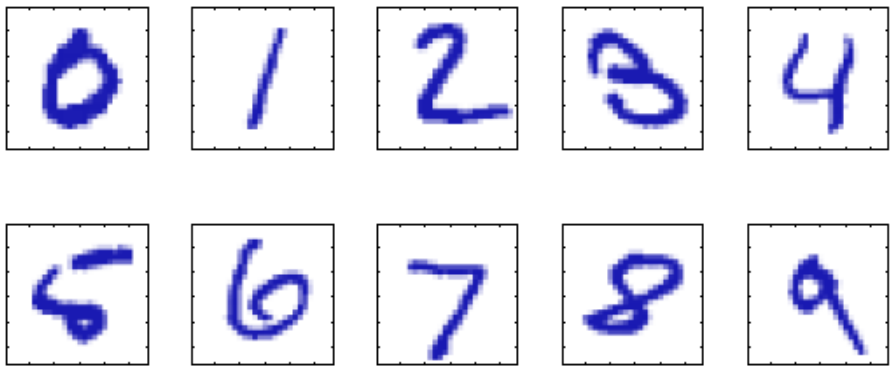


Figura 4: Exemplos de dígitos manuscritos retirados de códigos postais americanos

Representação da imagen

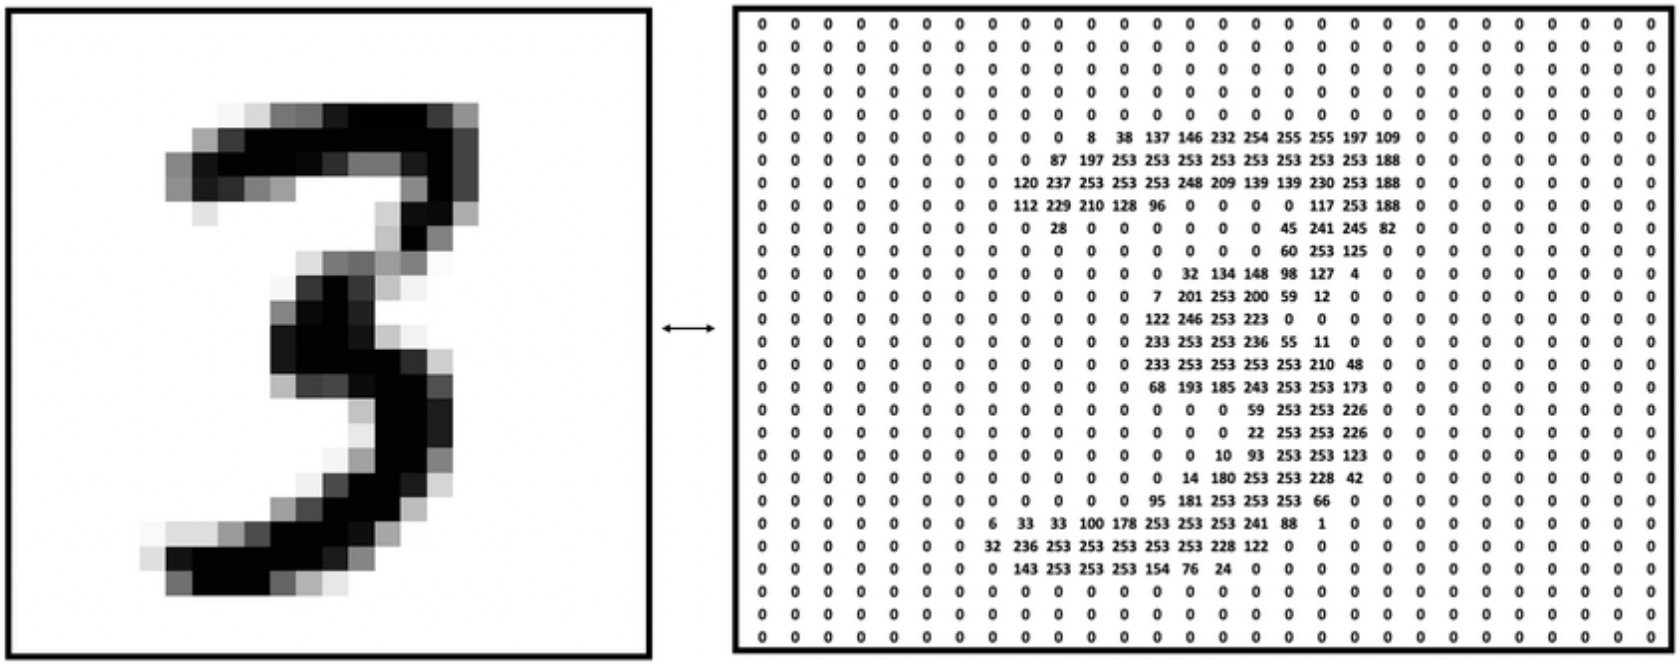


Figura 5: Cada pixel da imagem é representado por uma valor numérico, representando o grau de preto/cinza da imagem. Fonte: [2]

Exemplo: Reconhecimento de dígitos manuscritos

- Utilizando a programação tradicional, poderíamos pensar em regras e heurísticas para distinguir os dígitos baseado nos formato dos traços..
- ... mas na prática isso gera muitas regras e exceções e resultados ruins.

Conceitos iniciais

- Para melhores resultados adotamos uma abordagem de **aprendizado de máquina**, onde um conjunto grande de N dígitos $\{\mathbf{x}_1, ..., \mathbf{x}_N\}$, chamado de **conjunto de treino**, é utilizado para ajustar os **parâmetros** de um **modelo adaptativo**.
- As categorias dos dígitos no **conjunto de treino** já são conhecidas previamente. Podemos representar a categoria de um dígito usando um **vetor alvo t**.

Rotulação de dados

Normalmente, essa definição das categoria dos dígitos é feita por inspeção individual e manual e comumente chamada de **rotulação de dados**.

Conceitos iniciais

- O resultado da execução de um algoritmo de aprendizado de máquina pode ser expressado por $\mathbf{y}(\mathbf{x})$, que ao receber uma imagem de dígito $\mathbf{x}$ gera um vetor saída $\mathbf{y}$, codificado da mesma maneira que $\mathbf{t}$.
- A forma final de $\mathbf{y}(\mathbf{x})$ é determinada durante a **etapa de treinamento**, também conhecida como **etapa de aprendizado**, tendo como base os **dados de treino**.

Conceitos Iniciais

- Para a grande maioria das aplicações, as variáveis de entrada, comumente chamada de **atributos**, são **pre-processadas**, onde elas são transformadas de forma a tornar o aprendizado mais fácil de resolver.
  - No exemplo dos dígitos manuscritos, a imagens são editadas de forma que todas tenham o mesmo tamanho e posição similar no centro da imagem.
- Esta etapa é também chamada de **extração de atributos** e pode também ser aplicada para tornar o **treinamento mais rápido**.

Dados de teste

É importante destacar que os dados de teste devem passar pelo mesmos passos de processamento que os dados de treino.

Fluxograma básico

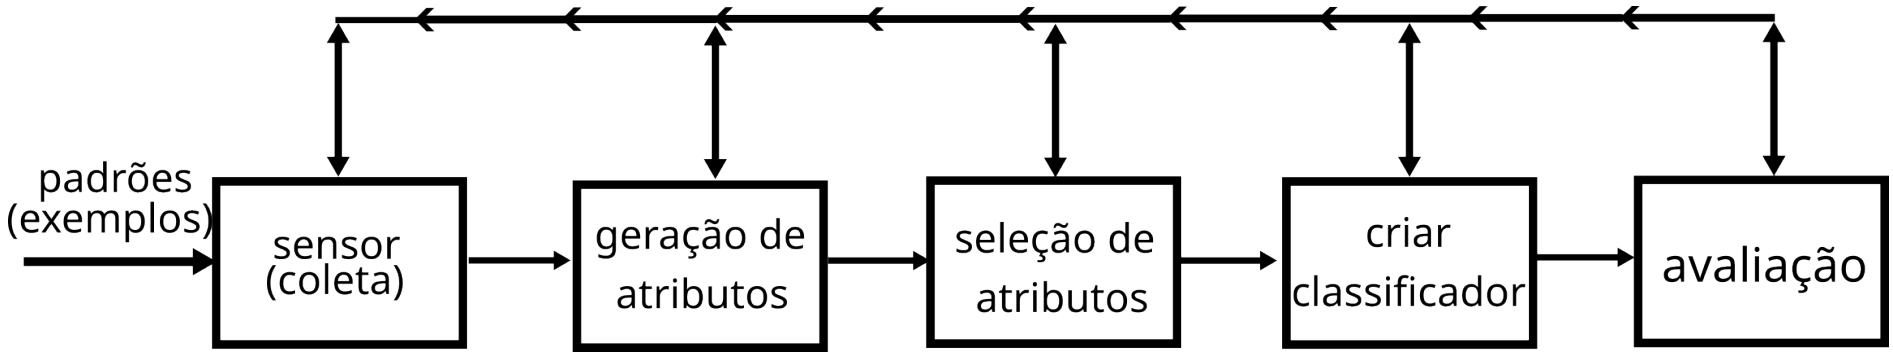


Figura 6: Fluxo simplificado do treinamento de modelos de Aprendizado de máquina. Fonte: Autor, baseado em [3]

Tipos de aprendizado

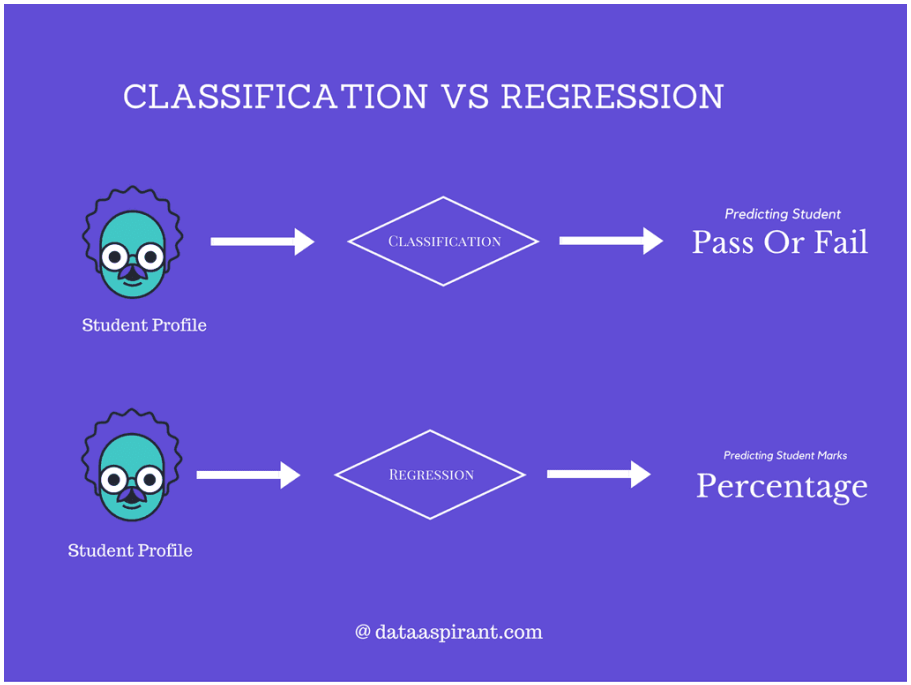
Aprendizado supervisionado

Problemas onde os dados de treino são compostos por vetores de entrada e seus respectivos vetores alvo/saída.

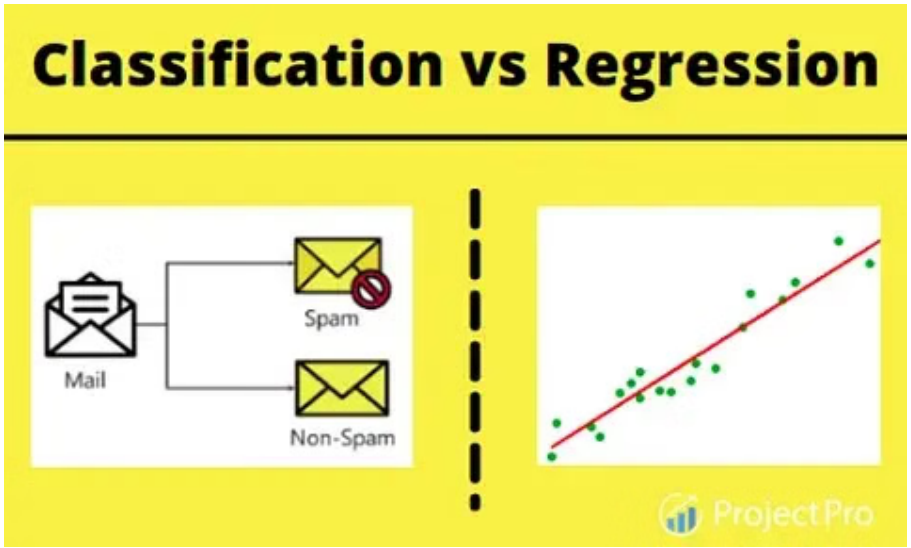
Problemas de *aprendizado supervisionado* podem ser divididos em duas categorias principais:

- **Classificação** - o objetivo é atribuir ao vetor de entrada uma categoria dentro de um conjunto finito de categorias.
- **Regressão** - o objetivo é atribuir ao vetor um (ou mais) valor contínuo y, tal que $y \in \mathbb{R}$

Exemplos

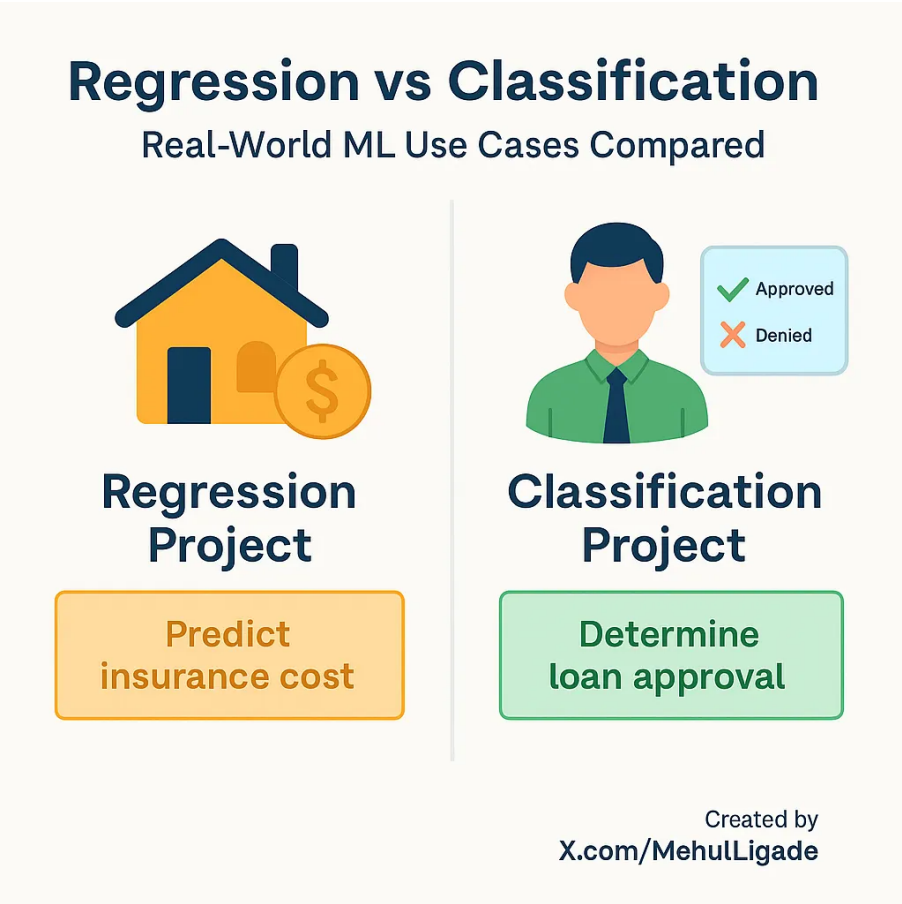


(a) Fonte: dataaspirante.com

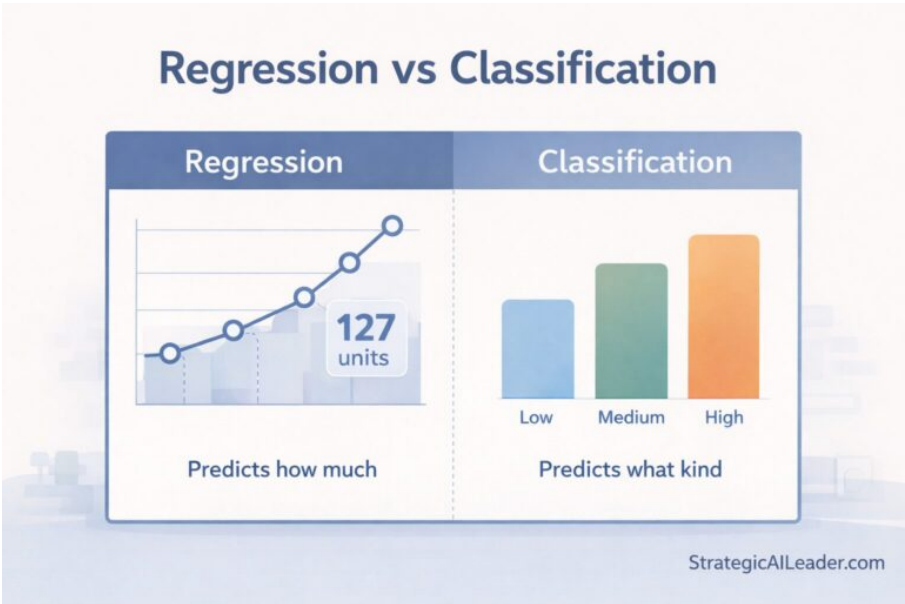


(b) Fonte: projectpro.io

Exemplos



(a) Fonte: towardsai.net



(b) Fonte: strategicaileader.com

Tipos de Aprendizado

Aprendizado não-supervisionado

Problemas onde os dados de treino não possuem seus correspondentes valores alvo/saída.

Problemas não-supervisionados podem ser divididos em três categorias:

- **Clusterização/Agrupamento** - quanto o objetivo é descobrir grupos de dados similares.
- **Estimativa de densidade** - quando o objetivo é determinar a distribuição dos dados
- **Redução de dimensionalidade** - reduzir dados de alta dimensão $x \in \mathbb{R}^n$ para um espaço menor, $x \in \mathbb{R}^m$, onde $m < n$. Geralmente, para uma redução de duas ou três dimensões, com propósito de **visualização**.

Exemplos: Não supervisionado

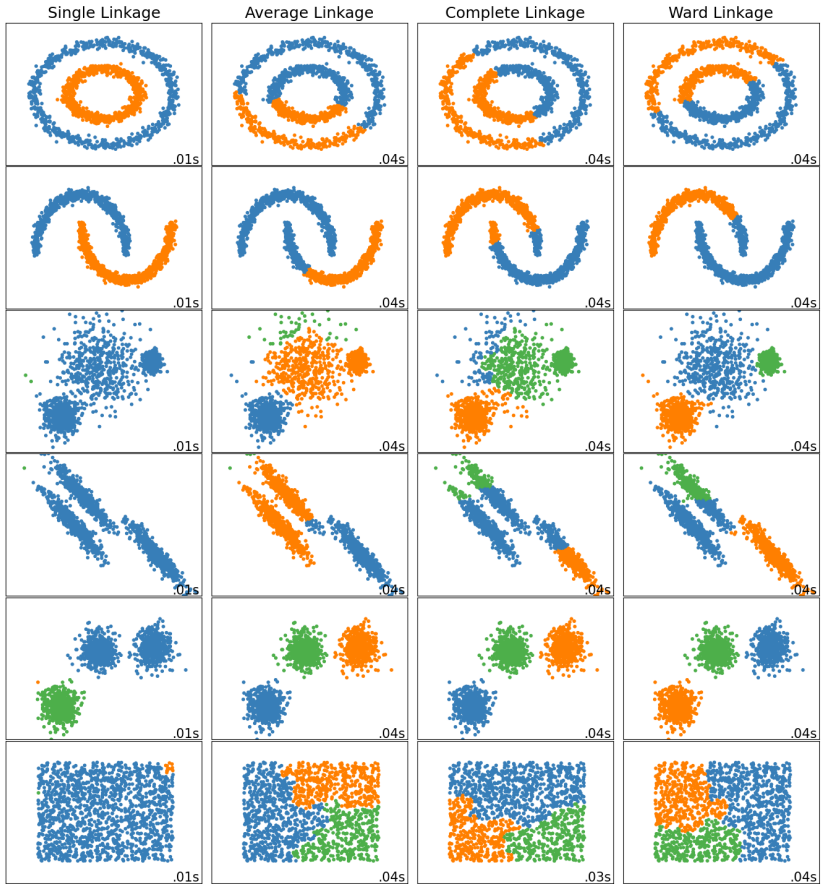


Figura 9: Agrupamento de dados 2D. O objetivo é agrupar dados similares, mas o que é "similar" vai depender da natureza dos dados. Fonte: scikit-learn.org

Exemplos: Não supervisionado

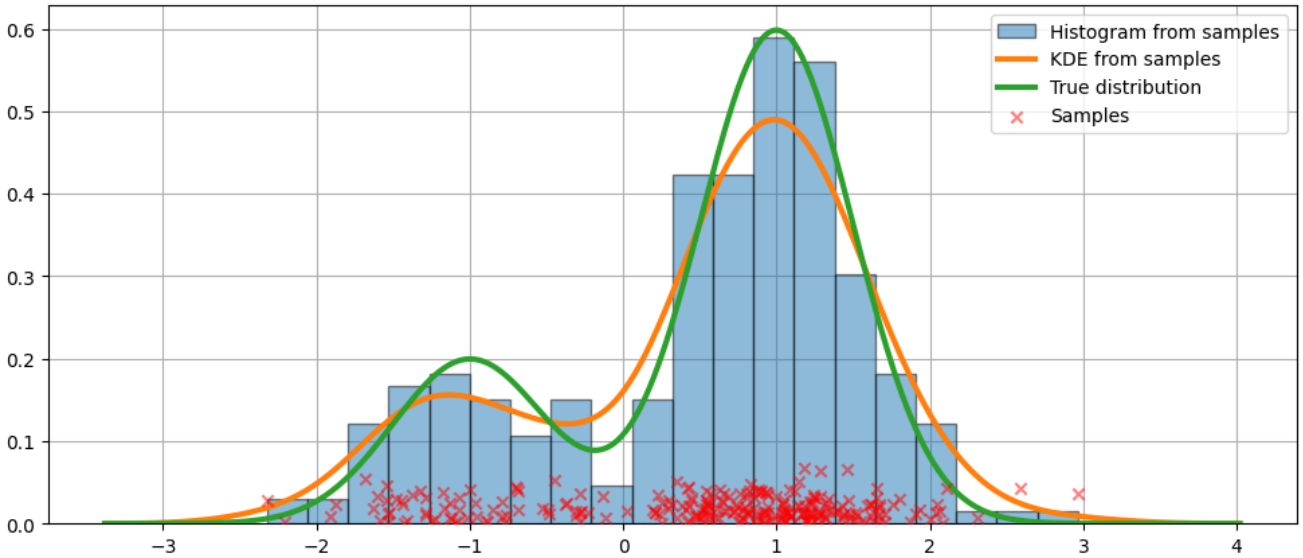


Figura 10: **Estimativa de densidade**: usada para estimar a distribuição de probabilidade dos dados, permitindo visualizar onde há maior concentração de pontos, identificar padrões e detectar possíveis anomalias. Fonte: statsmodels.org

Exemplos: Não supervisionado

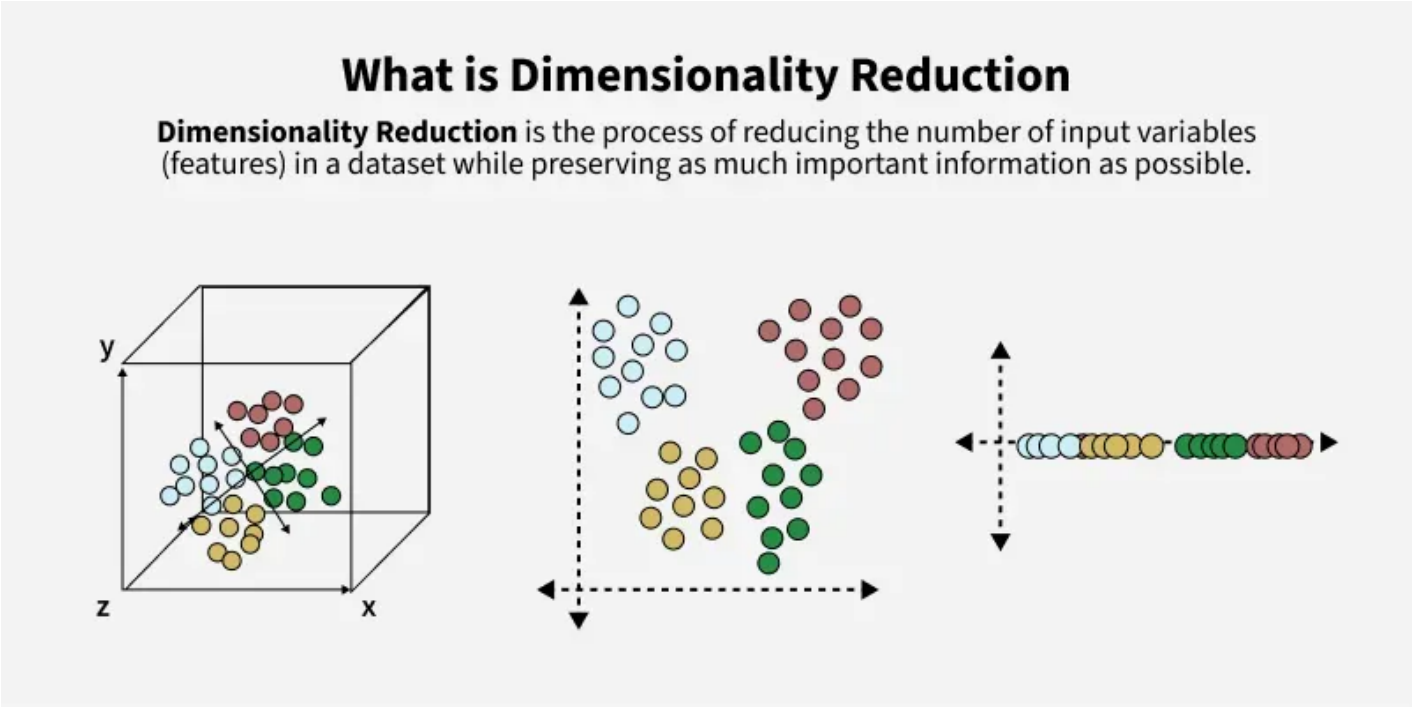


Figura 11: Reduzir a quantidade de atributos necessários para descrever um dado, mantendo a maior quantidade de informação possível. Fonte: geeksforgeeks.org

Tipos de aprendizado

Aprendizado por reforço

Problemas de encontrar ações apropriadas em determinados contextos, para maximizar uma recompensa. Nesse cenário, não há exemplos de saídas ideais, mas sim a **descoberta** dessas ações via tentativa e erro.

Conceitos importantes:

- **Estados** - Situação atual do ambiente em um determinado instante. É a informação que o agente observa para decidir o que fazer.
- **Ações** - São as decisões ou movimentos que o agente pode executar em cada estado.
- **Ambiente** - É tudo aquilo com que o agente interage. Ele recebe a ação do agente, muda de estado e retorna uma recompensa.
- **Recompensa** - É o *feedback* numérico que o agente recebe após executar uma ação. Guia o aprendizado.

Exemplos: Aprendizado por reforço

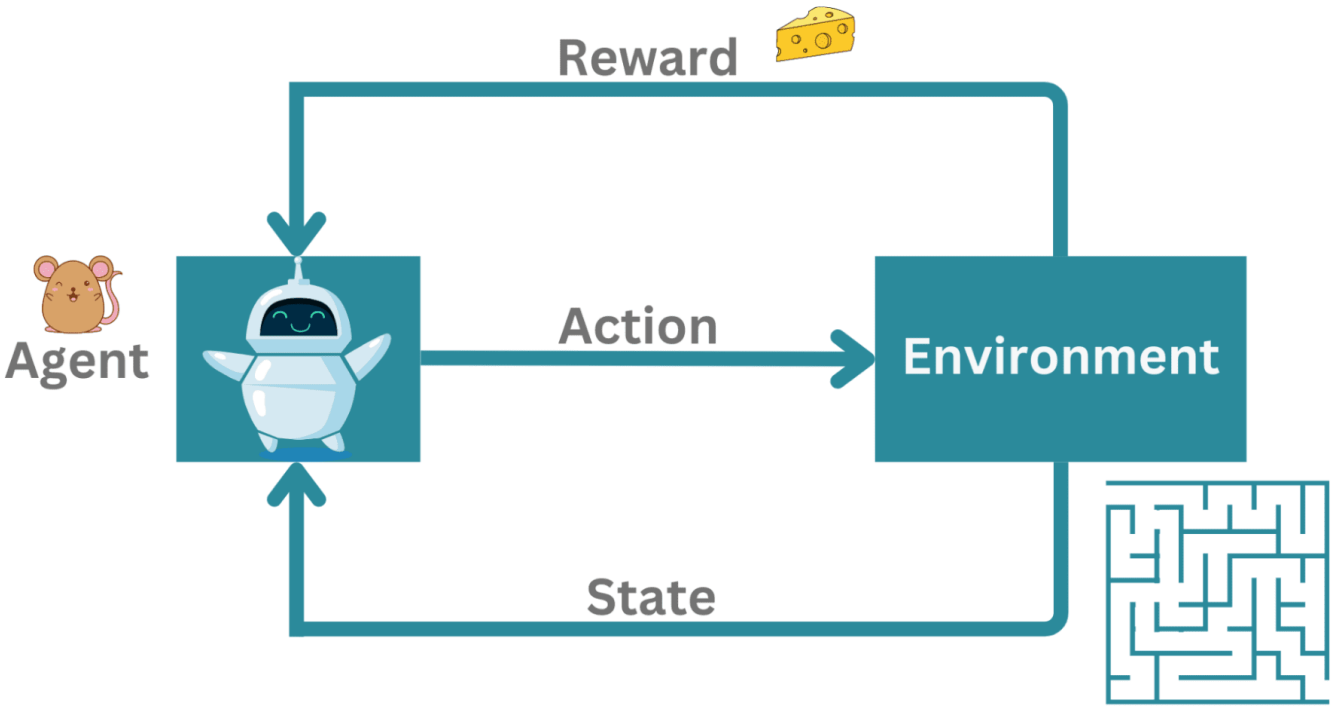


Figura 12: Normalmente, um agente opera em um ambiente simulado do real, simulando tomada de decisões. Fonte: kdnuggets.com

Exemplo: Ajuste de curva polinomial

Ajuste de curva polinomial

Começamos introduzindo um exemplo simples de problema de regressão.

- Observamos uma variável de entrada $x \in \mathbb{R}$.
- Queremos usar essa observação para predizer o valor alvo $t \in \mathbb{R}$
- **Atenção**: consideramos um exemplo sintético porque já sabemos qual o processo que gerou tais dados, de forma que a comparação com o modelo aprendido fica mais fácil.
- Nesse exemplo, os dados foram gerados a partir da função $sin(\pi x)$, com um *ruído Gaussiano*.

Ajuste de curva polinomial

Formalmente, temos um conjunto de dados de treino composto por N observações de x, dado como

$$\mathbf{x} \equiv (x_1, ...x_N)^T$$

junto as observações de t equivalentes, denotada

$$\mathbf{t} \equiv (t_1, ...t_N)^T.$$

Nesse exemplo, temos $N = 10$, com x espaçados uniformemente no intervalo $[0, 1]$, tendo os valores de t computados a partir da função $sin(2\pi x)$ e depois adicionado de um pequeno nível de ruído aleatório Gaussiano.

Ajuste de curva polinomial

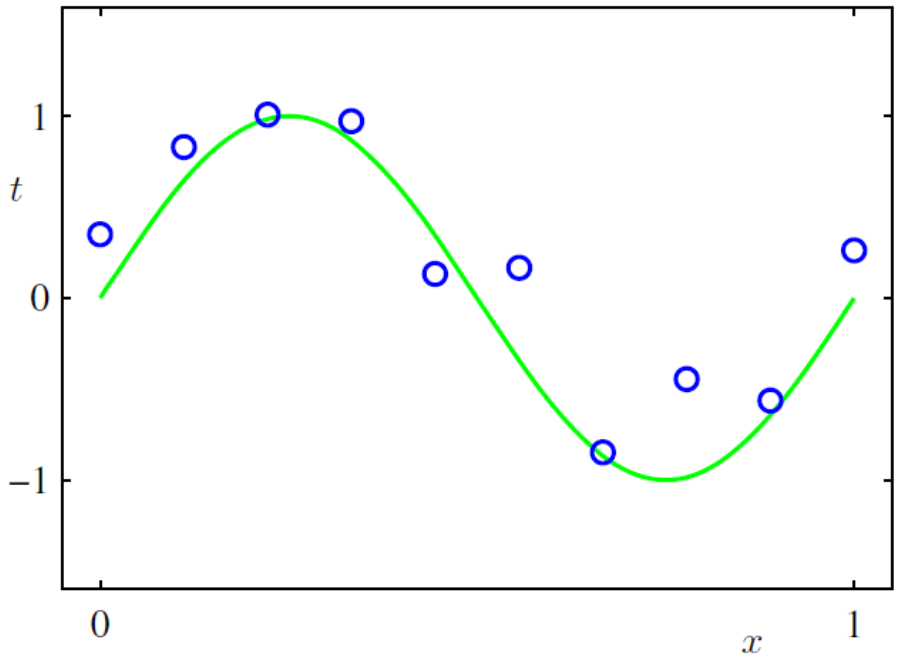


Figura 13: Gráfico de um conjunto de dados de treinamento com $N = 10$ pontos, mostrados como círculos azuis, cada um composto por uma observação da variável de entrada x juntamente com a variável alvo correspondente t. A curva verde mostra a função $sin(2\pi x)$ usada para gerar os dados. Nosso objetivo é prever o valor de t para algum novo valor de x, sem conhecimento da curva verde. Fonte: [1]

Ajuste de curva polinomial

Ruído

Ao gerar os dados dessa forma, estamos capturando uma propriedade de diversos datasets reais: eles possuem uma regularidade intrínseca, que desejamos aprender, mas que estão corrompidos por um ruído aleatório.

O ruído (*noise*) tem basicamente duas origens:

- Processos intrinsecamente aleatórios
- Fontes de variabilidade que são não-observáveis

Pergunta

Quais seriam possíveis ruídos em um processo de coleta de altura e peso de um grupo de pessoas?

Ajuste de curva polinomial

- **Objetivo**: Usar o conjunto de treino para fazer predições de valores $\hat{t}$ de um novo valor $\hat{x}$. Implicitamente, isso envolve descobrir a função $sin(2\pi x)$.
- Vamos começar com um uma abordagem mais simples e informal: uma função polinomial

$$y(x, \mathbf{w}) = w_0 + w_1 x + w_2 x^2 + \cdots + w_M x^M = \sum_{j=0}^{M} = w_j x^j$$

onde M é a *ordem* do polinômio, x^j denota x elevado a j. Os coeficientes polinomiais $w_o, \cdots, w_M$ são denotados pelo vetor $\mathbf{w}$

- Funções que são lineares nos parâmetros desconhecidos $\mathbf{w}$ são chamados de *modelos lineares*.

Ajuste de curva polinomial

- Os valores dos coeficientes serão determinados ajustando o polinômio aos dados de treino.
- Isso é feito *minimizando* uma **funcão de erro** que mede a discordância entre a função $y(x, \mathbf{w})$ para qualquer valor de $\mathbf{w}$ e os dados do conjunto de treino.
- Uma escolha simples e amplamente utilizada é a **soma quadrática dos erros** entre as predições e os dados.

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^{N} \{y(x_n, \mathbf{w}) - t_n\}^2$$

Ajuste de curva polinomial

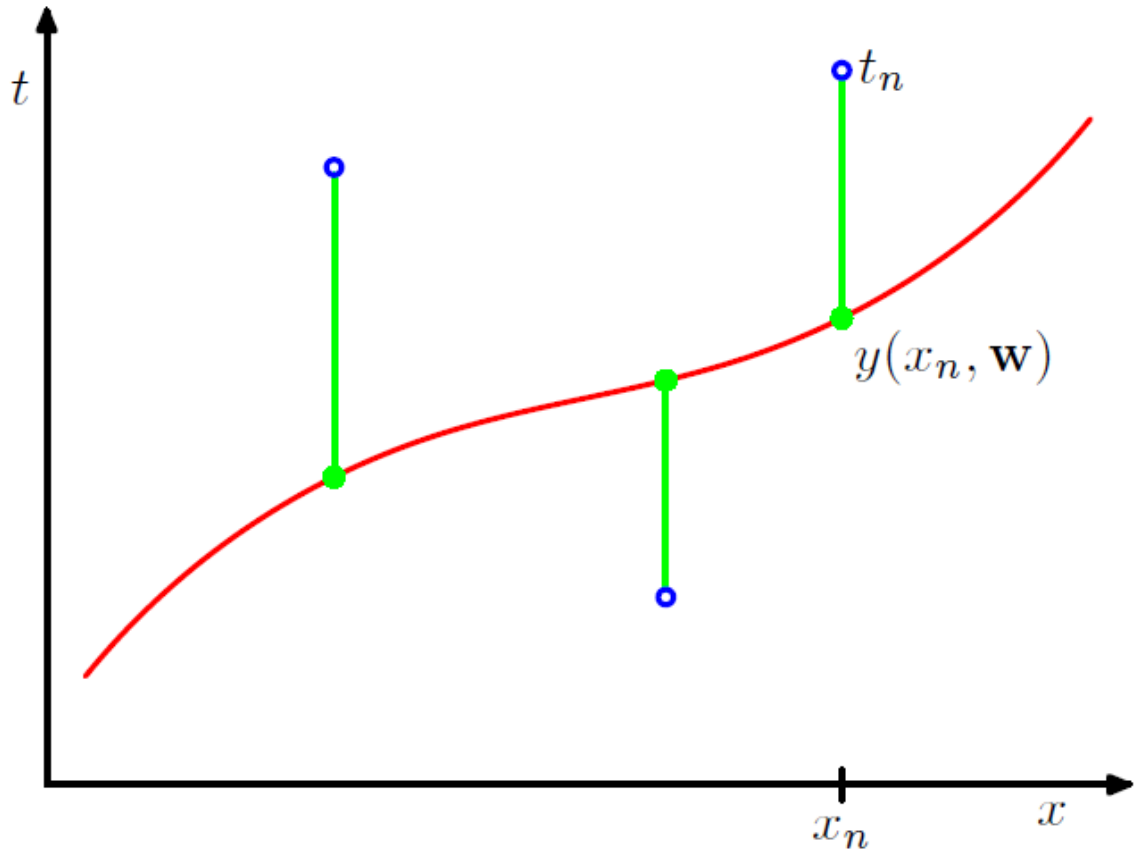


Figura 14: A função erro corresponde a (metade da) soma dos quadrados dos deslocamentos (mostrados pelas barras verticais verdes) de cada ponto de dado em relação à função $y(x, \mathbf{w})$. Fonte: [1]

Ajuste de curva polinomial

- Solucionamos o problema ao escolher o valor de $\mathbf{w}$ onde $E(\mathbf{w})$ é o menor possível.
- No caso do exemplo por ser uma função quadrática dos coeficientes de $\mathbf{w}$, há somente uma solução, via fórmula fechada, resultando no polinômio $y(x, \mathbf{w}^*)$
- Só há mais um problema: escolher a ordem M do polinômio. Isso é o conceito de *seleção de modelo* ou *comparação de modelo*.

Ajuste de curva polinomial

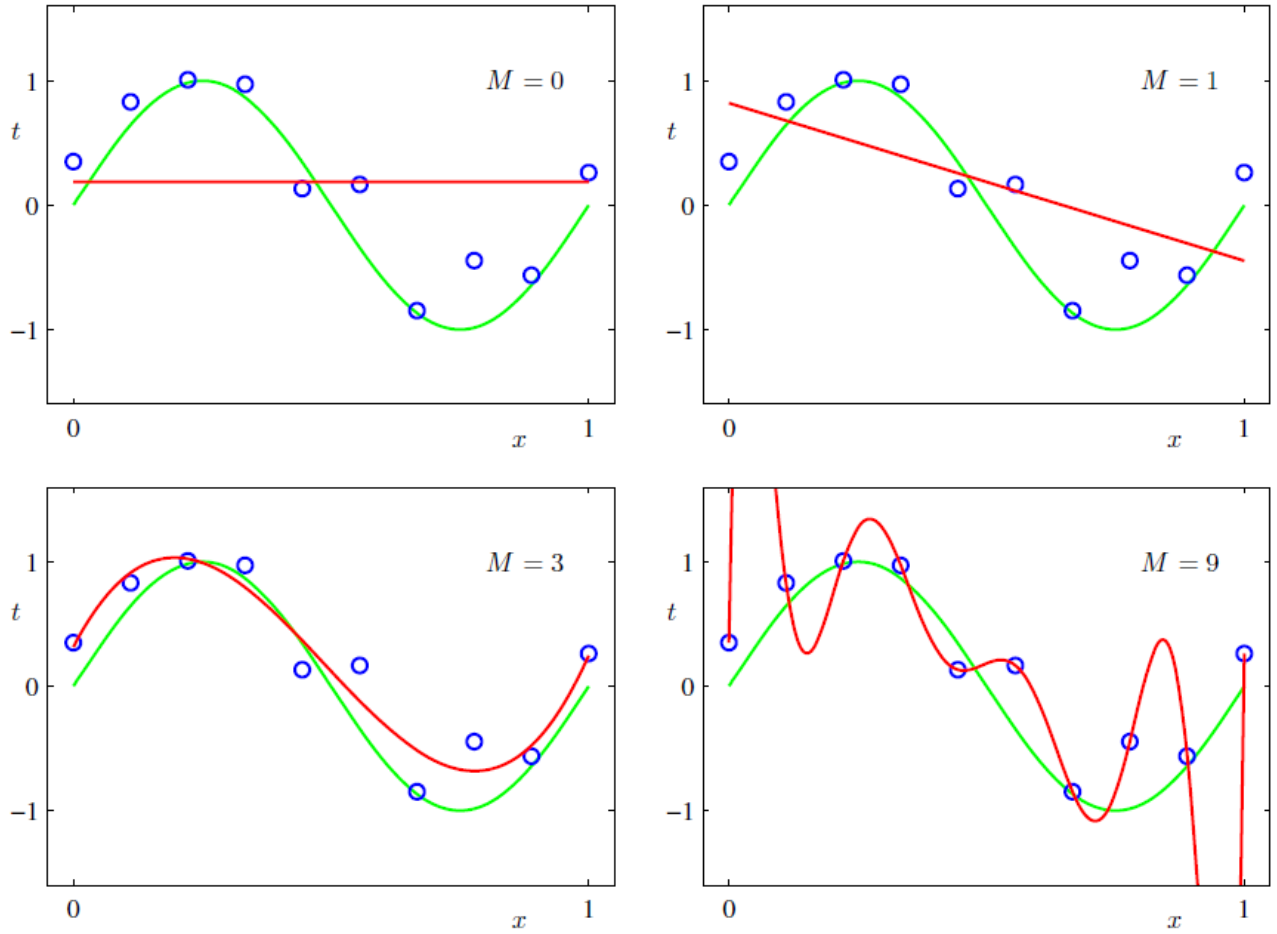
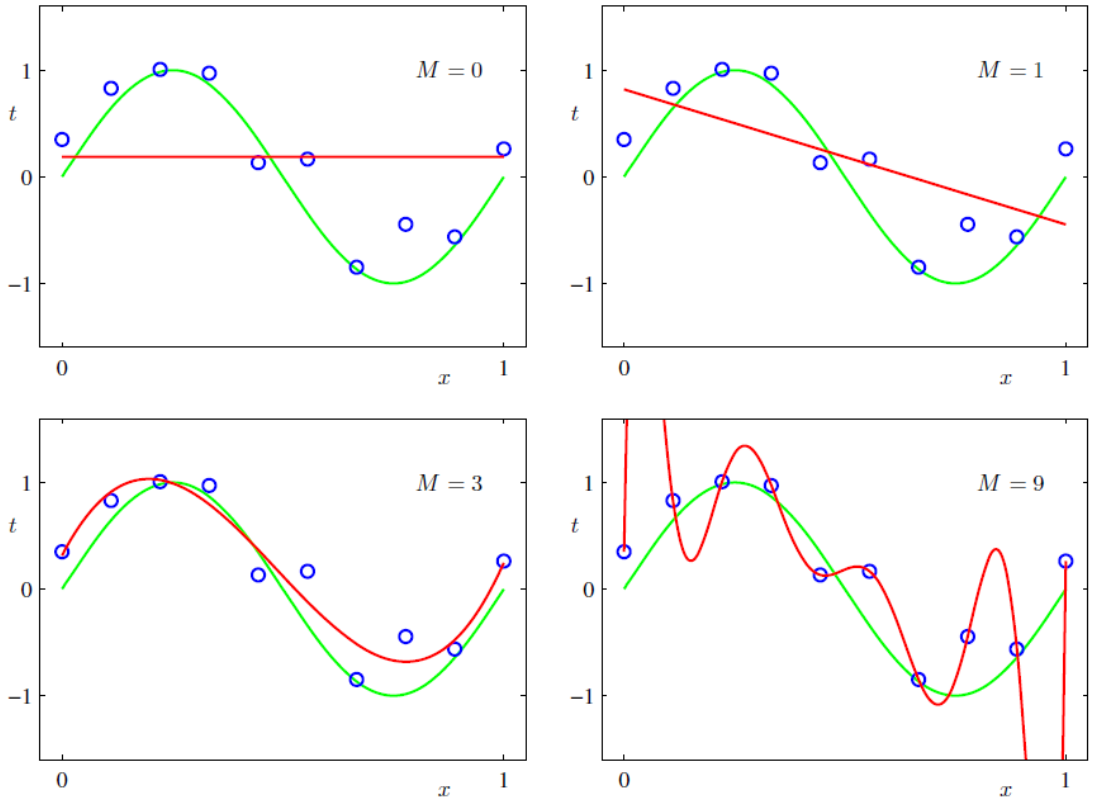


Figura 15: Plots de polinômios com diferentes ordens M, exibidas como curvas vermelhas, ajustadas a partir dos dados de treino do nosso exemplo. Fonte: [1]

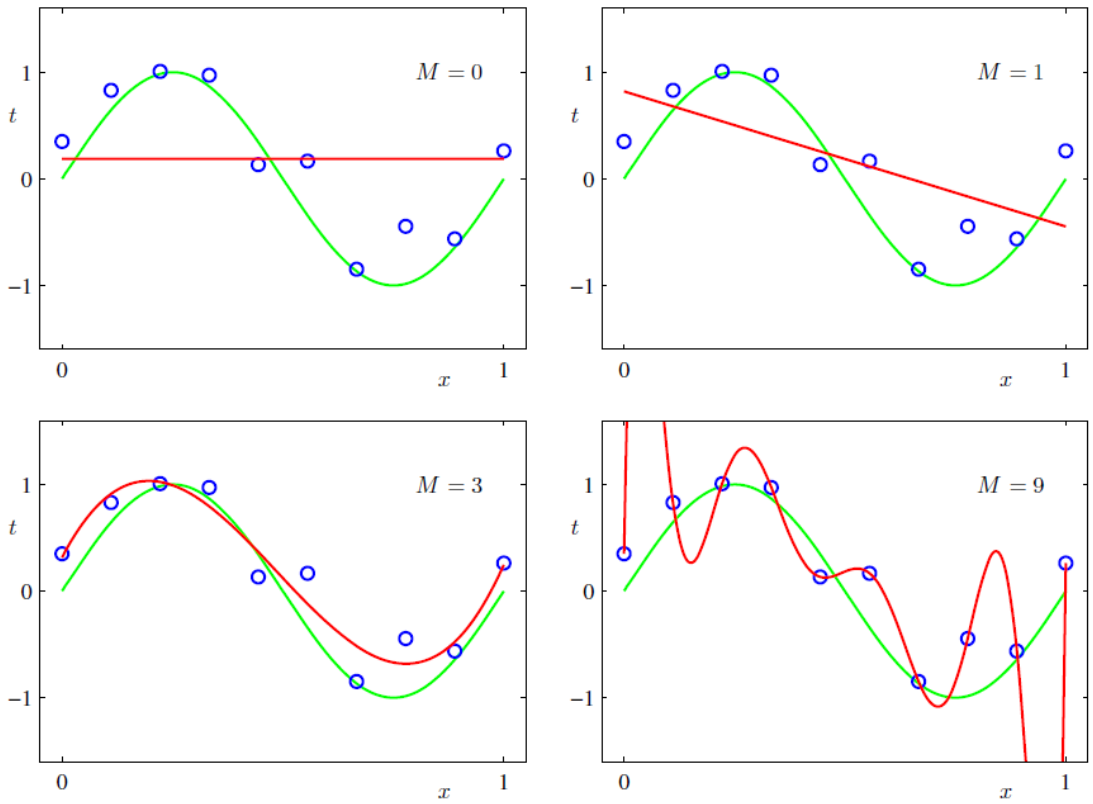
Ajuste de curva polinomial



Pergunta

Qual dos modelos possui menor valor de $E(\mathbf{w}^*)$?

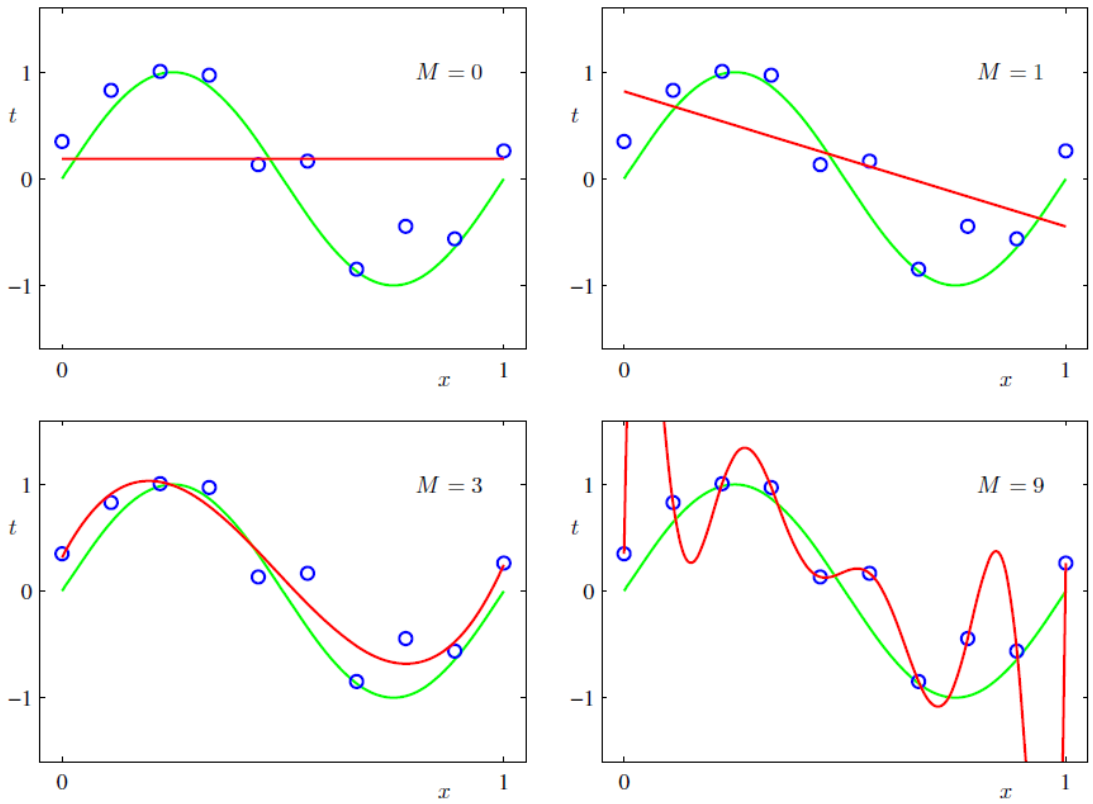
Ajuste de curva polinomial



? Pergunta

Qual dos modelos mais se aproximou da função verdadeira?

Ajuste de curva polinomial



Pergunta

Por que com $M = 0$ e $M = 1$ temos retas e não curvas?

Ajuste de curva polinomial

Lembrando que nosso objetivo é ser capaz de estimar valores $\hat{t}$ aproximados para dados novos, ou seja, não pertencentes aos dados de treino. Ter uma boa *generalização*.

- Consideramos então um conjunto separado de 100 pontos, diferentes dos dados de treino, mas gerados pelo mesmo processo.
- Computamos então os valores *residuais* de $E(\mathbf{w}^*)$ para os dados de *treino* e de *teste*.
- É comum também utilizarmos a raiz do erro quadrático médio (*root-mean-square (RMS) error*) definido por

$$E_{RMS} = \sqrt{2E(\mathbf{w}^*)/N}$$

Ajuste de curva polinomial

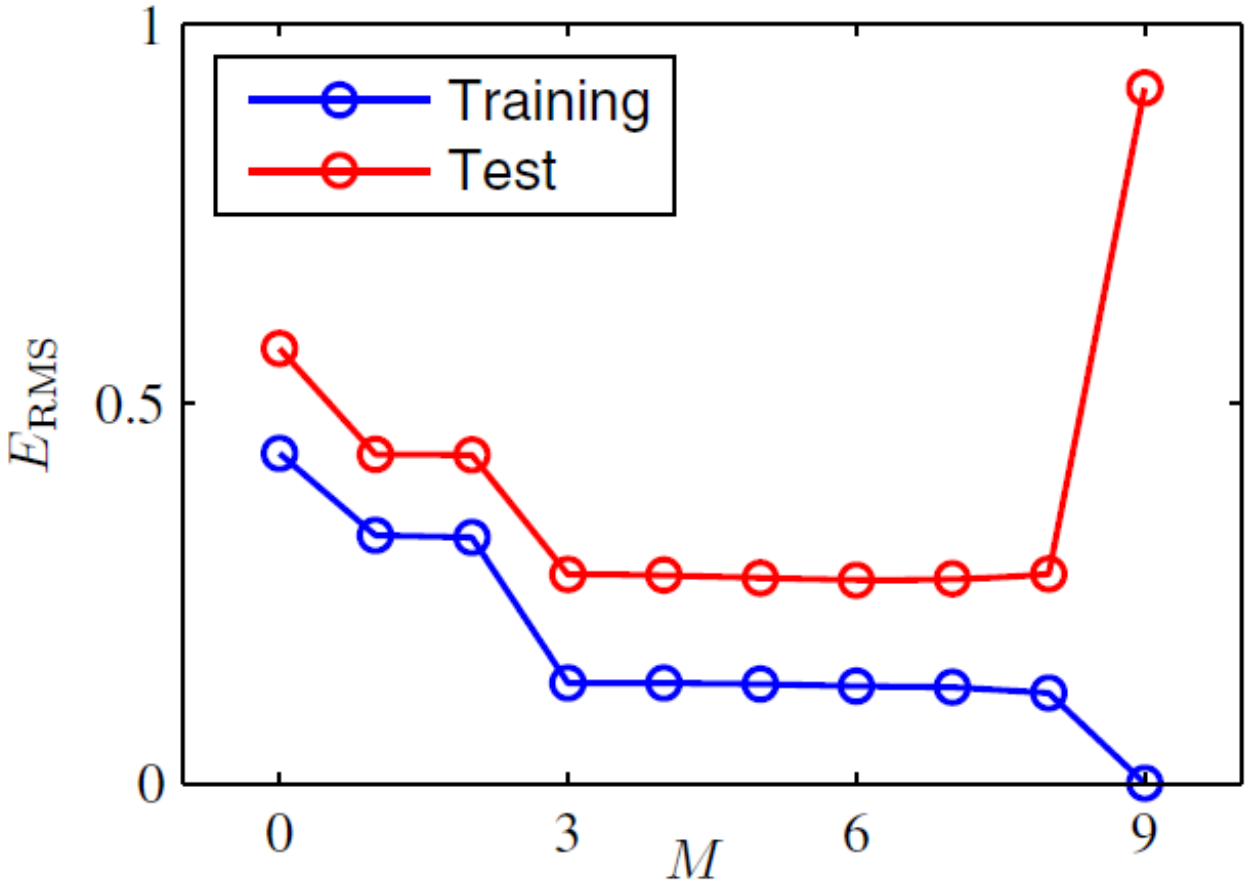


Figura 16: Gráficos da raiz do erro quadrático médio dos conjunto de treino e de teste para diferentes valores de M. Fonte: [1]

Ajuste de curva polinomial

	$M=0$	$M=1$	$M=6$	$M=9$
$w_0^\star$	0.19	0.82	0.31	0.35
$w_1^\star$		-1.27	7.99	232.37
$w_2^\star$			-25.43	-5321.83
$w_3^\star$			17.37	48568.31
$w_4^\star$				-231639.30
$w_5^\star$				640042.26
$w_6^\star$				-1061800.52
$w_7^\star$				1042400.18
$w_8^\star$				-557682.99
$w_9^\star$				125201.43

Figura 17: Tabelas de dos coeficientes $\mathbf{w}^*$ para polinômios de vários graus. Observe como a magnitude dos coeficientes aumentam drasticamente quando a ordem do polinômio também aumenta.

Ajuste de curva polinomial

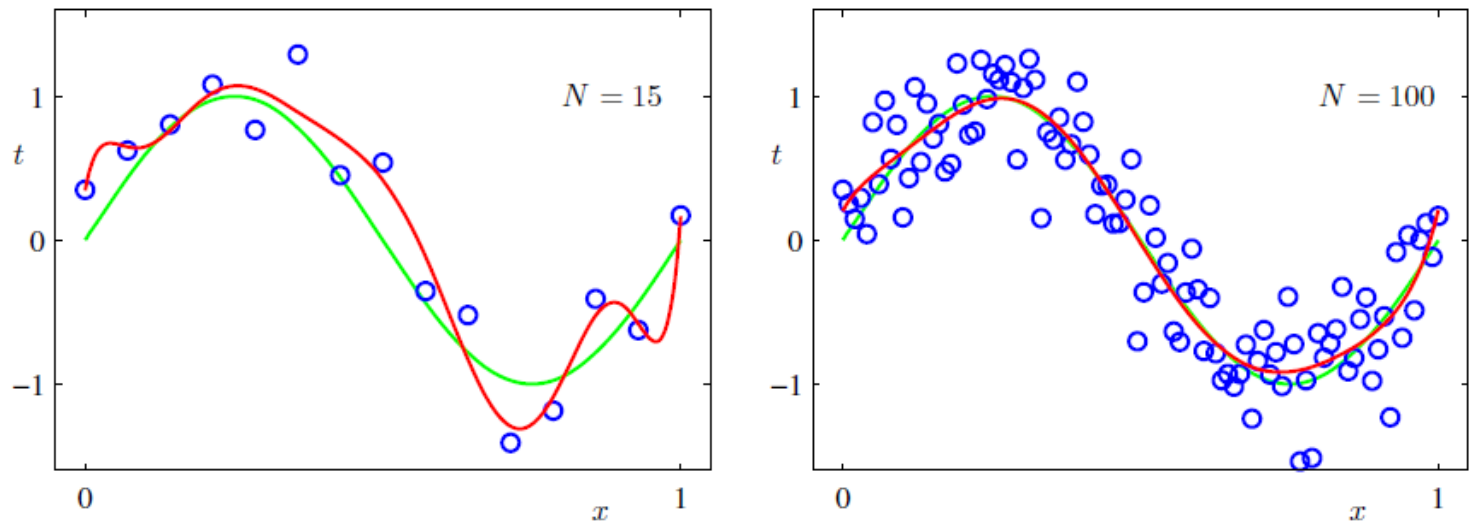


Figura 18: Plots de soluções obtidas ao minimizar a soma quadrática dos erros usando um polinômio de grau $M = 9$ com $N = 15$ e com $N = 100$

Ajuste de curva polinomial

Como apanhado até então, temos:

- Mais parâmetros (w) torna o modelo mais flexível (e mais complexo)...

Ajuste de curva polinomial

Como apanhado até então, temos:

- Mais parâmetros (w) torna o modelo mais flexível (e mais complexo)...
- ... que pode causar um *sobreajuste* nos dados de treino, gerando uma generalização ruim...

Ajuste de curva polinomial

Como apanhado até então, temos:

- Mais parâmetros (w) torna o modelo mais flexível (e mais complexo)...
- ... que pode causar um *sobreajuste* nos dados de treino, gerando uma generalização ruim...
- ... problema esse que pode ser mitigado aumentando a quantidade de dados de treino.

Ajuste de curva polinomial

Outra forma de lidar com a complexidade do modelo é usando *regularização*, que basicamente envolve adicionar um termo de penalidade à função custo para desencorajar coeficientes muito grandes

$$\tilde{E}(\mathbf{w}) = \frac{1}{2}\sum_{n=1}^{N}(y(x_n, \mathbf{w}) - t_n)^2 + \frac{\lambda}{2}\|\mathbf{w}\|^2$$

onde $||\mathbf{w}||^2 = \mathbf{w}^{\mathrm{T}}\mathbf{w} = w_0^2 + w_1^2 + \cdots + w_M^2$ e λ controla a importância relativa da normalização comparado ao erro quadrático.

Regularização quadrática

Essa expressão regularizadora quadrática é chamada de *Rigdge regression*.

Regularização

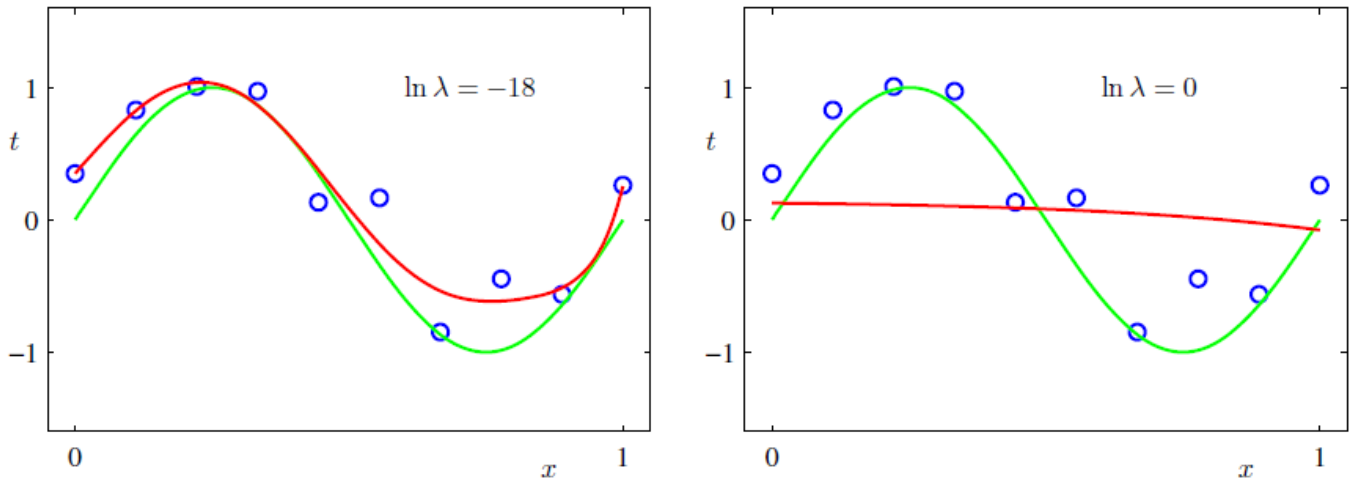


Figura 19: Plots com polinomios de $M = 9$, ajustados com os dados de treino, com a função de regularização para dois valores do parâmetro λ. Os valores comumente são dados por ln porque operamos com números muito pequenos de λ.

Regularização

	$\ln \lambda = -\infty$	$\ln \lambda = -18$	$\ln \lambda = 0$
$w_0^\star$	0.35	0.35	0.13
$w_1^\star$	232.37	4.74	-0.05
$w_2^\star$	-5321.83	-0.77	-0.06
$w_3^\star$	48568.31	-31.97	-0.05
$w_4^\star$	-231639.30	-3.89	-0.03
$w_5^\star$	640042.26	55.28	-0.02
$w_6^\star$	-1061800.52	41.32	-0.01
$w_7^\star$	1042400.18	-45.95	-0.00
$w_8^\star$	-557682.99	-91.53	0.00
$w_9^\star$	125201.43	72.68	0.01

Figura 20: Tabelas de coeficientes w* para polinômio $M = 9$, com diferentes valores de regularização. Para altos valores de regularização, observe que os valores dos coeficientes tem menor magnitude.

Resumo

- Aprendizado de máquina e Reconhecimento de padrões
- Modelos e parâmetros de um modelo
- Aprendizagem, conjunto de treino e teste, atributos
- Tipos de aprendizado: supervisionado, não-supervisionado e por reforço.
- Ruído
- Função de erro
- Seleção de modelos
- Regularização

Leituras

- Bishop - Capítulo 1 (somente o 1.1) [1]
- Duda, Hard, Stork - Capítulo 1 [3]
- James et. al. - Capítulo 1 [4]

Referências I


Christopher M Bishop.
Pattern Recognition and Machine Learning, volume 4 of Information science and statistics.
Springer, 2006.


Soha Boroojerdi and George Rudolph.
Handwritten multi-digit recognition with machine learning.
In 2022 Intermountain Engineering, Technology and Computing (IETC). IEEE, 2022.
ISBN: 978-1-6654-8654-5.


Richard O Duda, Peter E Hart, and David G Stork.
Pattern Classification.
John Wiley & Sons, New York, 2nd edition, 2000.

Referências II



Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani, and Jonathan Taylor.
An Introduction to Statistical Learning with Applications in Python.
Springer Texts in Statistics. Springer, Cham, 1st edition, 2023.



Kevin P. Murphy.
Machine learning : a probabilistic perspective.
MIT Press, Cambridge, Mass. [u.a.], 2013.