Fundamentos do Aprendizado de Máquina

Prof. Renan Gomes Vieira

Uninersidade Federal do Ceará - Campus Quixadá
Aprendizado de Máquina

2026.2

Sumário

1. Notações
2. Motivações e mais exemplos
3. Por que estimar f?
4. Como estimar f?
5. Avaliando acurácia de Modelos

Notações

Notação

- n: representa o número de **pontos de dados** ou **observações** em nossa **amostra** (*conjunto de dados* ou *dataset*).
- p: o número de **variáveis** ou **preditores** que estão disponíveis para fazer predições.
- x_{ij}: representa o valor da j-ésima variável da i-ésima observação, onde $i = 1, 2, \cdots, n$ e $j = 1, 2, \cdots, p$
- $\mathbf{X}$: uma matriz $n \times p$, cujo elemento (i, j) é x_{ij}. Isto é,

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}.$$

Observações como vetores

As linhas de $\mathbf{X}$ representam as observações do conjunto de dados.
Denotamos a i-ésima linha por x_i (minúsculo e em itálico).
Cada x_i contém os valores das p variáveis para a i-ésima observação:

$$x_i = \begin{pmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{pmatrix}.$$

Assim, x_i é um **vetor coluna** de comprimento p.

$\mathbf{X}$ vs. x_i

No contexto de $\mathbf{X}$, cada observação ocupa uma linha. No contexto de um vetor único x_i, são representados comumente via vetor coluna.

Variáveis como vetores

As colunas de $\mathbf{X}$ representam as variáveis do conjunto de dados.
Denotamos a j-ésima coluna por $\mathbf{x}_j$.
Cada $\mathbf{x}_j$ contém os valores da j-ésima variável para as n observações:

$$\mathbf{x}_j = \begin{pmatrix} x_{1j} \\ x_{2j} \\ \vdots \\ x_{nj} \end{pmatrix}.$$

Assim, $\mathbf{x}_j$ é um vetor de comprimento n.

Representações do conjunto de dados

A matriz de dados $\mathbf{X}$ pode ser representada a partir de suas colunas:

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_p \end{pmatrix}.$$

Ou, equivalentemente, a partir de suas linhas:

$$\mathbf{X} = \begin{pmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_n^T \end{pmatrix}.$$

Transposta da matriz de dados

A notação T representa a **transposta** de uma matriz ou vetor.
Para uma matriz de dados $\mathbf{X} \in \mathbb{R}^{n \times p}$,

$$\mathbf{X}^T = \begin{pmatrix} x_{11} & x_{21} & \cdots & x_{n1} \\ x_{12} & x_{22} & \cdots & x_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ x_{1p} & x_{2p} & \cdots & x_{np} \end{pmatrix}.$$

Portanto,

$$\mathbf{X} \in \mathbb{R}^{n \times p} \qquad \Longrightarrow \qquad \mathbf{X}^T \in \mathbb{R}^{p \times n}.$$

Preditores como variáveis aleatórias

Em um nível conceitual, os preditores podem ser vistos como **variáveis aleatórias**:

$$X_1, X_2, \ldots, X_p.$$

Nesse caso, cada X_j representa a j-ésima característica medida na população, como por exemplo idade, renda ou escolaridade.
Podemos reunir esses preditores no vetor aleatório

$$\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{pmatrix}.$$

Motivações e mais exemplos

Exemplo: *Advertising*

- Considere um conjunto de dados `Advertising`, composto por vendas de um produto em 200 mercados diferentes.
- Temos também o orçamento dedicado para o produto em três tipos de canais de mídia: `TV`, `radio`, `jornal`.

? Pergunta

Como podemos sugerir qual é o melhor meio de investimento (`TV`, `radio`, ou `jornal`) para aumentar a quantidade de vendas de produto?

Dados de Advertising

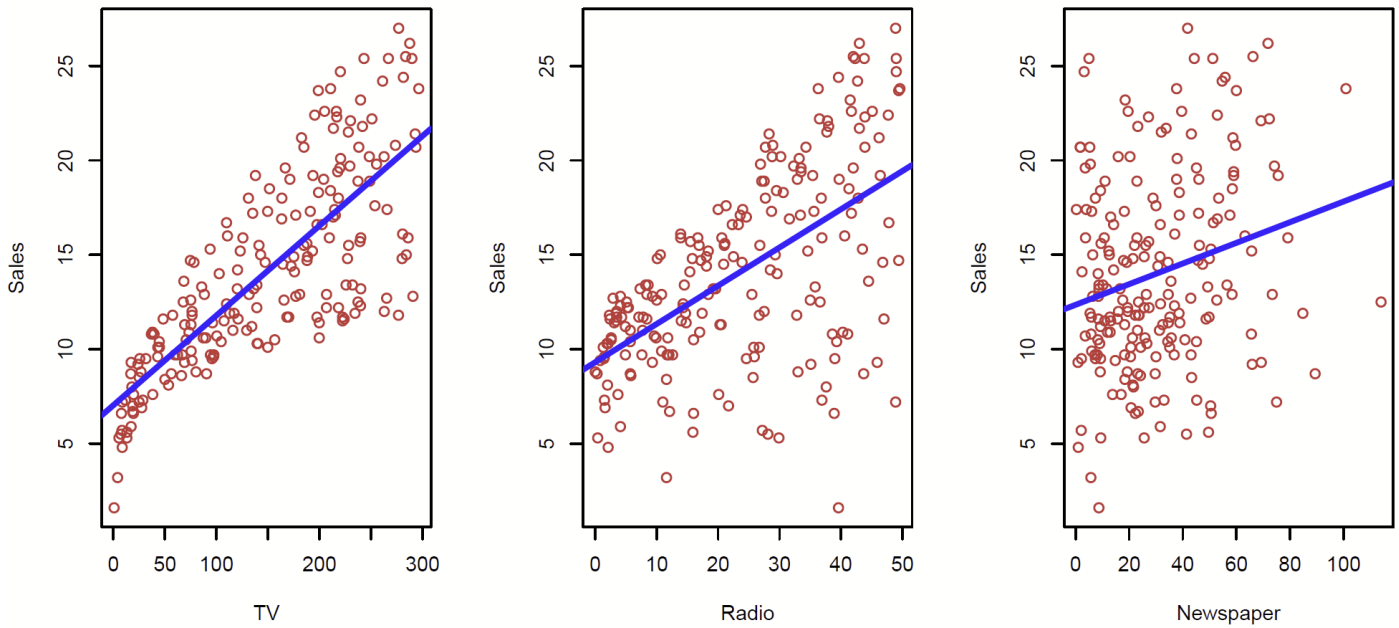


Figura 1: O plot exibe as vendas, em milhares de unidades, como função do orçamento direcionado às três mídias, em milhares de dólares, para 200 mercados diferentes. Fonte: [1]

Definições e Notações

- Nesse contexto, os orçamentos de propaganda são as **variáveis de entrada** enquanto as vendas são a **variável de saída.**
- **Variáveis de entrada** comumente são representados pelo símbolo X, usando o subscrito para distingui-los. Também conhecidas como: *preditores*, *variáveis independentes*, *atributos* ou apenas *variáveis*.
  - X_1: Orçamento da TV
  - X_2: Orçamento do rádio
  - X_3: Orçamento do jornal
- **Variáveis de saída**, também chamadas de *resposta* ou *variável dependente*, é tipicamente denotada por Y.

Definições e Notações

De forma geral, suponha que observamos uma resposta quantitativa Y e p atributos, $X_1, X_2, ..., Xp$. Assumimos que existe alguma relação entre Y e $X = (X_1, X_2, ...X_p)$ dada por

$$Y = f(X) + \epsilon.$$

f é uma função fixa, mas desconhecida de X e ϵ é um *termo de erro*, independente de X.

Aprendizado de Máquina / Estatístico

De forma geral, aprendizado de máquina/estatístico se referete às abordagens para estimar f.

Outro exemplo: Renda

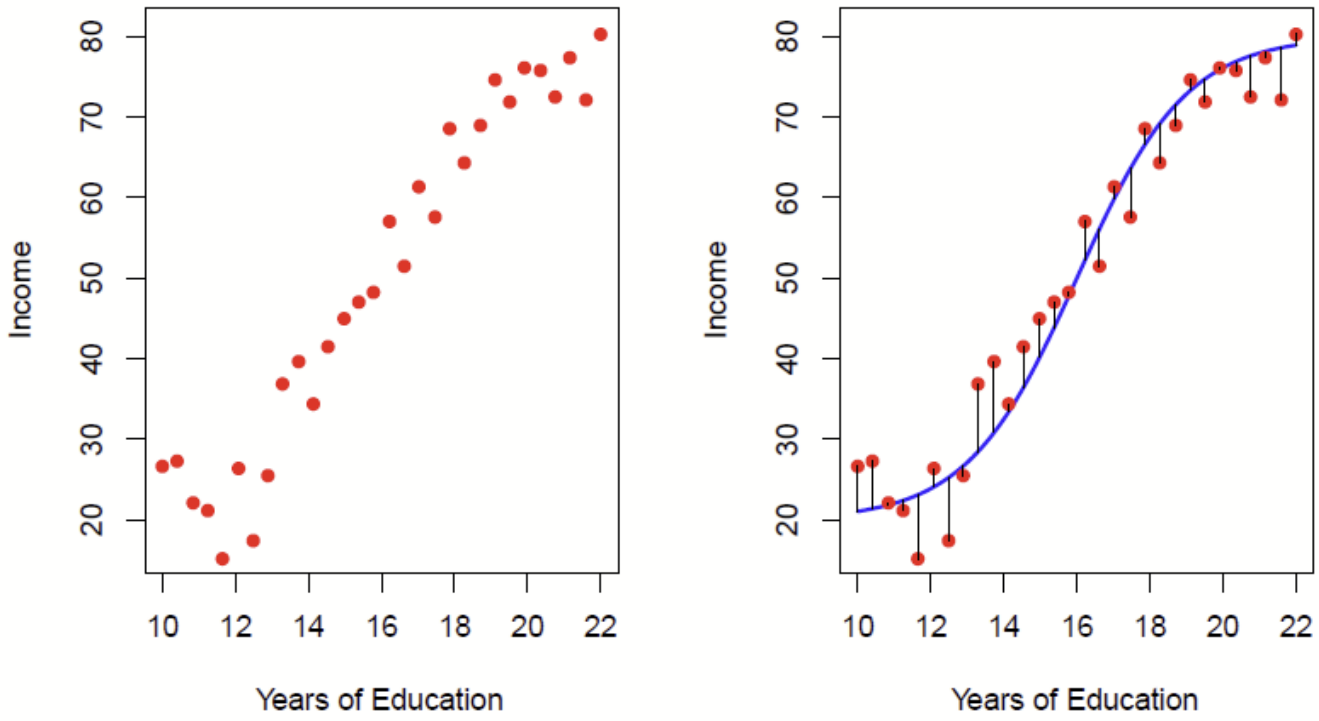


Figura 2: Dataset `Income`. Pontos vermelhos são os valores observados de renda e anos de educação. A linha em azul representa a real relação entre renda (em milhares de dólares) e anos de educação (nesse caso simulado). As linhas pretas representam o erro associado a cada observação. Fonte: [1]

Outro exemplo: Renda Multivariada

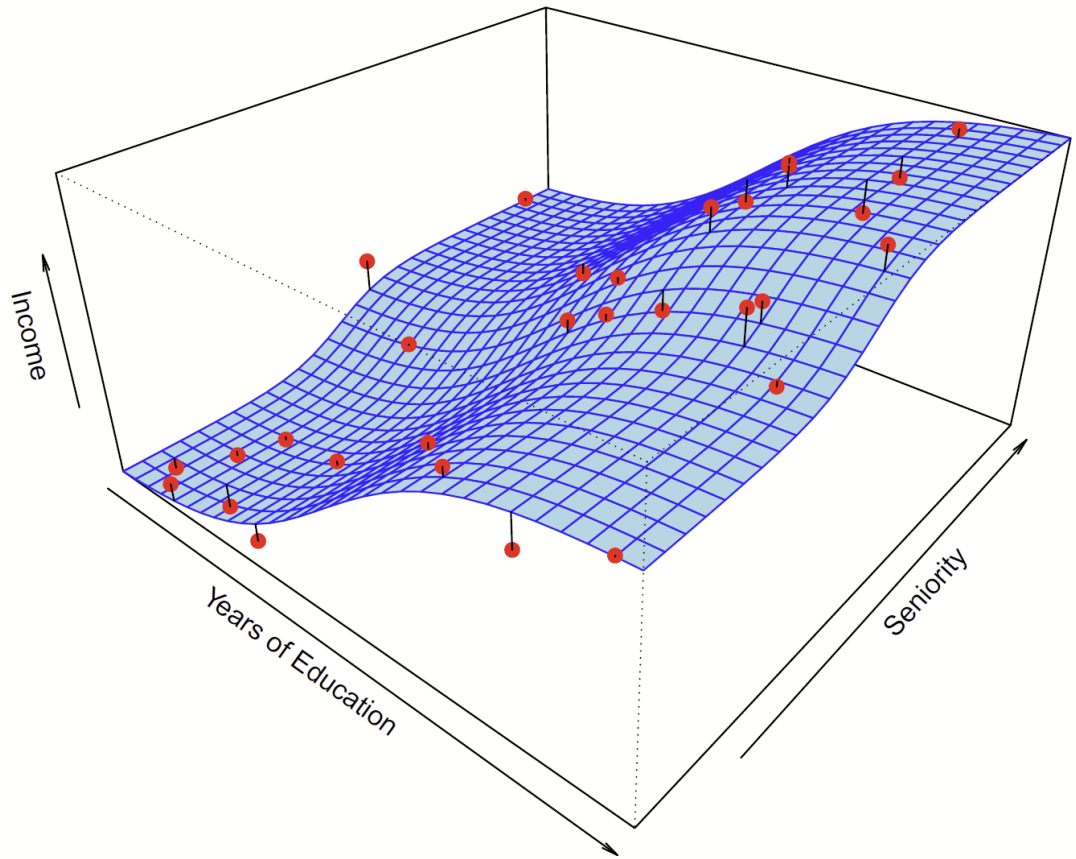


Figura 3: O gráfico mostra a renda em função dos anos de escolaridade e do tempo de serviço. A superfície azul representa a verdadeira relação subjacente entre a renda, os anos de escolaridade e o tempo de serviço.

Por que estimar f?

Por que estimar f? - Predição

Em muitos cenários, possuímos um conjunto de entradas X mas a saída Y não pode ser obtida facilmente. Nesse cenário

$$\hat{Y} = \hat{f}(X),$$

onde $\hat{f}$ representa nossa *estimativa* de f e $\hat{Y}$ representa a predição de Y.

Modelos Caixa-preta

Nesses cenários, $\hat{f}$ é comumente tratada como uma *black box* (caixa-preta), no sentido de que sua forma é irrelevante pro problema, contanto que $\hat{Y} \approx Y$

Por que estimar f? - Predição

A acurácia de $\hat{Y}$ como predição de Y depende de duas grandezas: *erro redutível* e *erro irredutível*.

Erro redutível

Vem do fato de $\hat{f}$ não ser a estimativa perfeita de f, logo há um erro associado a essa escolha. Contudo, podemos *reduzir* esse erro ao buscar outra técnica mais adequada aos dados.

Erro irredutível

O fato de Y ser em função de ϵ, mesmo com $f = \hat{f}$ ainda há um erro que não temos controle sobre. Esse é um erro *irredutível* pois não temos condições de modelar ϵ.

Valores esperados dos erros

Consideremos uma estimativa $\hat{f}$ e um conjunto de atributos X, tal que $\hat{Y} = \hat{f}(X)$. Vamos assumir que $\hat{f}$ e X são fixos, de forma que a variabilidade vem de ϵ, temos

$$\mathbb{E}(Y - \hat{Y})^2 = \mathbb{E}\left[f(X) + \epsilon - \hat{f}(X)\right]^2 = \left[f(X) - \hat{f}(X)\right]^2 + \text{Var}(\epsilon),$$

onde $\mathbb{E}(Y - \hat{Y})^2$ representa o *valor esperado* do quadrado da diferença entre $\hat{Y}$ e Y, e $\text{Var}(\epsilon)$ a variância do termo associado com o termo ϵ.

Por que estimar f? - Inferência

- Quando estamos interessados em entender a associação entre a Y e X. Nesses cenários, queremos estimar f mas o objetivo não é fazer predições para Y. **Não podemos tratar $\hat{f}$ como uma caixa-preta.**
- Geralmente queremos responder as seguintes questões:
  1. Quais atributos estão associados com a resposta?
  2. Qual é relação entre a resposta e cada preditor?
  3. Podemos sumarizar adequadamente a relação de Y e cada preditor usando uma equação linear ou a relação é mais complicada?

Inferência ou Predição?

Uma empresa possui dados demográficos de clientes (idade, renda, região etc.) e quer prever quem responderá positivamente a uma campanha de marketing. O objetivo é construir um modelo que classifique novos clientes como "provável responder" ou "não responder".

Inferência ou Predição?

Uma empresa analisa dados de investimento em TV, rádio e jornal e vendas. O objetivo é responder perguntas como: qual mídia está mais associada às vendas? e qual aumento em vendas está relacionado a um aumento no investimento em TV?

Inferência ou Predição?

- Há cenários onde queremos **as duas coisas**.
- Diferentes métodos são mais recomendados para cada um dos cenários apresentados.
- Comumente, modelos lineares são simples e fácil interpretação para inferência, mas limitados para predição.
- Já modelos mais complexos, apresentam o comportamento inverso: melhores para predição e mais desafiadores para serem interpretados.

Como estimar f?

Como estimar f?

- Durante o curso, vamos explorar diferentes abordagens lineares e não-lineares, cada um com suas **características**.
- **MAS ANTES**.. relembrando:
  - Observamos uma quantidade n (ou N) de dados. Usamos para ajustar nosso modelo. São os **dados de treino**.
  - Seja x_{ij} o valor do j-ésimo atributo da observação i, $= 1, 2, ..., n$ e $j = 1, 2, ..., p$. Temos nosso conjunto de treino composto por

$$\{(x_1, y_1), (x_2, y_2), ...(x_n, y_n)\},$$

onde

$$x_i = (x_{i1}, x_{i2}, \cdots, x_{ip})^T.$$

  - Queremos encontrar $\hat{f}$ de forma que $Y \approx \hat{f}(X)$.

Métodos de aprendizado de máquina

De forma geral, a maioria dos modelos de AM podem ser caracterizados como **paramétricos** e **não-paramétricos**.

Métodos paramétricos

Métodos paramétricos envolvem um modelo de abordagem de **dois passos**:

1. Assumimos uma forma funcional de f. Por exemplo, uma suposição simples é que f é linear em X:

$$f(X) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots \beta_p X_p.$$

   Ao assumir que a função é linear, o problema é simplificado: basta estimar $p + 1$ coeficientes (ou parâmetros) $B_0, B_1, \cdots, B_p$.

2. Após um modelo ser escolhido, precisamos de um procedimento que usa os **dados de treino** para *ajustar* ou *treinar* o modelo, que se traduz em encontrarmos parâmetros $B_0, B_1, \cdots, B_p$ de forma que

$$Y \approx \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots \beta_p X_p.$$

   No caso do modelo proposto aqui, a abordagem mais comum é a dos **mínimos quadrados (ordinários)**, contudo há outras.

Modelos Paramétricos

Reduz o problema de encontrar uma função f a encontrar um conjunto de parâmetros.

- A principal desvantagem é assumir um modelo que não corresponde aos dados.
- A alternativa é escolher modelos mais *flexíveis*, mas que estão mais suscetíveis a *sobreajuste* (*overfitting*).

Exemplo: Método Paramétrico

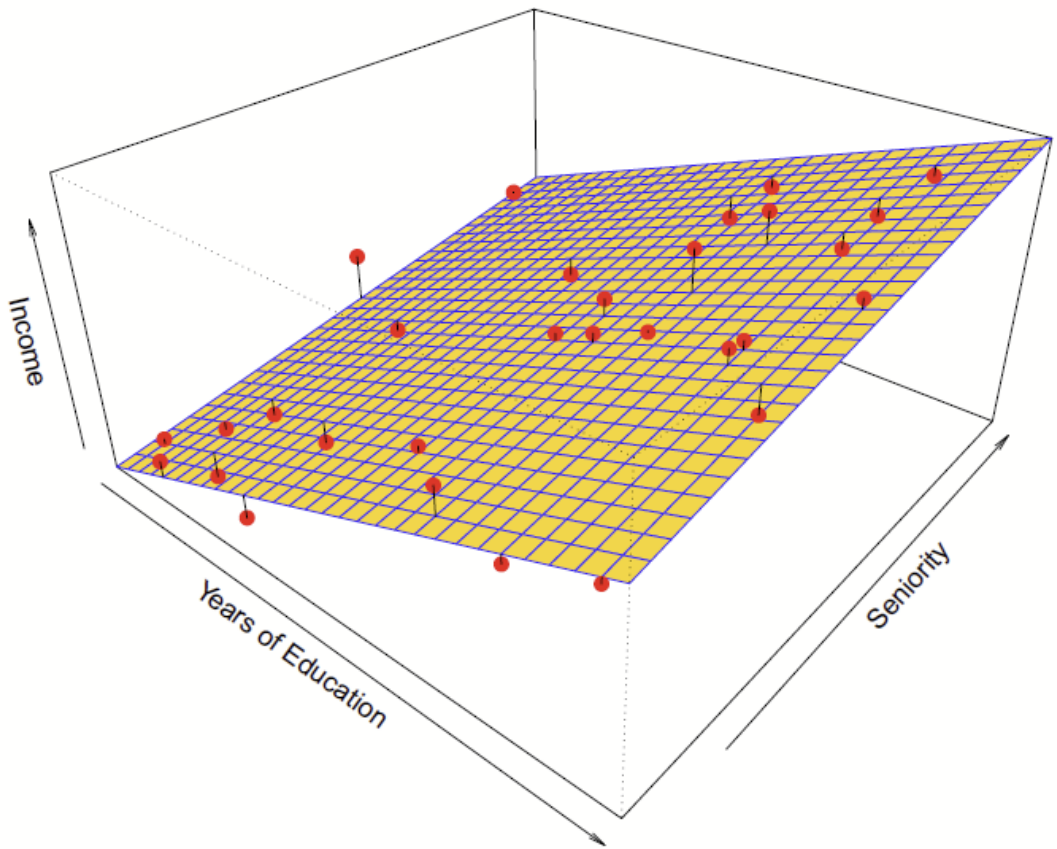


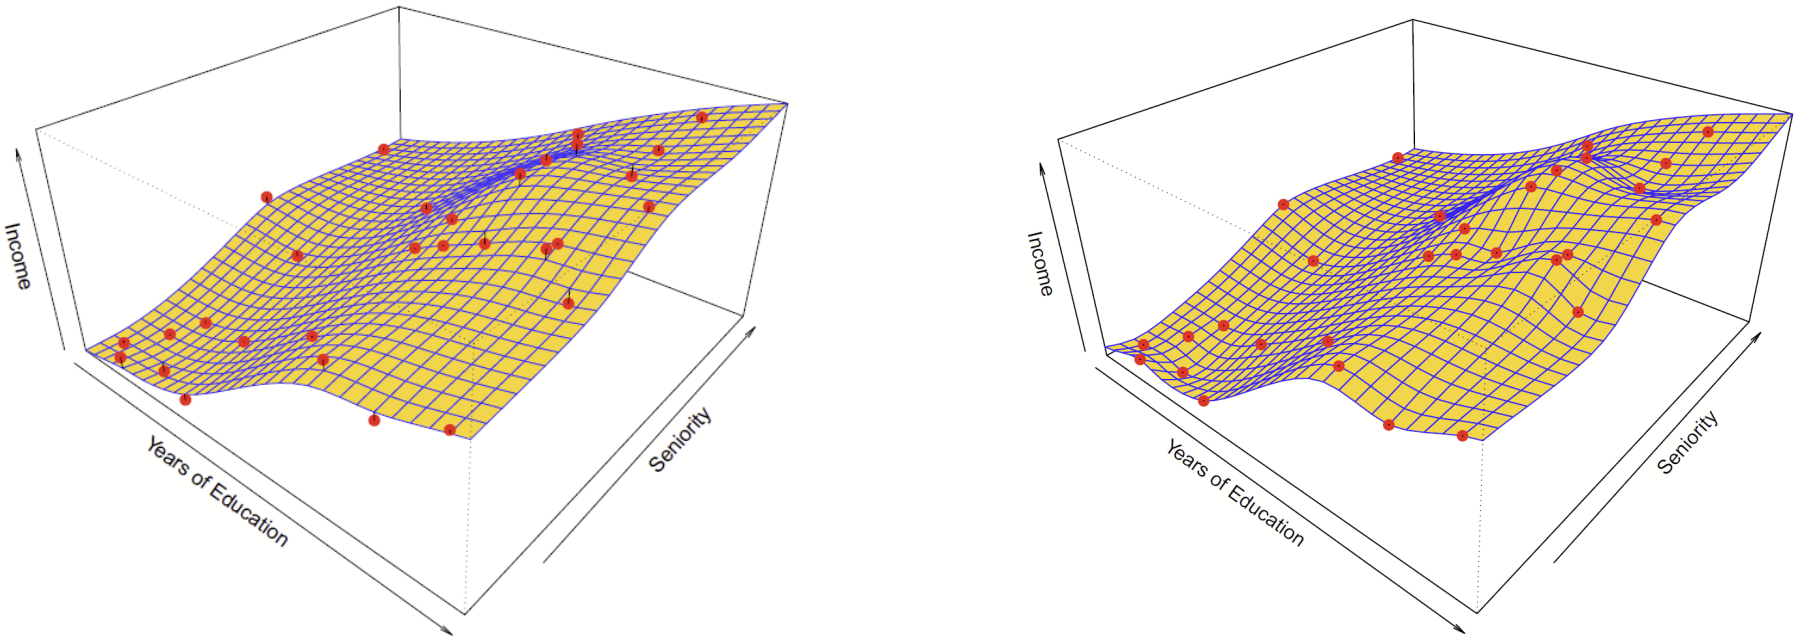
Figura 4: Modelo linear ajustado usando mínimos quadrados com n=30 de dados de renda. O plano amarelo indica o ajuste do modelo sobre os dados. Representa a ideia de income $\approx \beta_0 + \beta_1 \times education + \beta_2 \times seniority$. Fonte: [1]

Métodos Não-paramétricos

Métodos não paramétricos não fazem suposições explícitas sobre a forma funcional de f. Em vez disso, eles procuram uma estimativa de f que fique o mais próxima possível dos pontos de dados, sem ser excessivamente irregular ou ondulada.

- Ao fazer isso, permite funções bem mais flexíveis e mais propensas a uma maior gama de formatos para f.
- Contudo, exigem **bem mais dados** em comparação a métodos paramétricos para obter uma estimativa razoável de f.

Exemplo: método não paramétrico



(a) Ajuste suave.

(b) Ajuste rígido.

Figura 5: Ajustes distintos de *thin-plate splines*, método não-paramétrico. Fonte: [1]

Tradeoff Acurácia de Predição e Interpretabilidade



Figura 6: Representação do tradeoff (*compromisso* entre flexibilidade e interpretabilidade. Existe uma correlação negativa entre ambos. Fonte: [1]

Avaliando acurácia de Modelos

Avaliando a acurácia dos Modelos

Pergunta

Por que é existem tantos métodos de aprendizado diferentes? Não existe apenas um ***melhor*** *método?*

Avaliando a acurácia dos Modelos

Pergunta

Por que é existem tantos métodos de aprendizado diferentes? Não existe apenas um ***melhor*** *método?*

- Diferentes conjuntos de dados são melhores aprendidos com métodos específicos.

Avaliando a acurácia dos Modelos

Pergunta

Por que é existem tantos métodos de aprendizado diferentes? Não existe apenas um ***melhor*** *método?*

- Diferentes conjuntos de dados são melhores aprendidos com métodos específicos.
- Não sabemos a *priori* qual é melhor para qual problema: precisamos testar várias opções e escolher a **melhor**.

Avaliando a qualidade do ajuste

Precisamos de uma **medida**, comumente chamada de **métrica**, que quantifique a performance de um modelo. Em problemas de regressão, a mais usada é o **erro quadrático médio** (*mean squared error (MSE)* dado por

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{f}(x_i))^2$$

.

Avaliando a qualidade do ajuste

- **Lembrando:** computamos o MSE para os dados de **treino**, mas a real avalição deve ser feita para dados não utilizados no treinamento, que chamamos de dados de **teste**.
- O modelo performar bem em dados **que já aconteceram** não nos interessa.
- Queremos modelos onde o MSE é menor possível para **dados de teste**.

Avaliando qualidade do ajuste

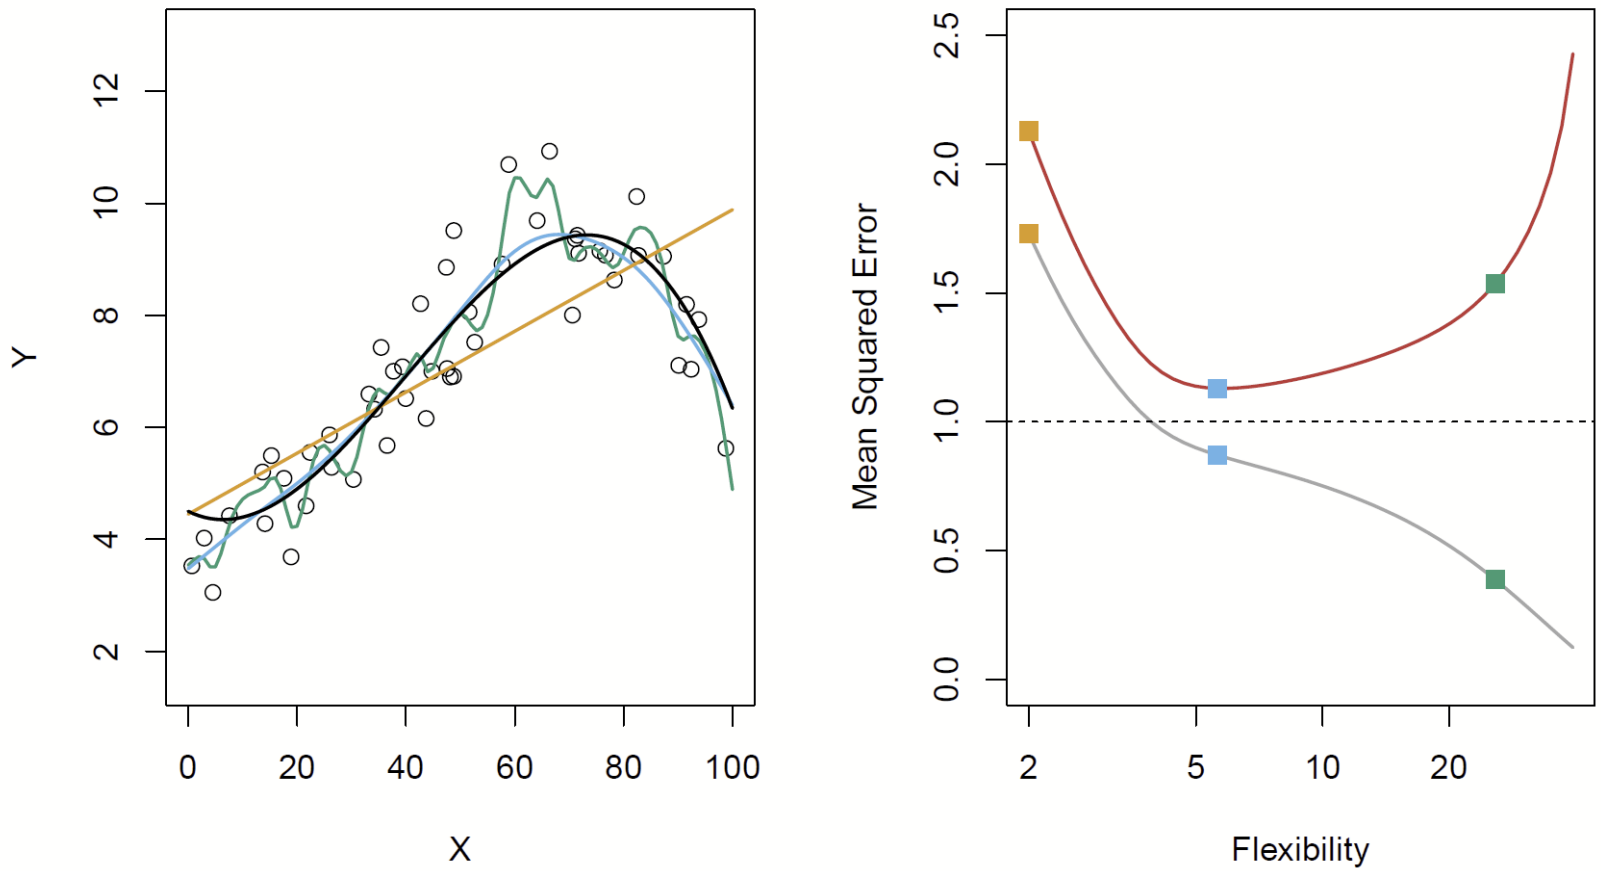


Figura 7: Direito: diferente estimativas para f (curva preta). Esquerdo: MSE de treino (curva cinza) e teste (curva vermelha) para as diferentes estimativas. Fonte: [1]

Avaliando a qualidade do ajuste

- O *formato-U* do MSE em função da flexibilidade do modelo é uma propriedade interessante e acontece para **todos os conjuntos de dados** e **qualquer modelo estatístico**.
- Temos ai exemplos numéricos e visuais de *subajuste* (*underfitting*), *ajuste adequado* e *sobreajuste*.
- Esse formato nem sempre é assim, mas acontece de diferentes maneiras.

Avaliando a qualidade do ajuste

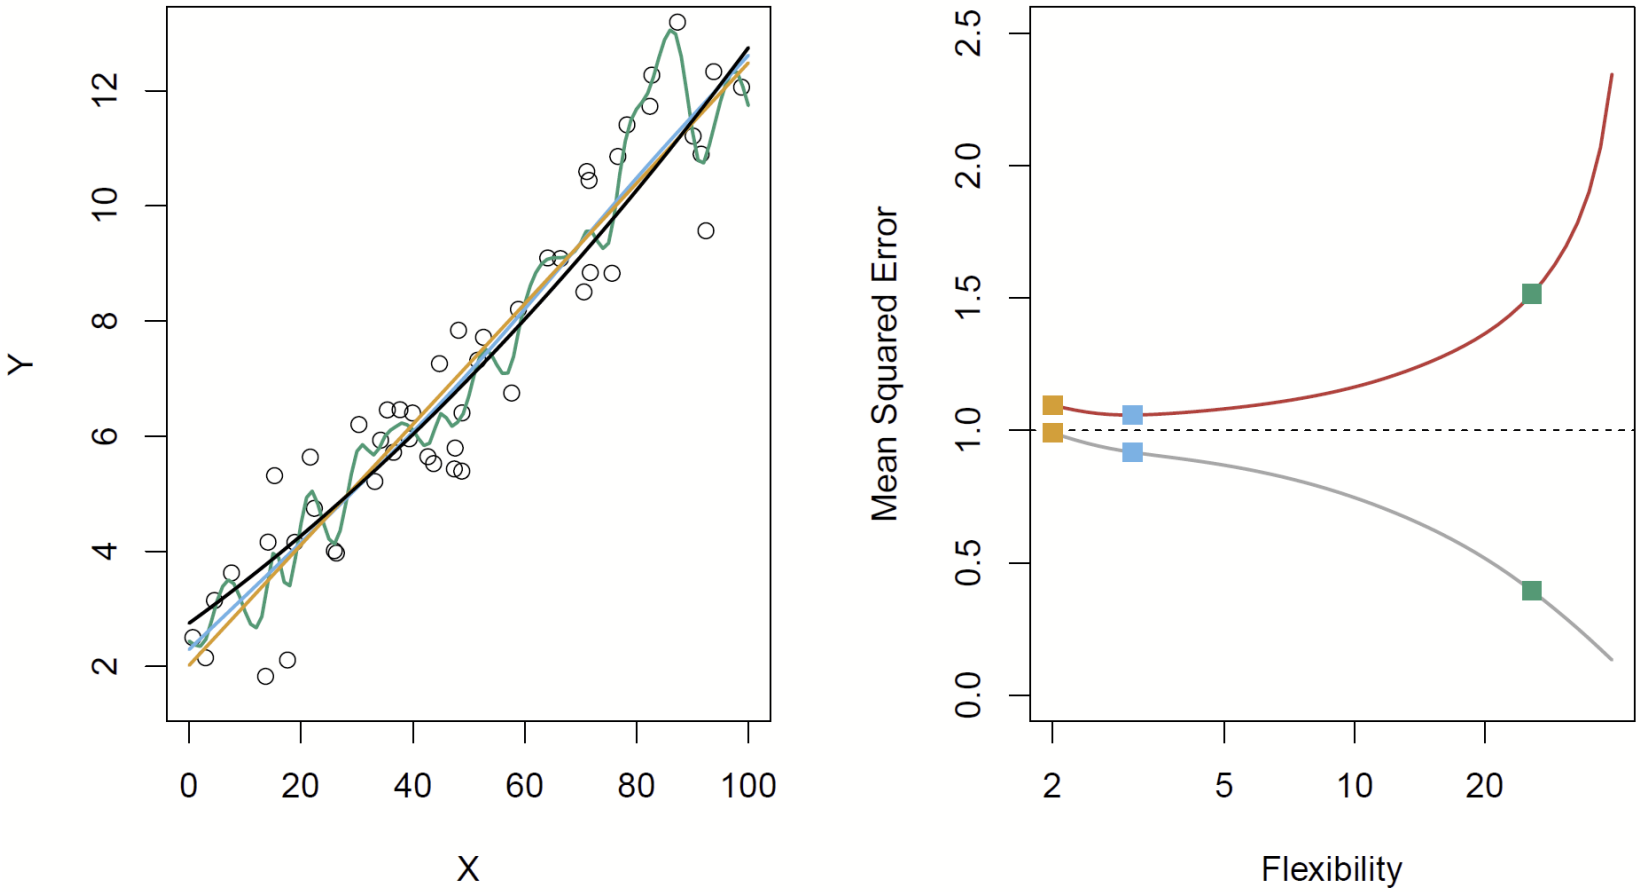


Figura 8: Comparativo de diferentes modelos para um f *quase* linear. Fonte: [1]

Avaliando a qualidade do ajuste

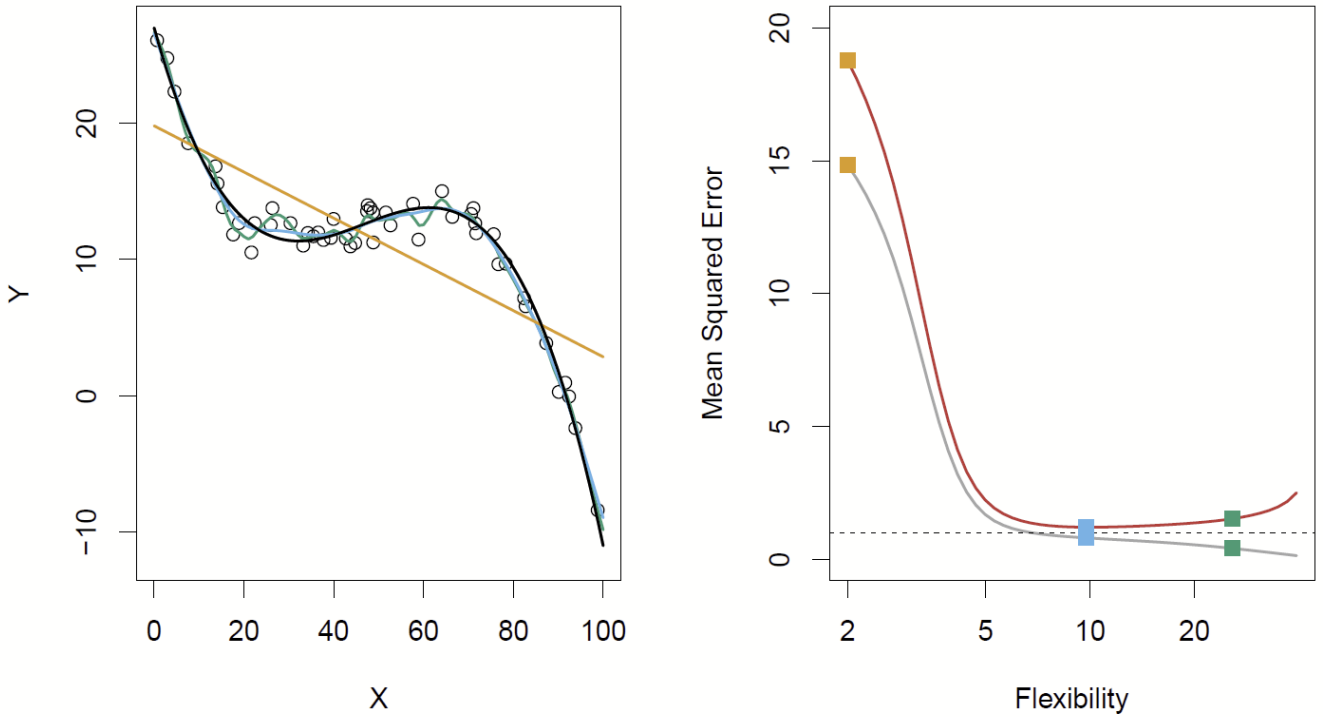


Figura 9: Comparativo de diferentes modelos para um f não linear. Fonte: [1]

O *Tradeoff* de viés-variancia

O formato em U observado no conjunto de teste vem duas propriedades competitivas. Considere o valor esperado do MSE para um dado de teste x_0 como

$$E\left(y_0 - \hat{f}(x_0)\right)^2 = \text{Var}\left(\hat{f}(x_0)\right) + \left[\text{Bias}\left(\hat{f}(x_0)\right)\right]^2 + \text{Var}(\epsilon).$$

Observe que esse MSE é decomposto por três quantidades: *variância* de $\hat{f}(x_0)$, o quadrado do *viés* e a variância do erro ϵ.

Variância

Variância do modelo está relacionada à quantidade de **variação de** f a medida que mudamos o conjunto de treino.

- Não queremos que f varie tanto ao mudarmos o conjunto de treino.
- Está mais relacionado com modelos mais flexíveis e ao conceito de *overfitting* (sobreajuste).

Viés e Variância

Viés

Viés do modelo se refere ao erro introduzido ao aproximar um problema da vida real, que pode ser extremamente complicado, por um modelo bem simples

- **Exemplo**: usar uma equação linear na relação de Y e X não-linear.
- Está relacionado ao *erro* do modelo e associado a modelos menos flexíveis e conceito de *underfitting* (subajuste).

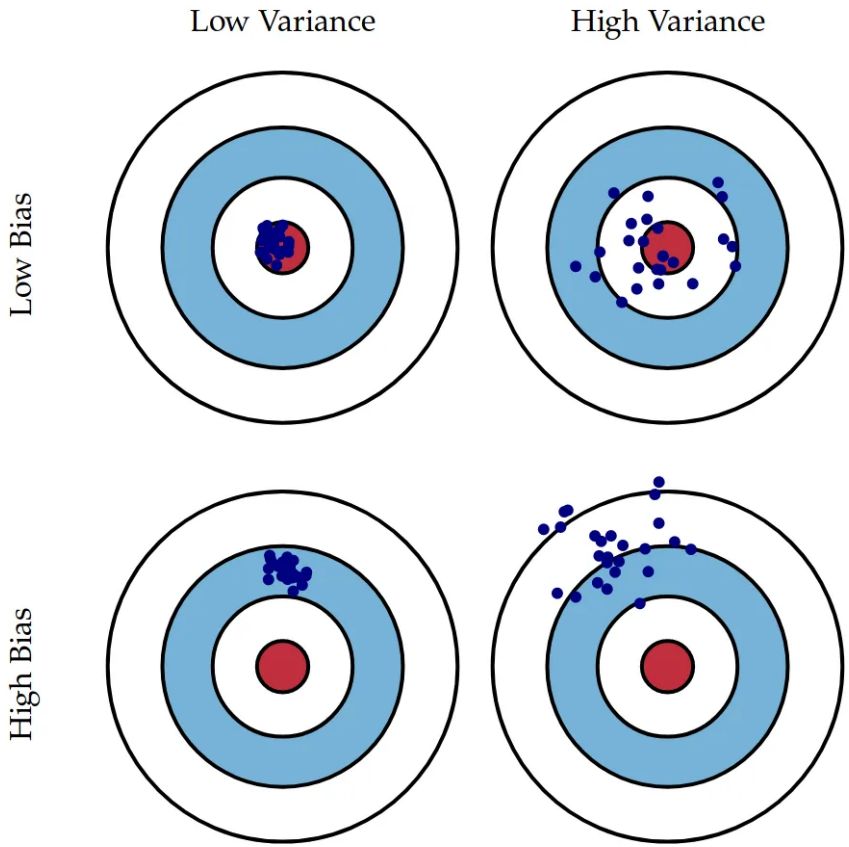


Fig. 1 Graphical illustration of bias and variance.

Figura 10: Fonte: appliedaicourse

Viés e Variância

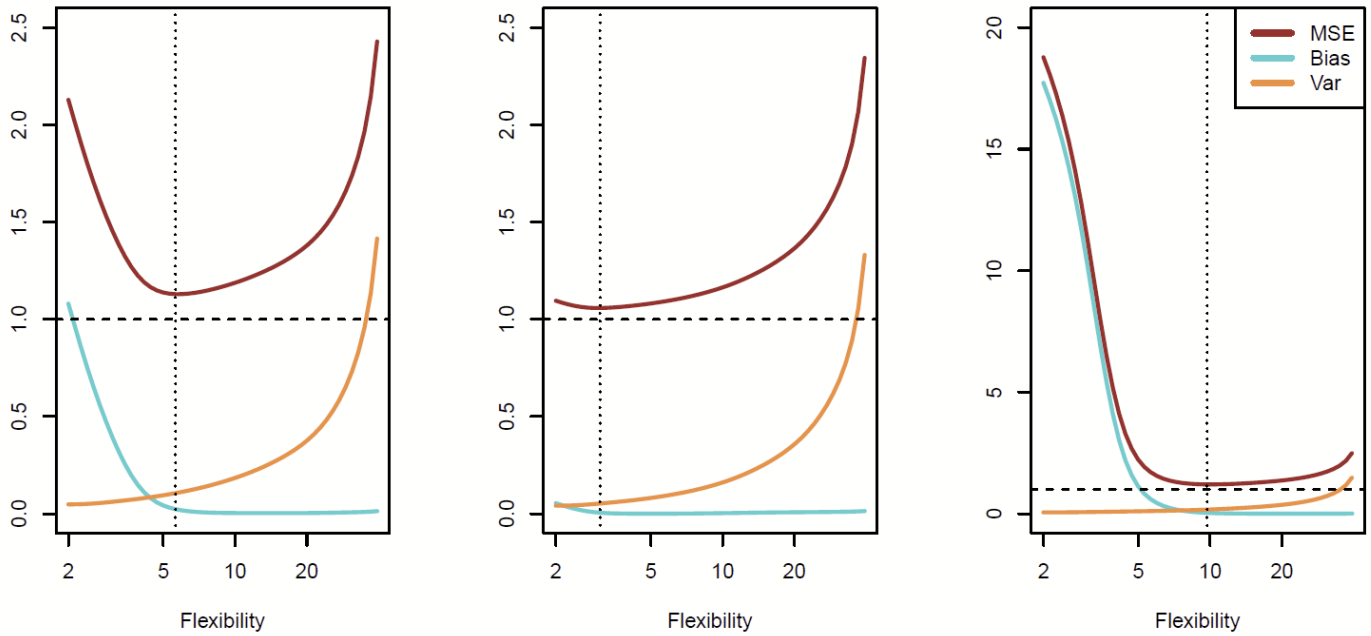


Figura 11: Viés ao quadrado (curva azul), variância (curva laranja), Var(ε) (linha tracejada) e erro quadrático médio de teste (MSE de teste, curva vermelha) para os três conjuntos de dados apresentados anteriormente. A linha vertical pontilhada indica o nível de flexibilidade correspondente ao menor MSE de teste. Fonte: [1]

Leitura Recomendada

[1] Capítulo 1, até 2.2.2.

Referências I



Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani, and Jonathan Taylor.
An Introduction to Statistical Learning with Applications in Python.
Springer Texts in Statistics. Springer, Cham, 1st edition, 2023.