Classificação & KNN

Prof. Renan Gomes Vieira

Uninersidade Federal do Ceará - Campus Quixadá
Aprendizado de Máquina

2026.2

Sumário

1. O cenário da classificação
2. O classificador de Bayes
3. K-Vizinhos Mais Próximos (K-Nearest Neighbors, KNN)
4. Variações do KNN
5. A Maldição da dimensionalidade

O cenário da classificação

Da Regressão à Classificação

O que permanece?

Os fundamentos de generalização continuam os mesmos:

- Compromisso **viés-variância**, riscos de *overfitting* e necessidade de validação.

O que muda?

A natureza da variável de resposta:

- **Regressão:** $y \in \mathbb{R}$ (quantitativo, valores contínuos).
- **Classificação:** $y \in \{C_1, C_2, \ldots, C_K\}$ (qualitativo, categorias/rótulos discretos).

Classificação

Suponha que queremos estimar um f a partir dos dados de treino

$$\{(x_1, y_1), \cdots, (x_n, y_n)\}$$

onde agora $y_1, ..., y_n$ são *qualitativos*

Variáveis qualitativas

Nesse contexto, o *qualitativo* pode ser substituído por *categórico*.
Exemplos: saudável/doente, bom/ruim, cachorro/gato/cavalo.

Classificação

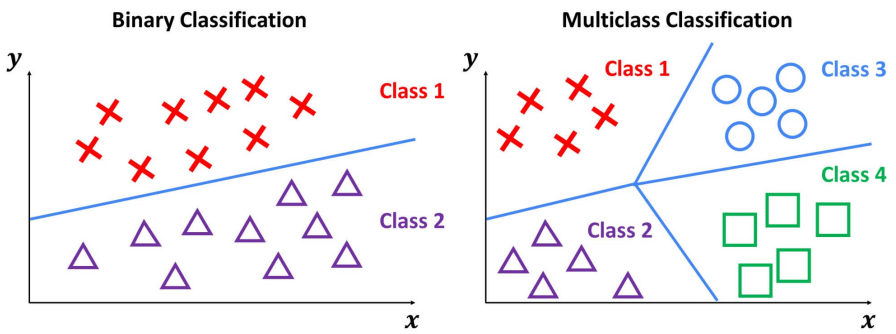


Figura 1: Problemas de classificação comumente tem duas ou mais classes. Fonte: datahacker.rs

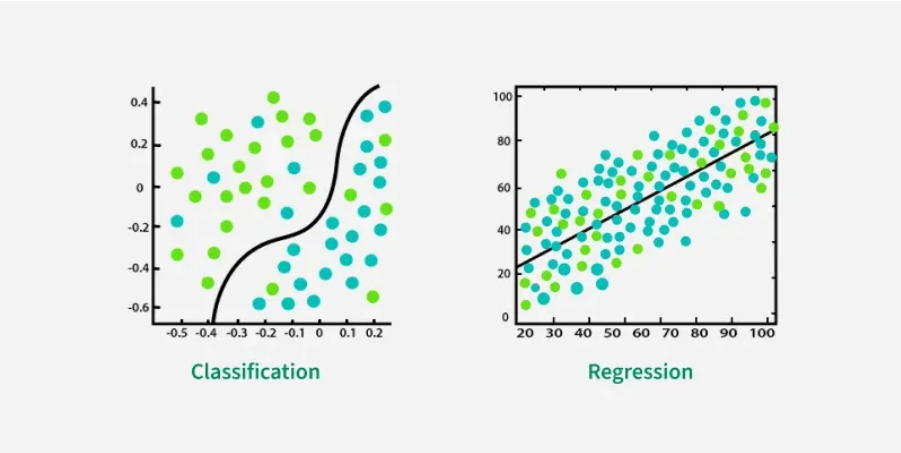


Figura 2: Observe que nossos modelos são iguais em forma aos de regressão, mas ficam dispostos em outro lugar no espaço em relação aos dados. Fonte: geeksforgeeks.org

Métrica de Desempenho: Taxa de Erro

Taxa de Erro de Treino

A qualidade do estimador $\hat{f}$ é avaliada pela proporção de erros cometidos:

$$\text{Taxa de Erro} = \frac{1}{n}\sum_{i=1}^{n} I(y_i \neq \hat{y}_i)$$

onde a função indicadora assume $I(y_i \neq \hat{y}_i) = 1$ se $y_i \neq \hat{y}_i$ (classificação incorreta) e 0 caso contrário.

Relação com a Acurácia

$$\text{Acurácia} = 1 - \text{Taxa de Erro}$$

A taxa de erro é utilizada para manter a formulação padrão de minimização de função de custo.

Critério de Otimização

O objetivo central é minimizar a **taxa de erro no teste**:

$$\text{Erro}_{\text{teste}} = \text{Ave}\big(I(y_0 \neq \hat{y}_0)\big), \quad (\mathbf{x}_0, y_0) \notin \mathcal{D}_{\text{treino}}$$

Paralelo com Regressão

- **Trade-off Viés-Variância:** ajuste da complexidade do modelo.
- **Taxonomia:** algoritmos paramétricos vs. não paramétricos.
- **Erro Irredutível:** limite imposto pela taxa de erro de Bayes.
- **Seleção de modelos:** comparação entre modelos e hiperparâmetros.

O classificador de Bayes

Classificador de Bayes

É possível mostrar que o erro de teste é minimizado, na média, por um classificador bem simples que *determina cada observação a sua classe mais provável, dado seus atributos*. Em outras palavras, a classe de um dado de teste com preditores x_0 é j onde

$$Pr(Y = j|X = x_0)$$

é a maior dentre todas as outras classes $\neq j$.

Classificador de Bayes

- Esse classificador é chamado de *Classificador de Bayes*.
- Por exemplo, para um problema binário com *classe 1* e *classe 2*, caso $Pr(Y = 1|X = x_0) > 0.5$, então x_0 é classificado como classe 1.
- Esse modelo teórico nos fornece o limite inferior do erro possível em problemas de classificação, chamado de *erro de Bayes*, que representa o erro irredutível do problema.
- Ele é considerado um modelo teórico pois, na prática, **não conhecemos as distribuições verdadeiras dos dados** e muitas vezes é **impraticável estimá-las**, especialmente em problemas de alta dimensionalidade.

Classificador de Bayes

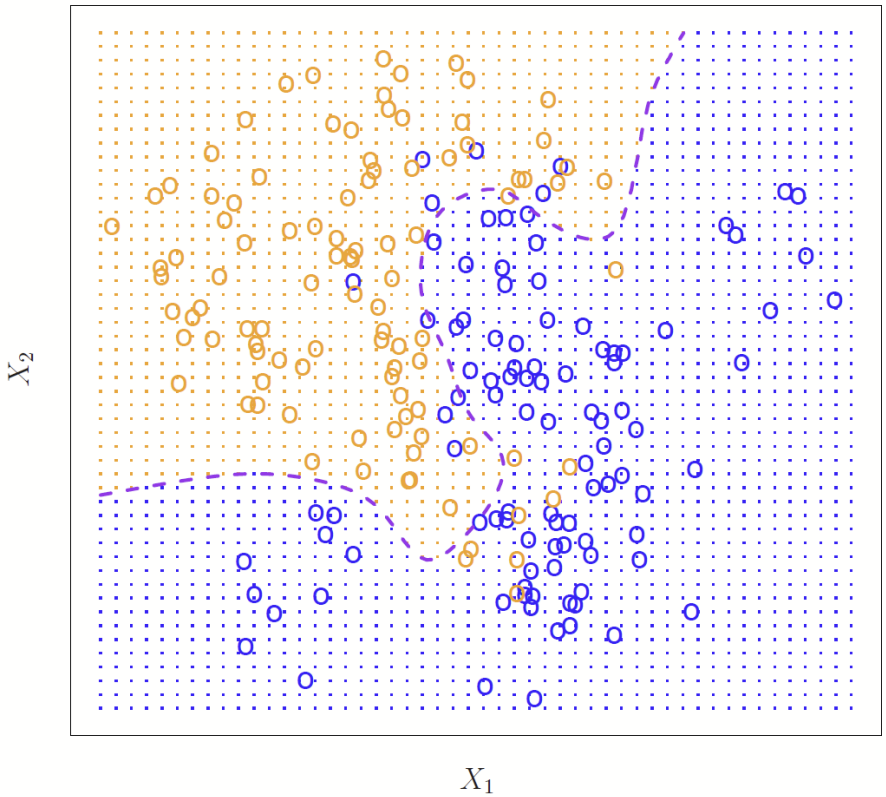


Figura 3: 100 dados simulados de dois grupos: laranjas e azuis. A linha roxa representa a *fronteira de decisão* de Bayes. Esse é o melhor classificador, na média, para esses dados, que fornece o menor erro possível para dados com sobreposição de classes.

Classificador de Bayes

- O classificador de Bayes produz o menor erro de teste possível, chamado de *taxa de erro de Bayes*

$$1 - E(\max_j Pr(Y = j|X)),$$

que é o valor esperado de todos os valores possíveis da variável aleatória X.

- Para os dados simulados apresentados, o erro é 0.133.

Erro de Bayes

O erro de Bayes é o menor erro possível que qualquer classificador pode atingir dada a distribuição real dos dados.

K-Vizinhos Mais Próximos (K-Nearest Neighbors, KNN)

K-Vizinhos Mais Próximos (K-Nearest Neighbors, KNN)

- Como não podemos estimar as distribuições condicionais $P(Y|X)$, o classificador de Bayes é um padrão de ouro inalcançável.
- Contudo, ele serve de base para outras ideias que tentam *estimar* a $P(Y|X)$ com a maior probabilidade *estimada*.
- Um desses métodos é o **K-Vizinhos Mais Próximos** (*K-Nearest Neighbors*), um método **não-paramétrico**, baseando em **instâncias**.

Dado um inteiro positivo K e um dado de teste x_0, o classificador KNN primeiro identifica os K pontos do **conjunto de treino** que são mais próximos de x_0, representados por N_0, computando assim a probabilidade condicional da classe j como a fração das quais são de fato classe j:

$$Pr(Y = j|X = x_0) = \frac{1}{K} \sum_{i \in N_0} I(y_i = j).$$

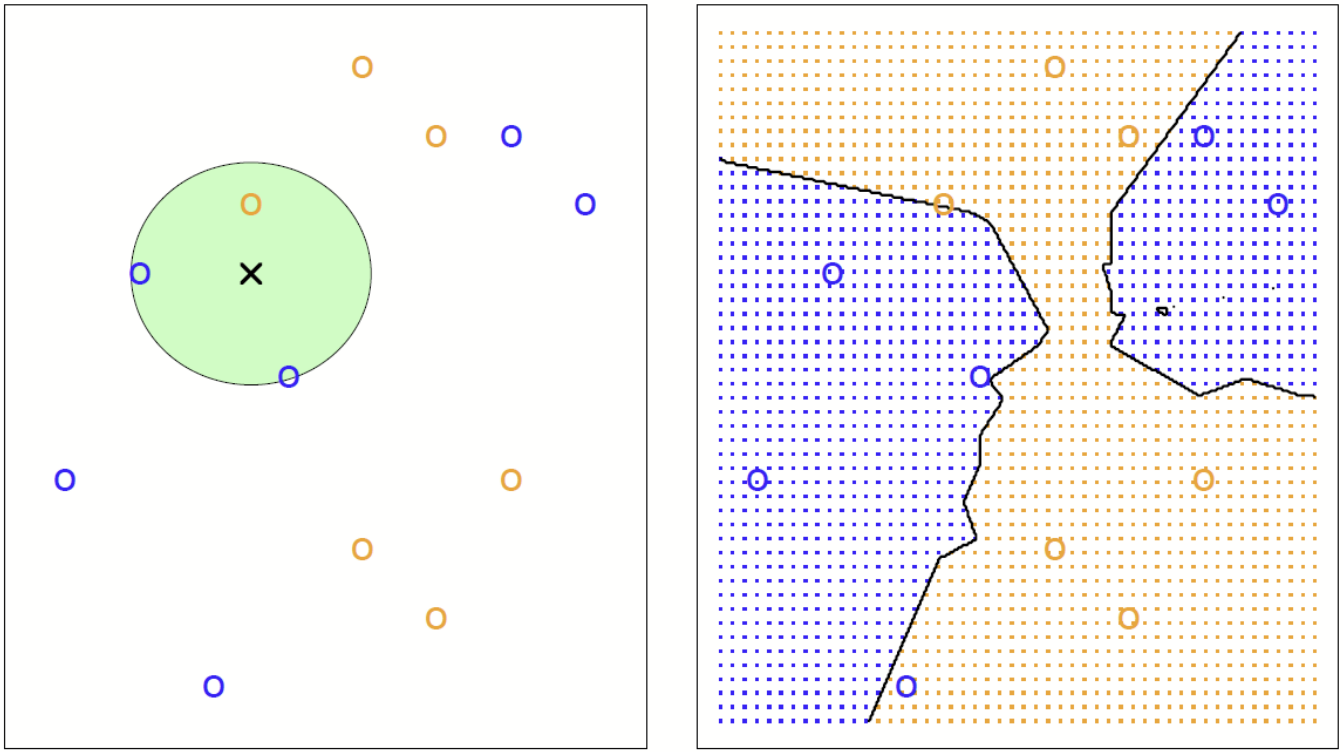


Figura 4: Com um $K = 3$, queremos classificar o dado $\times$ como classe azul ou classe laranja, a partir dos dados de treino (os pontos $\circ$.)

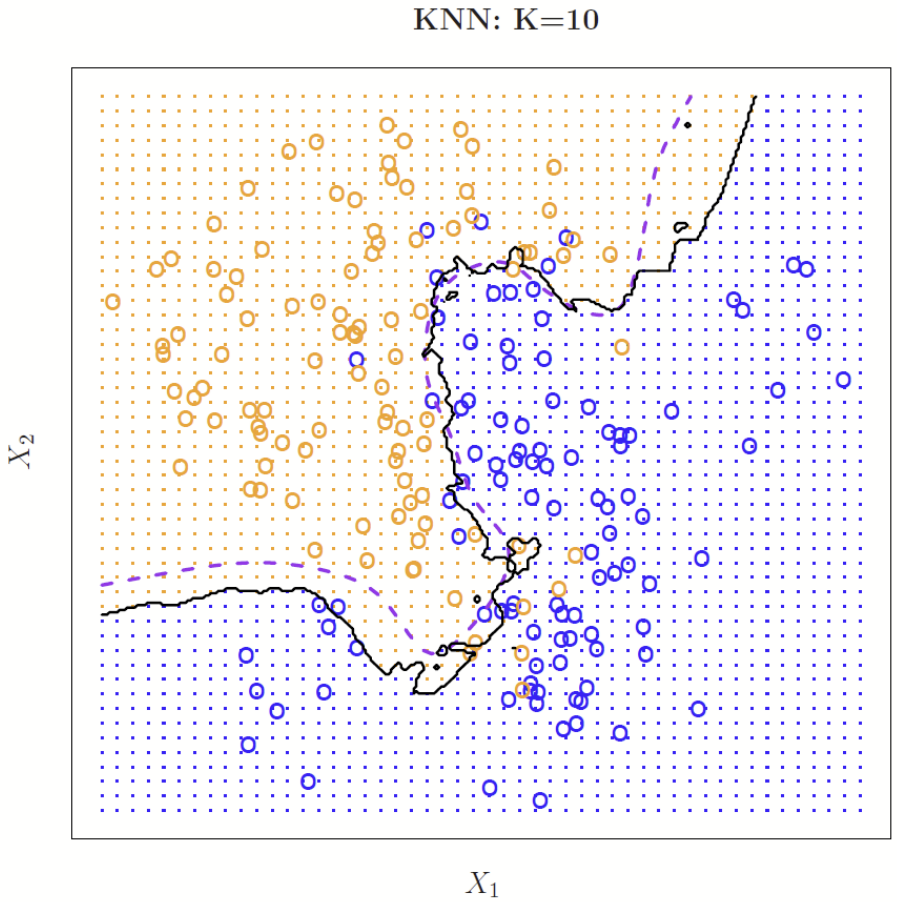


Figura 5: A curva preta indica a *superfície de decisão*, usando $K = 10$. A superfície de decisão é linha pontilhada roxa. Observe como são similares, com erros numericamente similares também.

KNN - Mas e o valor de K?

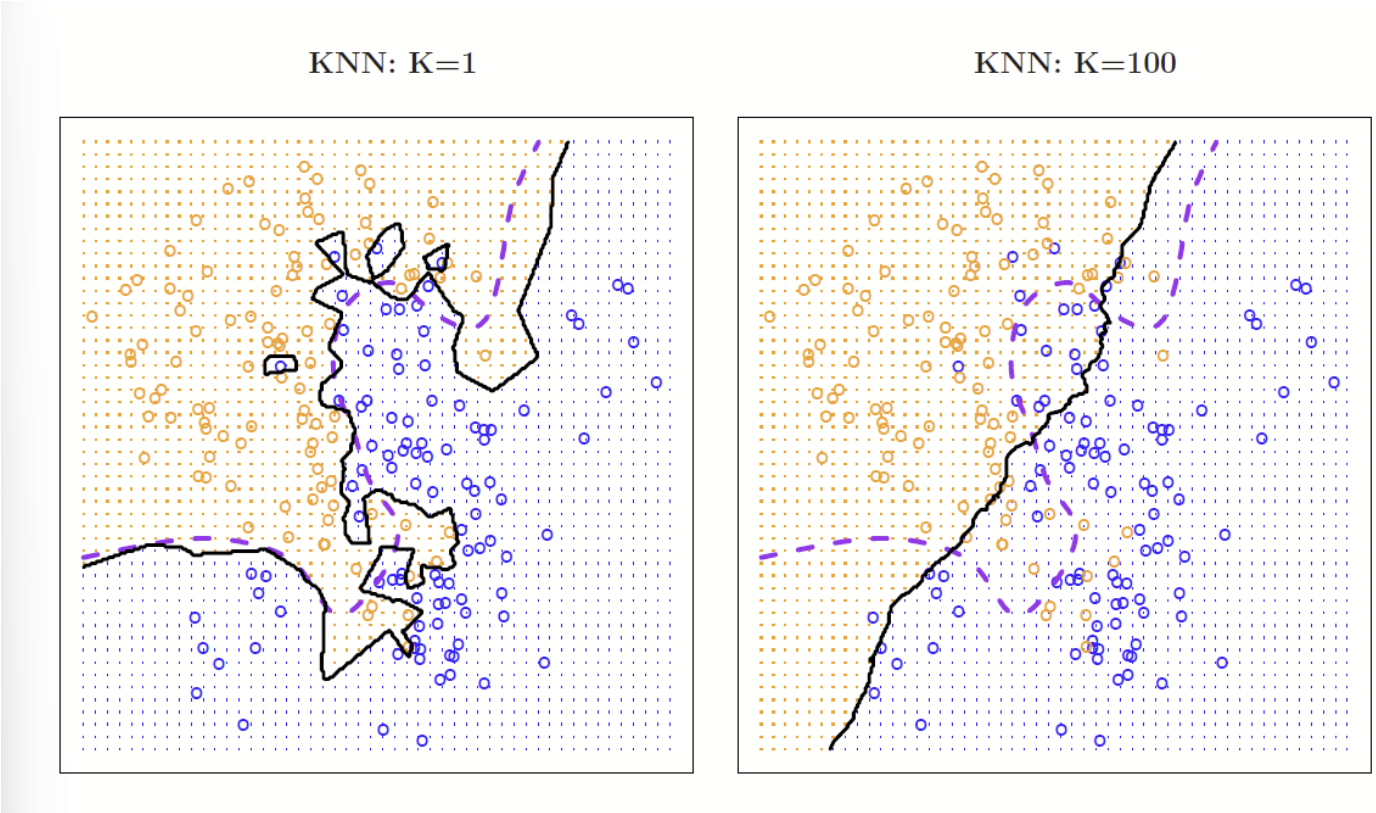


Figura 6: O valor de K define a flexibilidade da superfície de decisão.

KNN - Taxas de Erro para diferentes valores de K

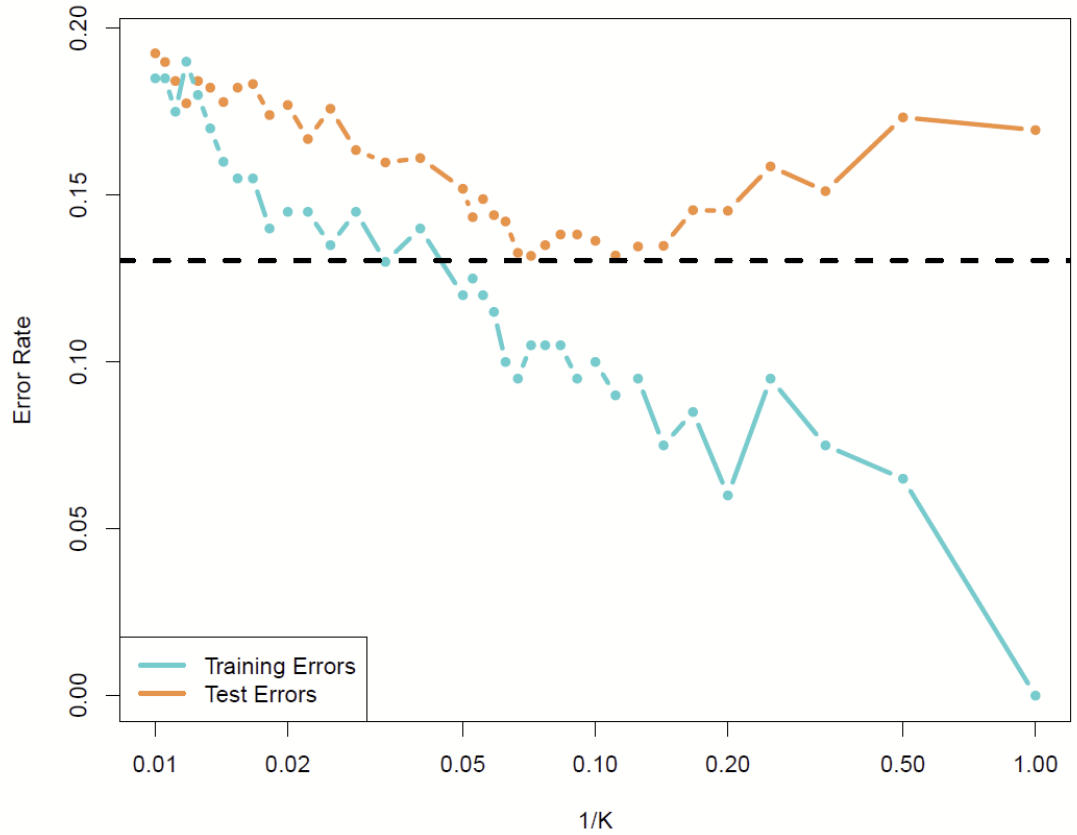


Figura 7: Curvas da taxa de erro utilizando diferentes valores de K. Note que no caso do KNN, grandes valore de K deixam o modelo menos flexível. Observa-se também o a curva de teste em formato de U.

KNN - Medida de Distância

A métrica de distância mais comum é a *Distância Euclidiana*, também conhecido como *norma euclidiana* ou *norma L2* e é dada por

$$d(\mathbf{x}, \mathbf{x}') = \sqrt{\sum_{i=1}^{p} (x_i - x_i')^2}$$

Classificador K-Nearest Neighbors (K-NN)

Dada uma observação de teste x_0 e um inteiro positivo K:

1. Identifica-se o conjunto $\mathcal{N}_0$, composto pelos K pontos de treino mais próximos de x_0 no espaço de atributos.
2. Estima-se a probabilidade condicional de x_0 pertencer à classe j:

$$\mathrm{P}(Y = j \mid X = x_0) = \frac{1}{K} \sum_{i \in \mathcal{N}_0} I(y_i = j)$$

   onde $I(y_i = j)$ é a **função indicadora**:

$$I(y_i = j) = \begin{cases} 1, & \text{se } y_i = j \\ 0, & \text{se } y_i \neq j \end{cases}$$

3. Classifica-se x_0 na classe com maior probabilidade estimada (regra de Bayes):

$$\hat{y}_0 = \arg\max_j \mathrm{P}(Y = j \mid X = x_0)$$

Variações do KNN

Variações do KNN Básico

O comportamento do KNN padrão baseia-se em duas premissas simples:

1. A proximidade é medida por **distância euclidiana**.
2. Todos os K vizinhos têm o **mesmo peso** no voto.

Podemos flexibilizar o algoritmo atuando em dois eixos:

- **Métricas de Distância:** Como definir o que é "próximo"?
- **Esquema de Ponderação:** Vizinhos mais perto devem votar com mais força?

Variação 1: Métricas de Distância

A escolha da métrica altera a geometria da fronteira de decisão.

Distância de Minkowski (L_q)

Dadas duas instâncias x e z em $\mathbb{R}^p$:

$$d(x, z) = \left(\sum_{m=1}^{p} |x_m - z_m|^q \right)^{\frac{1}{q}}$$

- **Euclidiana ($q = 2$):** padrão, mede a distância em linha reta.
- **Manhattan ($q = 1$):** soma dos deslocamentos absolutos nos eixos (útil quando os atributos têm significados físicos distintos).

Outras Distâncias

Você pode ler um pouco mais sobre em academis.eu.

Exemplos: Diferentes distâncias

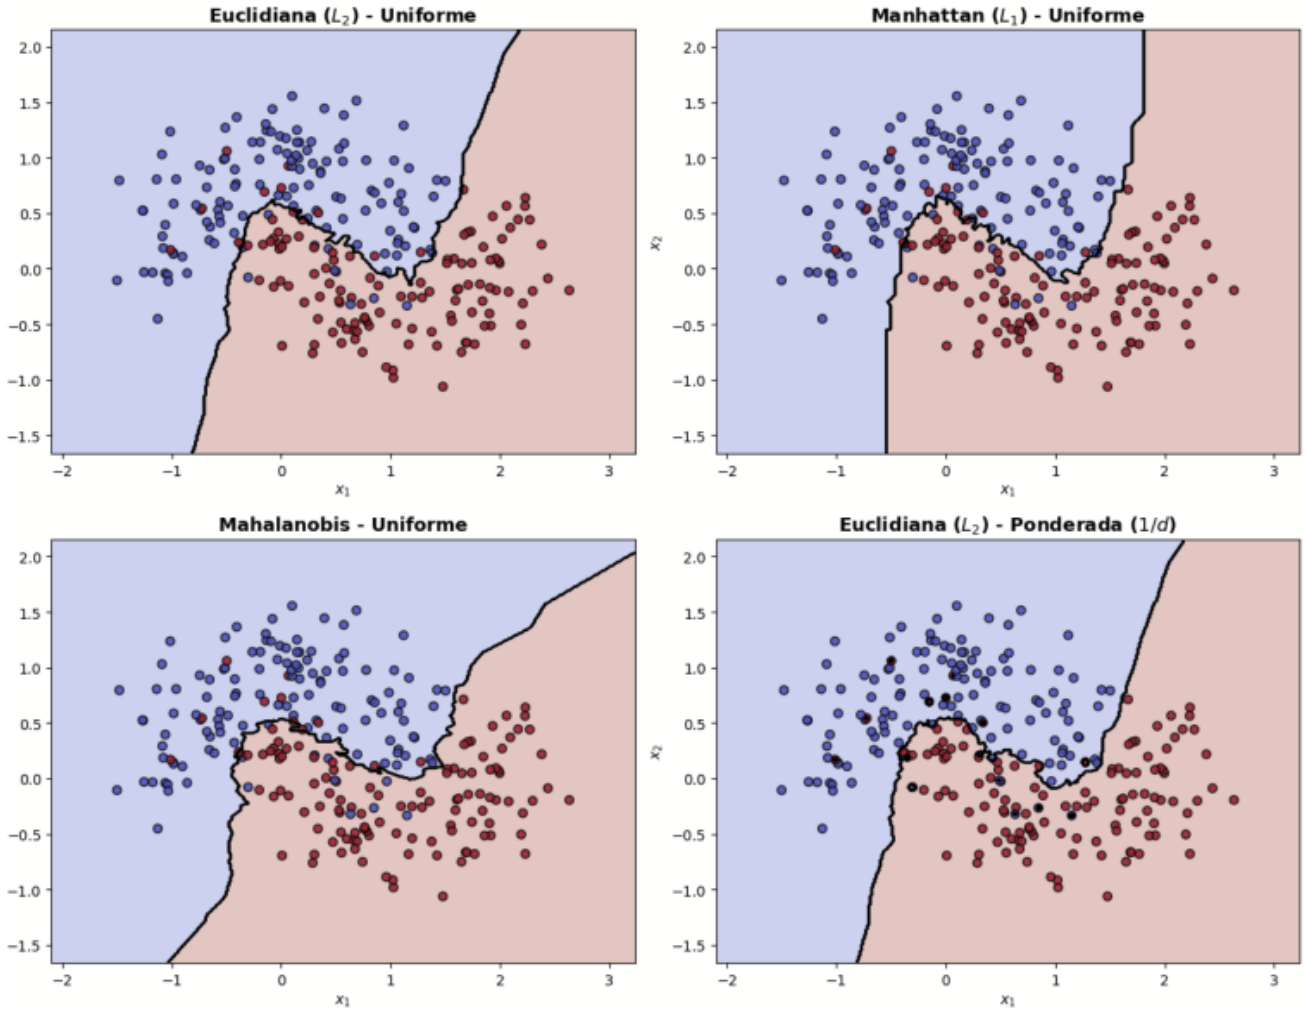


Figura 8: Superfície de decisão para um mesmo problema de classificação binário, usando diferentes métricas de distância

Variação 2: Ponderação pela Distância

No KNN padrão, o vizinho colado a x_0 tem o mesmo peso do vizinho mais afastado.

Atribuição de Pesos (w_i)

Atribui-se a cada $x_i \in \mathcal{N}_0$ um peso inversamente proporcional à distância:

$$w_i = \frac{1}{d(x_0, x_i)^2 + \epsilon}$$

- A predição passa a ser uma média ponderada dos votos:

$$\hat{y}_0 = \arg\max_j \sum_{i \in \mathcal{N}_0} w_i \cdot I(y_i = j)$$

- Reduz a sensibilidade do algoritmo a uma escolha imperfeita de K.

KNN para Regressão

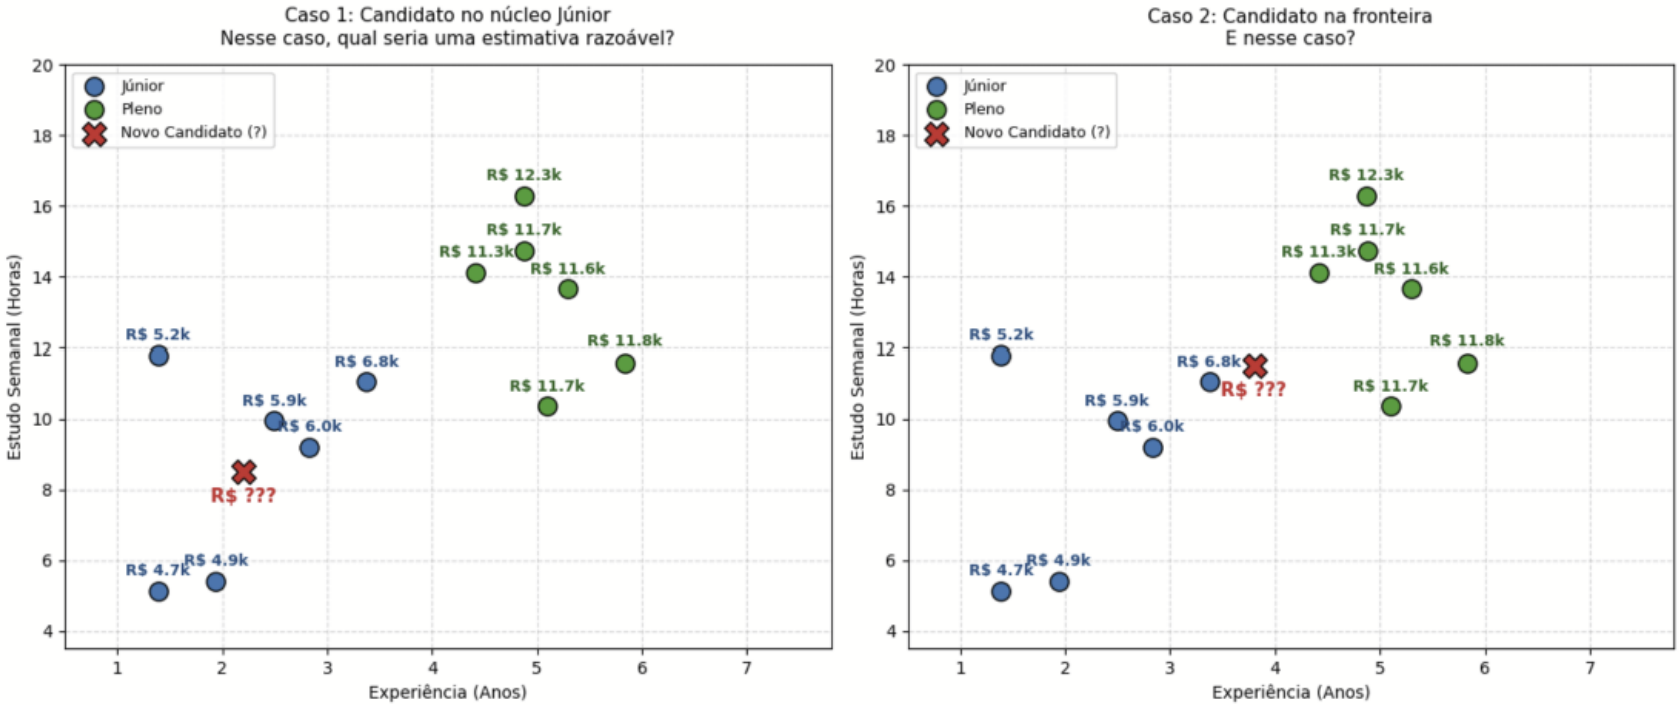


Figura 9: Exemplo para estimativa de salário (regressão) usando KNN

KNN para Regressão

Na classificação, o alvo y é discreto (rótulo). Na regressão, o alvo $y \in \mathbb{R}$ é contínuo.

- **Premissa básica:** Instâncias com atributos x similares devem ter respostas y similares.
- Em vez de **contar votos** da classe majoritária, tomamos a **média dos valores reais** dos K vizinhos mais próximos.

Comportamento da Curva

- A função estimada é uma **constante por partes** (em degraus).
- K pequeno $\implies$ curva ajusta-se a ruídos locais (alta variância).
- K grande $\implies$ curva suaviza em direção à média global (alto viés).

KNN para Regressão

Dada uma nova observação x_0 e o conjunto $\mathcal{N}_0$ dos K pontos de treino mais próximos:

1. Média Simples (Padrão)

A estimativa $\hat{f}(x_0)$ é a média aritmética dos valores de treino na vizinhança:

$$\hat{f}(x_0) = \frac{1}{K} \sum_{i \in \mathcal{N}_0} y_i$$

2. Média Ponderada por Distância

Atribuindo pesos $w_i = \frac{1}{d(x_0, x_i)^2 + \epsilon}$:

$$\hat{f}(x_0) = \frac{\sum_{i \in \mathcal{N}_0} w_i \cdot y_i}{\sum_{i \in \mathcal{N}_0} w_i}$$

Efeito dos pesos: Elimina os degraus bruscos e torna a curva de regressão contínua e mais suave.

Exemplos visuais: KNN para regressão

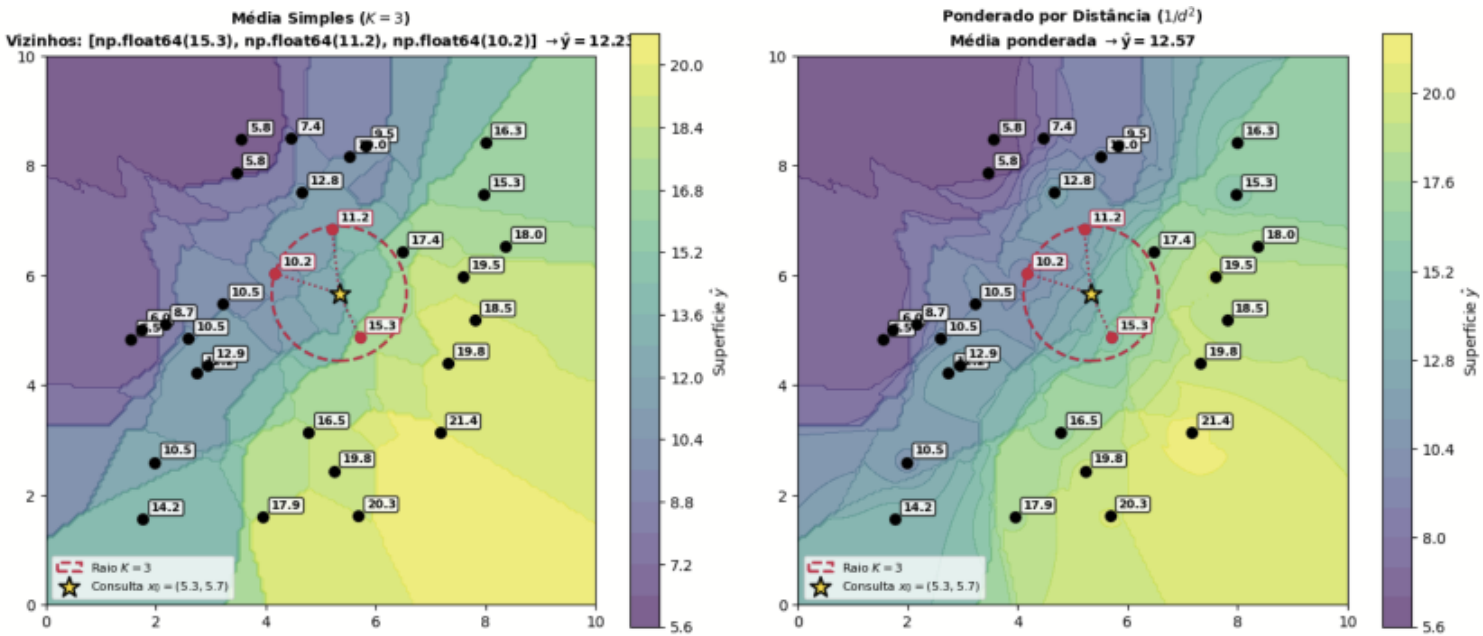


Figura 10: A estimativa ponderada consideram que pontos mais próximos são mais significativos

Exemplos visuais: KNN para regressão

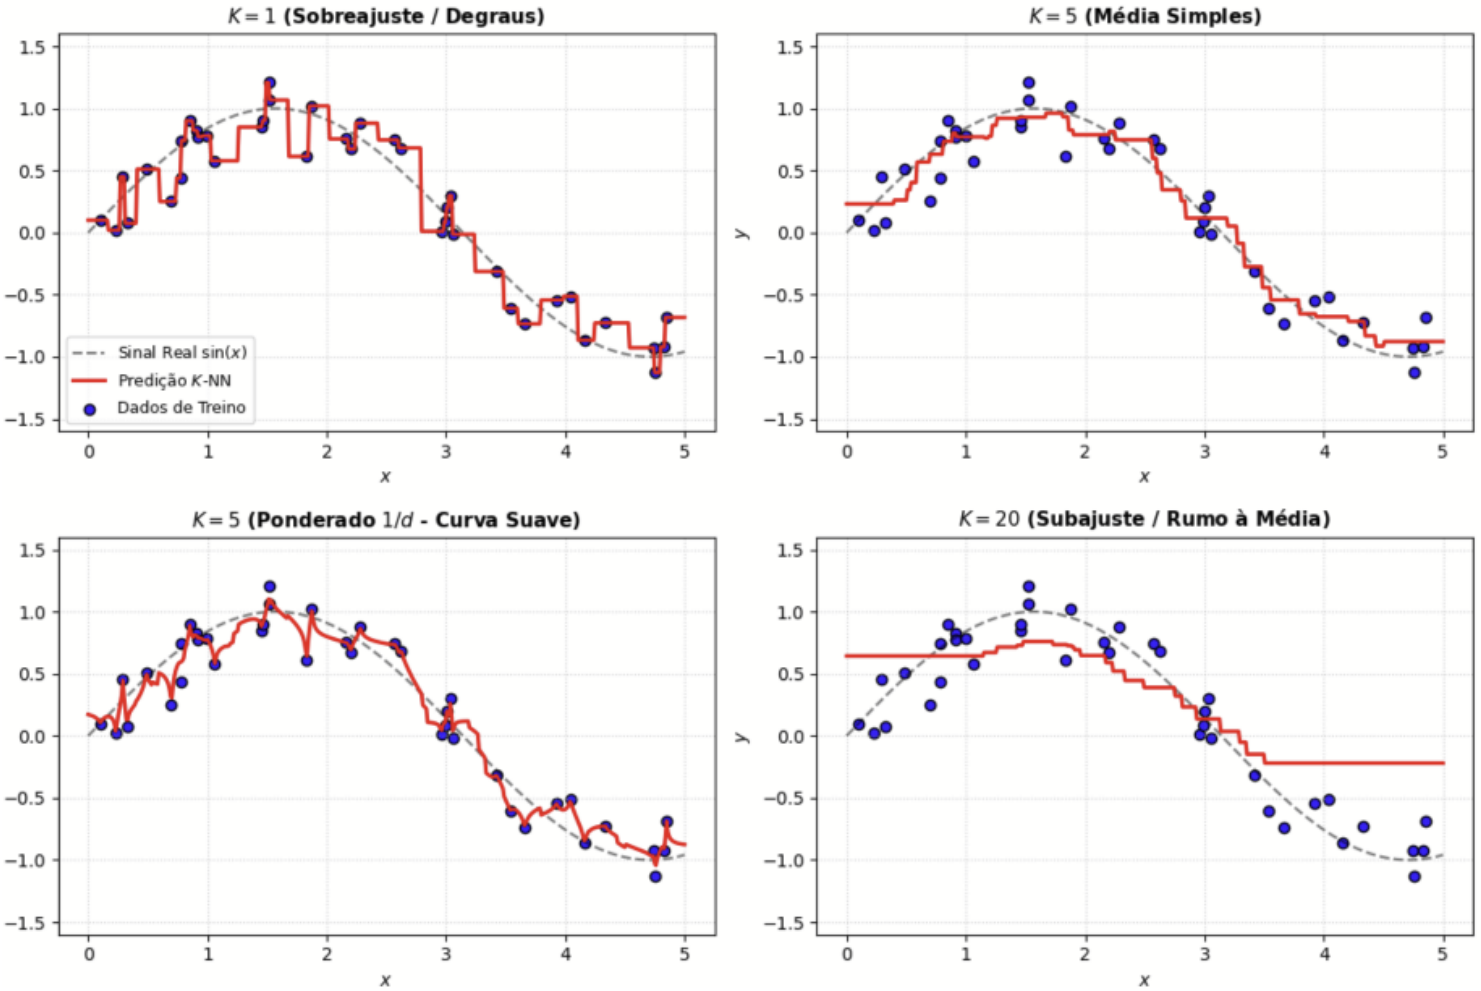


Figura 11: Diferentes configurações de KNN para regressão para aproximar uma função seno.

A Maldição da dimensionalidade

A Maldição da Dimensionalidade

Imagine dividir cada eixo de um espaço unitário $[0, 1]^p$ em 10 intervalos.

- $p = 1$ (1D): $10^1 = 10$ células
- $p = 2$ (2D): $10^2 = 100$ células
- $p = 3$ (3D): $10^3 = 1.000$ células
- $p = 20$ (20D): 10^{20} células

Para preencher minimamente esse espaço, o número de amostras N precisa crescer **exponencialmente** com a dimensão p:

$$N = \mathcal{O}(k^p)$$

A Maldição da dimensionalidade

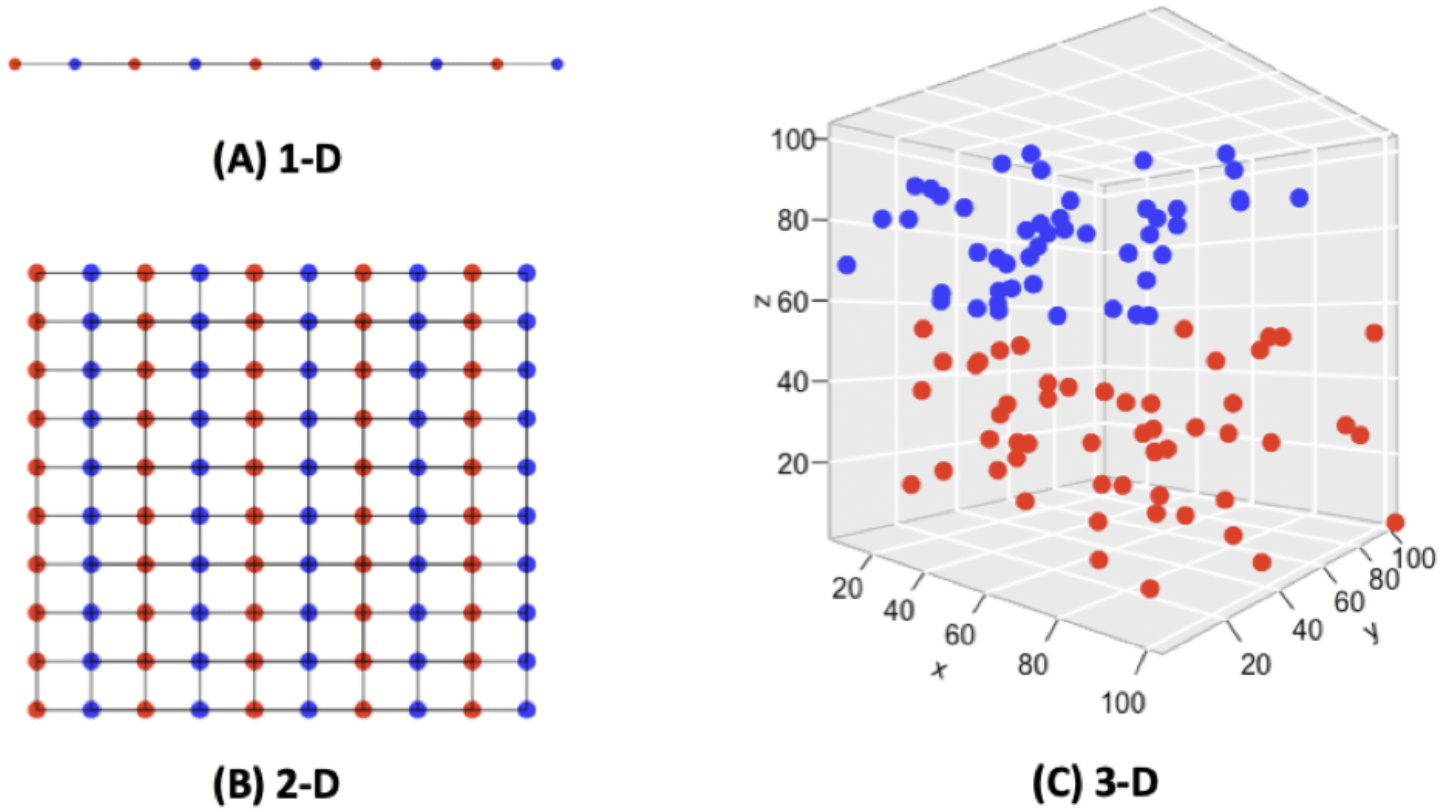


Figura 12: Subir a dimensão faz o espaço explodir exponencialmente ($10 \rightarrow 100 \rightarrow 1000$). O que era vizinho colado em 1D vira um ponto isolado no vácuo em 3D.

O Bloqueio na Estimação de $P(X \mid Y)$

No classificador ótimo de Bayes, buscamos:

$$P(Y = c \mid X = x) = \frac{P(X = x \mid Y = c) \cdot P(Y = c)}{P(X = x)}$$

- Para estimar a densidade conjunta contínua $p(x_1, x_2, \ldots, x_p \mid Y = c)$ sem assumir independência, precisamos de dados suficientes na vizinhança de x.
- Como a maioria das regiões em $\mathbb{R}^p$ não contém amostra alguma ($k = 0$), a estimativa pontual empírica colapsa para zero ou se torna extremamente instável.

Naive Bayes

É por isso que surge o **Naive Bayes**, que força a premissa de independência condicional $P(X \mid Y) = \prod_{j=1}^{p} P(X_j \mid Y)$ para escapar da maldição.

Algumas perguntas para reflexão

- Em problemas de 2 classes, faz diferença usar valores de K par ou impar? E em problemas de 3 classes? E de 6 classes?
- Se avaliarmos um modelo com $K = 1$ na própria base de treino, a acurácia será 100%. Isso indica que ele é ótimo? E se usarmos $K = N$, qual será a resposta para qualquer nova consulta?
- Com um rótulo incorreto isolado no meio da outra classe, qual a diferença da fronteira de decisão gerada por $K = 1$ em relação a $K = 15$?
- Se mantivermos 2 atributos úteis e adicionarmos 50 colunas de puro ruído aleatório, o que acontece com o cálculo da distância Euclidiana e a escolha dos vizinhos?
- Quanto tempo o KNN gasta na etapa de ajuste/treino? Por que realizar inferência em tempo real com $N = 10^7$ pode se tornar inviável?

Leituras Recomendadas

- [2]
  - Cap. 2, Sec. 2.2.3 (KNN para classificação e regressão)
  - Cap. 3, Sec. 3.5 (comparação entre KNN e modelos lineares)
- [1]
  - Cap. 2, Sec. 2.4 (teoria de decisão e o classificador ótimo de Bayes)
  - Cap. 2, Sec. 2.5 (métodos locais e a maldição da dimensionalidade)
  - Cap. 13, Sec. 13.1–13.3 (variações, métricas e extensões do KNN)
- [3]
  - Cap. 6, Sec. 6.7–6.10 (classificador de Bayes e premissa do Naive Bayes)
  - Cap. 8, Sec. 8.2 (aprendizado baseado em instâncias e KNN ponderado)

Videos Recomendados

- The curse of Dimentionality (DataMListic)
- The curse of Dimentionality (Caltech)

Referências I


Trevor Hastie, Robert Tibshirani, and Jerome Friedman.
The Elements of Statistical Learning: Data Mining, Inference, and Prediction.
Springer, New York, 2nd edition, 2009.


Gareth James, Daniela Witten, Trevor Hastie, and Robert Tibshirani.
An Introduction to Statistical Learning: with Applications in R and Python.
Springer, New York, 2nd edition, 2021.


Tom M. Mitchell.
Machine Learning.
McGraw-Hill, New York, 1997.