Regressão Linear & Logística

Prof. Renan Gomes Vieira

Universidade Federal do Ceará - Campus Quixadá
Aprendizado de Máquina

2026.2

Sumário

1. Regressão Linear simples
2. Regressão Linear Múltipla
3. Métodos de Classificação
4. Regressão Logística
5. Generalização e Regularização: Polinômios, Ridge e Lasso

Regressão Linear simples

Regressão Linear

- É uma das ferramentas mais clássicas e úteis para problemas de regressão.
- Apesar de simples, ainda é amplamente utilizado e é a base de diversos outro métodos mais complexos.
  - Por exemplo, alguns modelos de redes neurais e até SVM podem ser vistos como generalizações ou extensões da regressão linear,
- É uma ferramenta que já se mostrou valiosa em diversos contextos de predição e inferência.

Regressão Linear Simples

Um modelo que assume que predizer o valor de Y em função de uma única variável X, assumindo também que há uma relação linear entre X e Y:

$$Y \approx \beta_0 + \beta_1 X.$$

onde $\approx$ é lido como "aproximadamente modelado por", de forma que queremos encontrar $\hat{\beta}_0$ e $\hat{\beta}_1$ tal que

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x.$$

O uso de ˆ

Em notações estatísticas e de aprendizado de máquina, qualquer símbolo com ˆ é um indicadivo de *estimativa*.

Regressão Linear Simples - Exemplos

$$\text{vendas} \approx \beta_0 + \beta_1 \text{propaganda}.$$

$$\text{valorImovel} \approx \beta_0 + \beta_1 \text{QtdQuartos}.$$

$$\text{probabilidadeAprovacao} \approx \beta_0 + \beta_1 \text{numFaltas}.$$

$$\text{peso} \approx \beta_0 + \beta_1 \text{altura}.$$

$$\text{vendasAno} \approx \beta_0 + \beta_1 \text{vendasAnoPassado}.$$

Regressão Linear Simples - Estimando parâmetros

- Existem diversos meios de estimar os parâmetros $\hat{\beta}_0$ e $\hat{\beta}_1$.
- O método mais comum é feito para *minimizar* os **mínimos quadrados**.
- Para tal, definimos

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i.$$

a predição de um valor de Y para um x_i de X,

$$e_i = y_i - \hat{y}_i$$

como o **resíduo** i e também a *soma quadrática dos resíduos* como

$$\text{RSS} = e_1^2 + e_2^2 + \cdots + e_n^2$$

A soma dos quadrados dos resíduos (RSS) é dada por:

$$RSS = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \cdots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2.$$

O **método dos mínimos quadrados** escolhe $\hat{\beta}_0$ e $\hat{\beta}_1$ de forma a minimizar o RSS. Utilizando cálculo, pode-se mostrar que os valores que minimizam são:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2},$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

Regressão Linear Simples - Mínimos Quadrados

A soma dos quadrados dos resíduos é definida por:

$$RSS(\beta_0, \beta_1) = \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$$

Nosso objetivo é encontrar os valores de β_0 e β_1 que minimizam essa função. Como $RSS(\beta_0, \beta_1)$ é uma função quadrática em β_0 e β_1, podemos encontrar seu mínimo calculando as derivadas parciais e igualando a zero:

$$\frac{\partial RSS}{\partial \beta_0} = 0 \qquad \frac{\partial RSS}{\partial \beta_1} = 0$$

Derivadas Parciais

Calculando as derivadas, obtemos:

$$\frac{\partial RSS}{\partial \beta_0} = -2\sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_i)$$

$$\frac{\partial RSS}{\partial \beta_1} = -2\sum_{i=1}^{n} x_i(y_i - \beta_0 - \beta_1 x_i)$$

Igualando as Derivadas a Zero

Igualando as derivadas a zero, temos:

$$\sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\sum_{i=1}^{n} x_i(y_i - \beta_0 - \beta_1 x_i) = 0$$

Essas duas equações formam o sistema que determina os estimadores de mínimos quadrados.

Manipulando a Primeira Equação

A partir da primeira equação:

$$\sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_i) = 0$$

distribuímos a soma:

$$\sum_{i=1}^{n} y_i - \sum_{i=1}^{n} \beta_0 - \sum_{i=1}^{n} \beta_1 x_i = 0$$

como β_0 e β_1 são constantes:

$$\sum_{i=1}^{n} y_i - n\beta_0 - \beta_1 \sum_{i=1}^{n} x_i = 0$$

Obtendo β_0

Reorganizando os termos:

$$\sum_{i=1}^{n} y_i = n\beta_0 + \beta_1 \sum_{i=1}^{n} x_i$$

Dividindo tudo por n:

$$\bar{y} = \beta_0 + \beta_1 \bar{x}$$

Logo,

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

Substituindo na Segunda Equação

Agora usamos a segunda equação:

$$\sum_{i=1}^{n} x_i(y_i - \beta_0 - \beta_1 x_i) = 0$$

Substituindo $\beta_0 = \bar{y} - \beta_1 \bar{x}$:

$$\sum_{i=1}^{n} x_i \left(y_i - (\bar{y} - \beta_1 \bar{x}) - \beta_1 x_i\right) = 0$$

ou, equivalentemente,

$$\sum_{i=1}^{n} x_i \left[(y_i - \bar{y}) - \beta_1 (x_i - \bar{x})\right] = 0$$

Isolando β_1

Expandindo a expressão:

$$\sum_{i=1}^{n} x_i(y_i - \bar{y}) - \beta_1 \sum_{i=1}^{n} x_i(x_i - \bar{x}) = 0$$

Após a simplificação algébrica, chegamos a:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

Estimadores de Mínimos Quadrados

Assim, os estimadores obtidos pelo método dos mínimos quadrados são:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Esses valores definem a reta de regressão estimada.

Mínimos Quadrados

Esse é um método que chamamos de **fórmula fechada**, pois a diretamente resolvido com uma expressão matemática explícita, sem precisar de iteração. Muitos métodos de AM são iterativos.

Ajuste de mínimos Quadrados

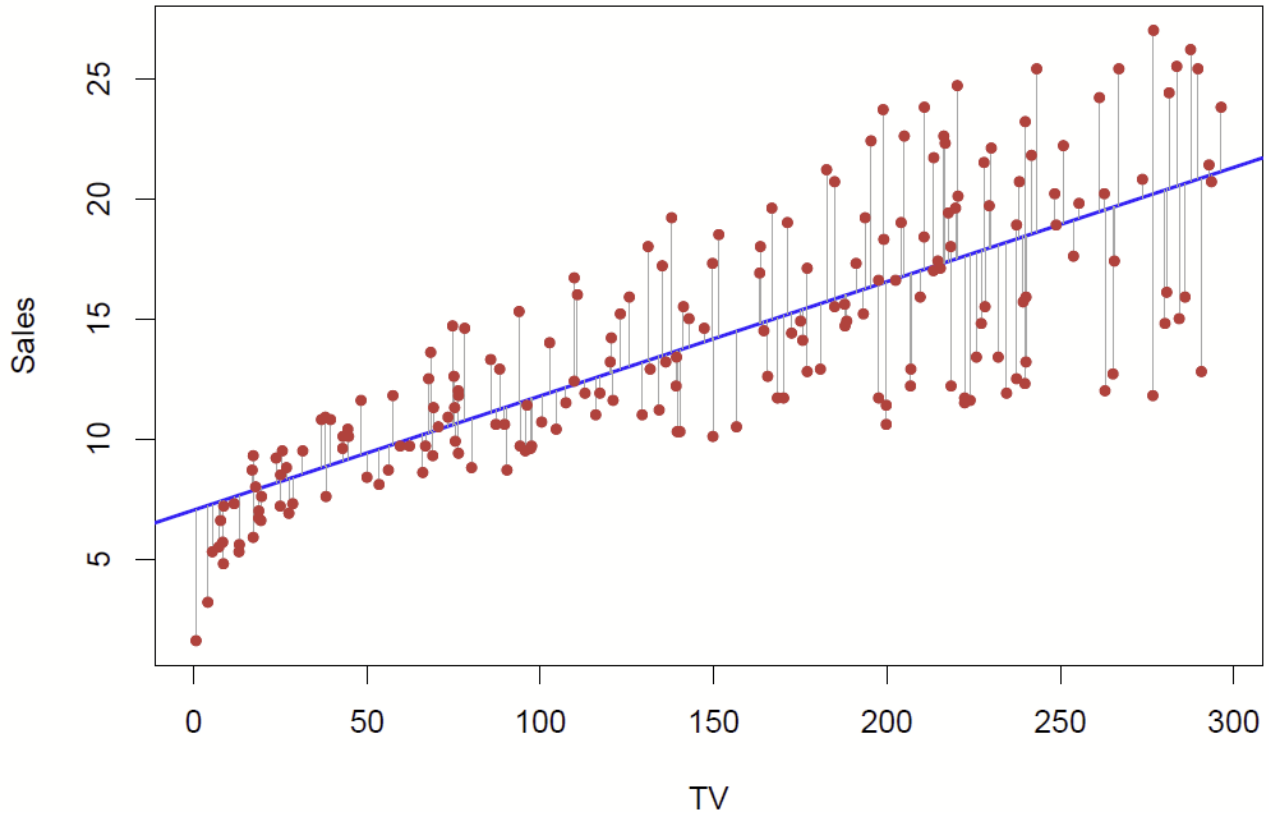


Figura 1: Ajuste da regressão utilizando mínimos quadrados. Tendência é bem capturada mas há uma estimativa grande nos primeiros pontos

Ajuste de Mínimos Quadrados

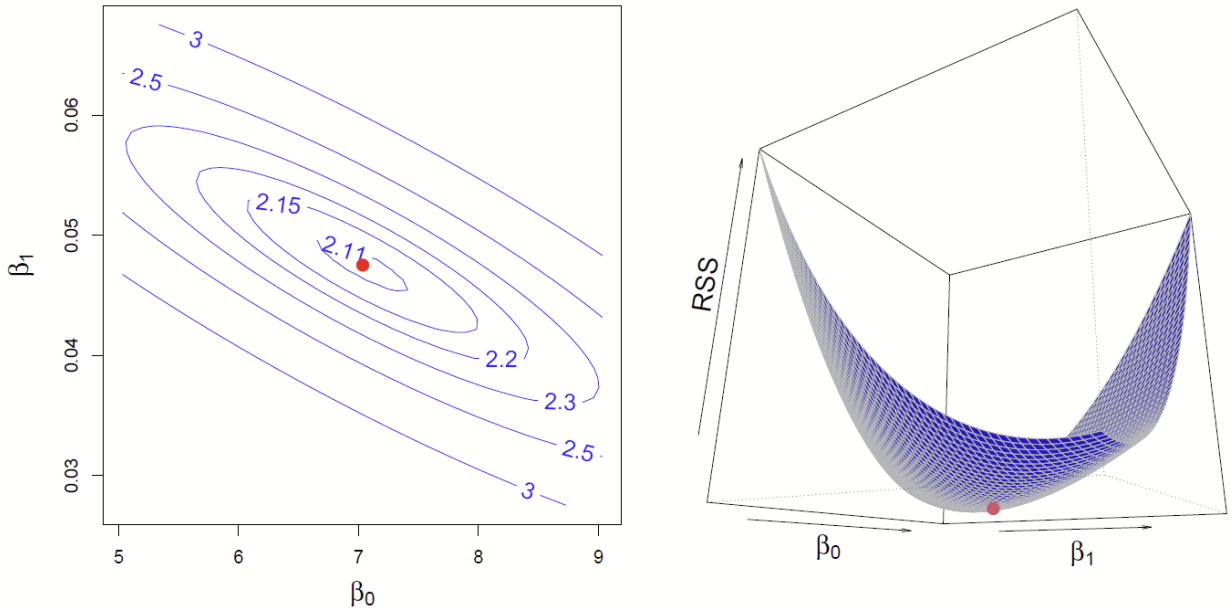


Figura 2: Contorno e plot 3D do RSS nos dados ajustados. Os pontos vermelhos correspondem às estimativas $\hat{\beta}_0$ e $\hat{\beta}_1$.

Interpretação de β_0 e β_1

Intercepto (*intercept*)

β_0, também conhecido como *intercepto*, representa o valor esperado de y quando $x = 0$. Geometricamente, é o ponto onde a reta intercepta o eixo y.

Inclinação (*slope*)

β_1, conhecido como *inclinação*, representa a variação esperada em y para cada aumento de uma unidade em x. Indica o grau de inclinação da reta.

Regressão Linear Múltipla

Regressão Linear Múltipla

- Normalmente, queremos predizer uma resposta a partir de mais de um preditor.
- Fazemos isso adicionando para cada preditor seu próprio coeficiente de intercepto e inclinação de forma que

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_P X_p + \epsilon$$

Interpretação

Podemos interpretar β_j como o efeito *médio* em Y se o atributo X_j aumentar uma unidade, *enquanto mantemos todos os outros preditores fixos.*

Regressão Linear Múltipla: Exemplos

$$\text{nota} = \beta_0 + \beta_1 \cdot \text{horas_estudo} + \beta_2 \cdot \text{horas_sono} + \epsilon$$

$$\text{salario} = \beta_0 + \beta_1 \cdot \text{experiencia} + \beta_2 \cdot \text{escolaridade} + \epsilon$$

$$\text{pressao} = \beta_0 + \beta_1 \cdot \text{peso} + \beta_2 \cdot \text{idade} + \epsilon$$

$$\text{vendas} = \beta_0 + \beta_1 \cdot \text{tv} + \beta_2 \cdot \text{radio} + \beta_3 \cdot \text{online} + \epsilon$$

Estimativa dos parâmetros

Podemos usar os **mínimos quadrados** da mesma forma que utilizamos na regressão linear simples. Queremos estimar os parâmetros $\hat{\beta}_0, \hat{\beta}_1 + \cdots + \hat{\beta}_p$ a partir da fórmula

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2, \cdots, \hat{\beta}_p x_p,$$

escolhendo os parâmetros que minimizam a soma dos resíduos (erros) ao quadrado

$$\text{RSS} = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 \tag{1}$$

$$= \sum_{i=1}^{n} \left(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \cdots - \hat{\beta}_p x_{ip} \right)^2 \tag{2}$$

Mínimos quadrados

- A solução para a regressão linear múltipla é melhor representada usando álgebra matricial. A solução fechada é dada por

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

Implementações dos Mínimos Quadrados

Muitas bibliotecas Python já tem implementações eficientes dessa formula. Na disciplina, vamos utilizar a implementação do `scikit-learn`.

Regressão Linear Múltipla

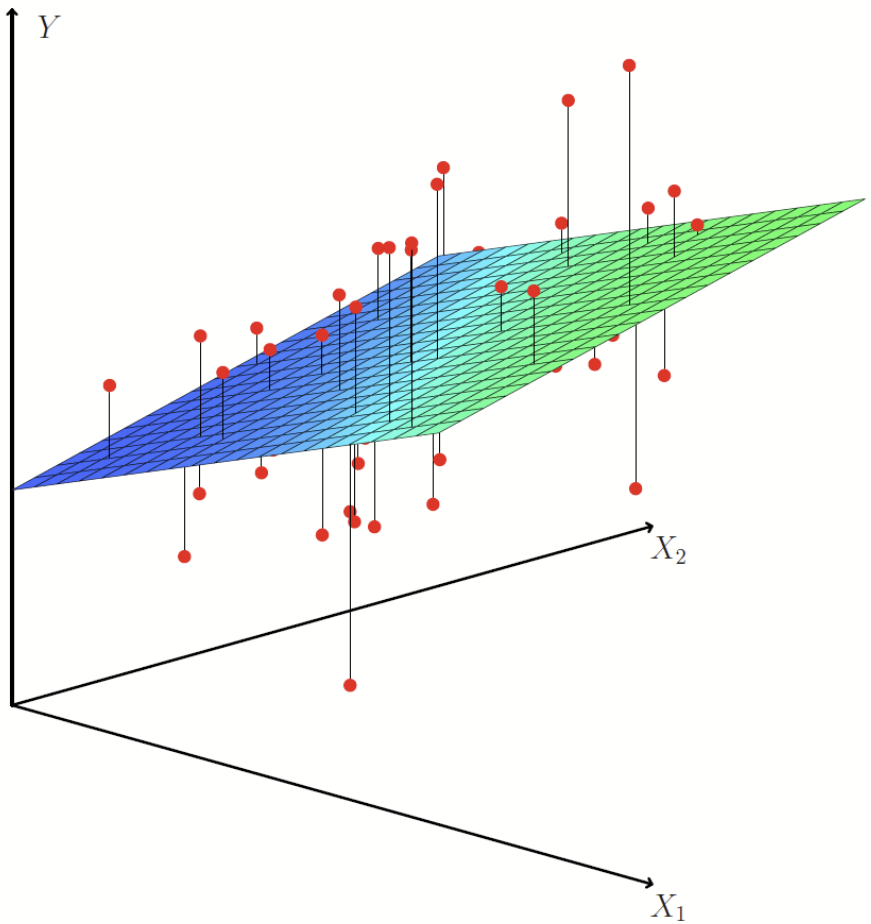


Figura 3: Em um contexto tridimensional, com dois preditores e uma resposta, a regressão múltipla se torna um **plano**. O plano é escolhido para minimizar a soma das distâncias ao quadrado entre cada observação e o plano.

Métodos de Classificação

Classificação

Relembrando: Classificação

Problemas onde as nossas váriáveis de resposta são *qualitativas*, mais comumente conhecidas como *categóricas*.

Predizendo Probabilidade

É comum que métodos de classificação, na realidade, estimem *probabilidades* de um dado de entrar pertencer a uma classe outra.

Classificação: Exemplos

- Um paciente chega ao pronto-socorro com sintomas que podem estar associados a três possíveis condições médicas. O objetivo é determinar qual delas ele possui.
  Resumo: Classificar o paciente em uma das três doenças.
- Um serviço bancário online precisa identificar se uma transação é fraudulenta com base em informações como endereço IP e histórico de transações.
  Resumo: Classificar transações como fraudulentas ou legítimas.
- Com base em dados de sequenciamento de DNA de pacientes com e sem uma doença, um biólogo deseja identificar quais mutações são causadoras da doença.
  Resumo: Classificar mutações como prejudiciais ou não.

Por que não usar Regressão?

- Lembrando: Se modelos de classificação buscam estimar a probabilidade de uma classe, *isso não seria um problema de regressão*?
- Ou melhor: não podemos simplesmente atribuir um número para cada classe e treinar uma regressão linear para estimar tais números?
- Como exemplo, vamos considerar um cenário bem tranquilo.

Exemplo: Diagnóstico

Suponha que estamos tentando predizer a condição médica de um paciente na sala de emergência a partir de seus sintomas apresentados, dentro de três categorias: **derrame**, **overdose de drogas** e **convulsão epiléptica**. Codificamos as variáveis qualitativas como *quantitativas*:

$$Y = \begin{cases} 1 & \text{se derrame;} \\ 2 & \text{se overdose de drogas;} \\ 3 & \text{se convulsão epiléptica.} \end{cases}$$

Exemplo: Diagnóstico

- Primeiro problema é que estamos atribuindo uma *ordem* na saída dos dados, que a priori, não existe.
- Segundo problema é que estamos atribuindo uma *distância* entre as classes.
- Quaisquer outras codificações seriam igualmente arbitrárias:

$$Y = \begin{cases} 1 & \text{se convulsão epiléptica;} \\ 2 & \text{se derrame;} \\ 3 & \text{se overdose de drogas.} \end{cases}$$

Exemplo: Cenário binário

Bem... mas se forem apenas duas categorias, digamos derrame e overdose de drogas? Usando uma variável *dummy*

$$Y = \begin{cases} 0 & \text{se derrame;} \\ 1 & \text{se overdose de drogas;} \end{cases}$$

de forma que para qualquer $\hat{Y} > 0.5$ temos overdose, caso contrário derrame.

Exemplo: Cenário binário

- Nesse cenário, a ideia na realidade não é tão ruim...
- ...mas não há nenhuma garantia de que as predições ficariam no intervalo de $[0, 1]$. Isso fornece probabilidade grosseiras.

A necessidade da classificação

São dois pontos principais: (a) um método de regressão não pode lidar com uma variável resposta qualitativa com mais de duas classes; (b) um método de regressão não fornecerá estimativas significativas de $Pr(Y|X)$, mesmo com apenas duas classes.

Regressão Logística

Modelo Logístico

Primeiro, convencionamos que $p(X) = Pr(Y = 1|X)$. Se considerarmos que vamos usar uma regressão linear temos que

$$p(X) = \beta_0 + \beta_1 X$$

Para evitar os problemas já citados, precisamos usar uma função que nos forneça valores entre 0 e 1 para todos os valores de X. Usamos uma função logística para isso

$$p(X) = \frac{e^{\beta_0+\beta_1 X}}{1 + e^{\beta_0+\beta_1 X}}$$

Função Logística

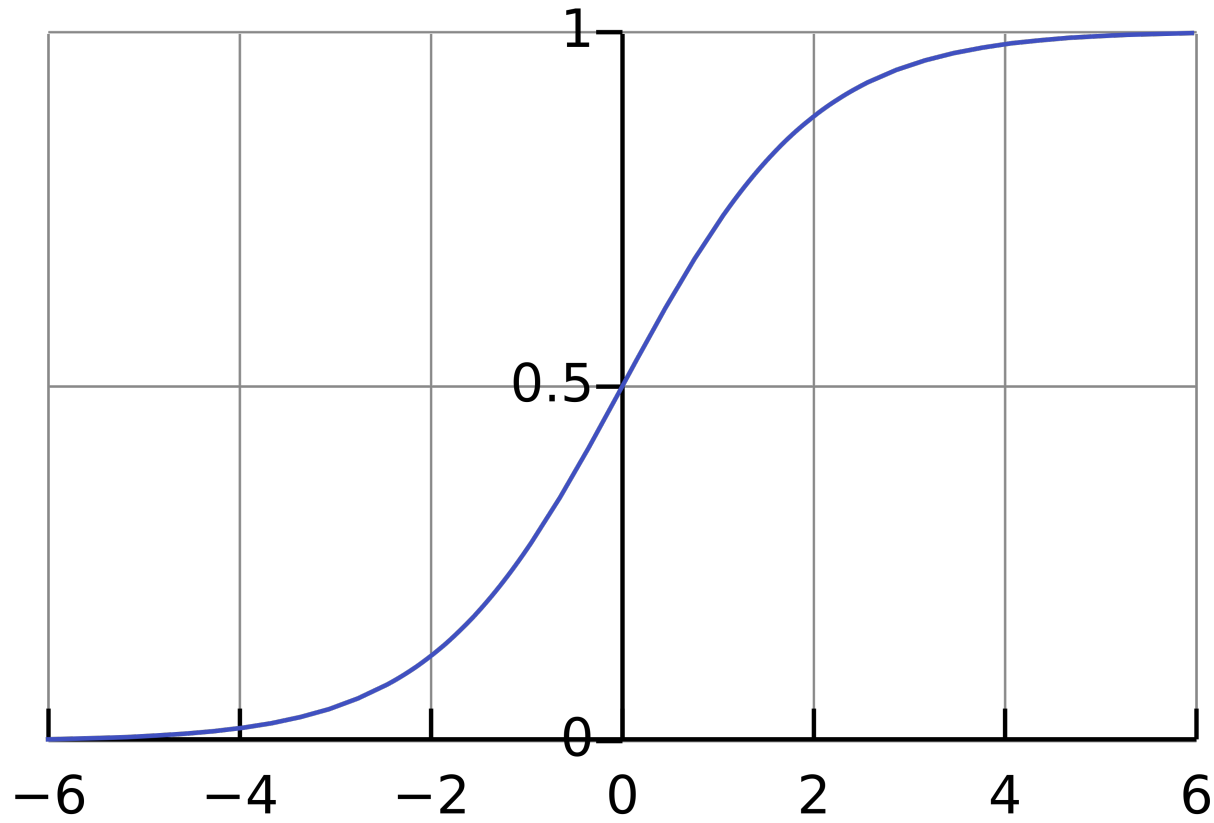


Figura 4: A curva sigmoide $\sigma(z) = \frac{1}{1+e^{-z}}$ como função de ligação. Suas assíntotas em 0 e 1 garantem saídas estritamente válidas de probabilidade ($0 < P(Y = 1 \mid \mathbf{x}) < 1$), com ponto de inflexão em $z = 0$ correspondente a $P = 0{,}5$ (limiar de decisão).

Comparativo

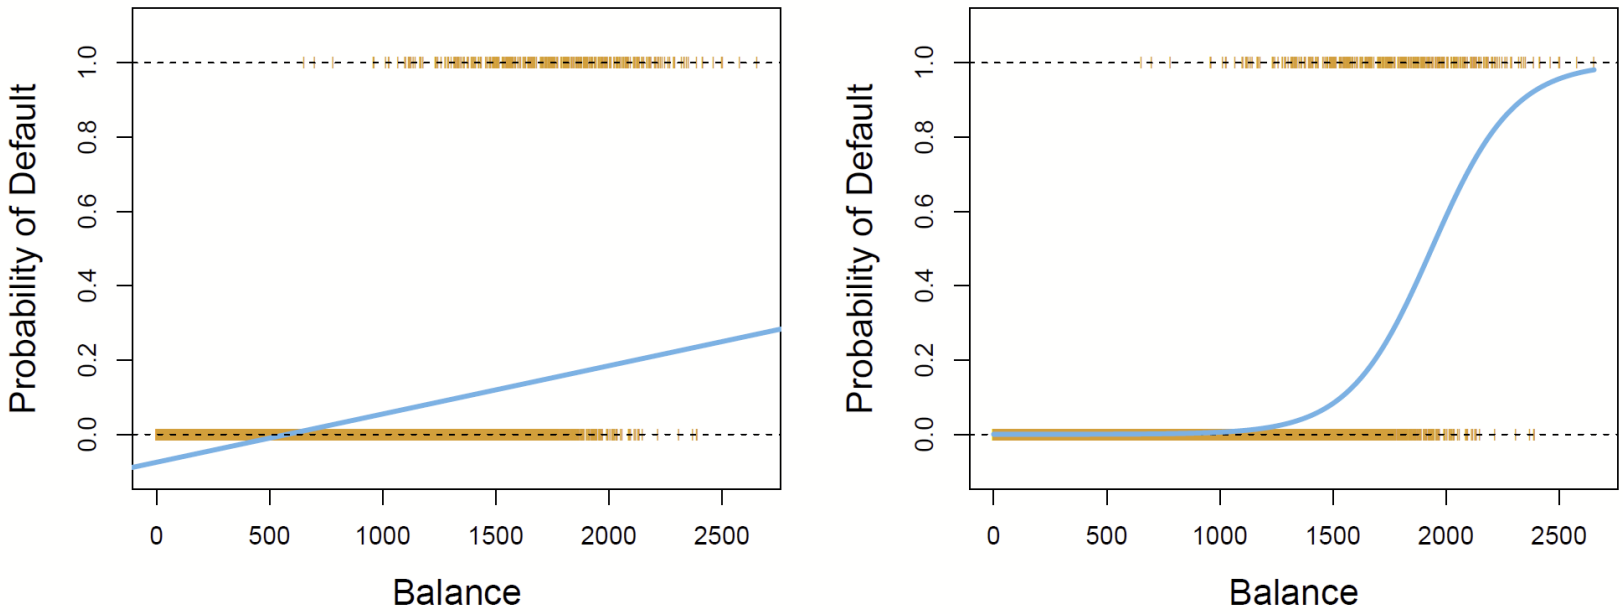


Figura 5: Painel esquerdo: usando regressão linear. Painel direito: usando regressão logística. Observe quais valores o painel da esquerda pode assumir. Default = No = 0 e Default = Yes = 1.

Estimando os parâmetros

Conforme já estabelecido, precisamos encontrar os valores de β_1 e β_2 a partir de um conjunto de treino disponível. O método mais comum para estimar tais parâmetros é o método de **máxima verossimilhança** dado por

$$L(\beta_0, \beta_1) = \prod_{i:y_i=1} p(x_i) \prod_{i':y'=0} (1 - p(x_{i'})).$$

Nesse caso, queremos **maximizar** a função custo.

? Pergunta

O que você entende dos termos da função custo apresentada?

Estimando os parâmetros

Comumente, não tentamos maximizar $L(\beta_0, \beta_1)$ e sim *minimizar* $-\ell(\beta_0, \beta_1)$, onde

$$\ell(\beta_0, \beta_1) = \log(L(\beta_0, \beta_1)) = \log(\prod_{i=1}^{n} p(y_i|x_i)) = \sum_{i=1}^{n} \log p(y_i|x_i)$$

por causa de uma propriedade dos logaritmos onde

$$log(a \cdot b) = \log a + \log b$$

Como encontramos o mínimo da Binary Cross-Entropy?

Diferente da regressão linear, não existe fórmula fechada porque os parâmetros ficam presos dentro da exponencial. Nesse caso, usamos **otimização numérica iterativa** (como Gradiente Descendente ou Newton-Raphson) para descer passo a passo até o **mínimo global**.

Regressão Logística Múltipla

Na prática, a formulação é basicamente a mesma da regressão Logística Simples, adicionando também os coeficientes de intercepto e inclinação no modelo para cada preditor, tal que

$$p(X) = \frac{e^{\beta_0+\beta_1+X_1+\cdots+\beta_p+X_p}}{1+e^{\beta_0+\beta_1+X_1+\cdots+\beta_p+X_p}}$$

Generalização e Regularização: Polinômios, Ridge e Lasso

Limitações dos Mínimos Quadrados Clássicos (OLS)

Embora o OLS seja o método padrão para regressão linear, ele possui limitações críticas:

- **Premissa de Linearidade:** O mundo raramente é estritamente linear.
- **Multicolinearidade:** Preditores muito correlacionados inflam a variância dos estimadores.
- **Sensibilidade a Outliers:** Como minimizamos o erro ao quadrado (RSS), pontos discrepantes puxam a reta com muita força.
- **Cenário $p > n$:** Se houver mais preditores do que observações, o sistema é indeterminado (infinitas soluções).

Regressão Polinomial

Podemos capturar curvaturas nos dados **sem sair do modelo linear**, criando novos atributos elevadas a potências:

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \cdots + \beta_d X^d + \varepsilon$$

Por que ainda é regressão linear?

O modelo continua **linear nos parâmetros** (β). Para o OLS, X^2 e X^3 são apenas novas colunas X_2 e X_3 na matriz $\mathbf{X}$.

- **Grau $d = 1$:** Reta padrão (pode sofrer de *underfitting*).
- **Grau $d = 2$ ou 3:** Parábolas ou curvas cúbicas (capturam acelerações e saturações).

O Efeito Colateral: Overfitting e Coeficientes Gigantes

Ao aumentar o grau do polinômio ($d = 10, 15, \dots$):

- A curva passa perfeitamente por todos os pontos de treino (RSS ≈ 0).
- A função oscila descontroladamente entre os pontos reais.

O sintoma matemático do Overfitting

Para compensar as oscilações bruscas, os coeficientes $\hat{\beta}_j$ explodem para valores astronômicos (ex.: $+10^5$ em X^8 e -10^5 em X^9).

Introdução à Regularização (Shrinkage)

A regularização adiciona uma **penalidade** à função de custo do OLS para encolher (*shrink*) os coeficientes em direção a zero.

$$\text{Custo Final} = \text{RSS} + \text{Penalidade}(\beta)$$

- Trocamos um pouco de **viés** (o modelo erra um pouco mais no treino) por uma redução drástica na **variância** (o modelo generaliza muito melhor no teste).
- O parâmetro $\lambda \geq 0$ controla a força da penalidade:
  - Se $\lambda = 0$: voltamos ao OLS clássico.
  - Se $\lambda \to \infty$: todos os coeficientes vão a zero (modelo vira uma reta horizontal).

Regressão Ridge (Penalidade L_2)

Minimiza a soma dos erros quadráticos adicionando a soma dos quadrados dos coeficientes:

$$J(\beta) = \sum_{i=1}^{n} \left(y_i - \beta_0 - \sum_{j=1}^{p} \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^{p} \beta_j^2$$

Propriedades do Ridge

- **Encolhe** os coeficientes conjuntamente, mas **nunca zera nenhum** β_j **exatamente**.
- Resolve o problema de multicolinearidade e posto incompleto ($p > n$), pois a solução matricial é sempre invertível:

$$\hat{\beta}_{\text{ridge}} = (\mathbf{X}^T\mathbf{X} + \lambda\mathbf{I})^{-1}\mathbf{X}^T\mathbf{y}$$

Regressão Lasso (Penalidade L_1)

Lasso (*Least Absolute Shrinkage and Selection Operator*) penaliza o valor absoluto dos coeficientes:

$$J(\beta) = \sum_{i=1}^{n} \left(y_i - \beta_0 - \sum_{j=1}^{p} \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^{p} |\beta_j|$$

O Superpoder do Lasso: Seleção de Variáveis

- O Lasso consegue **zerar coeficientes irrelevantes exatamente** ($\beta_j = 0$).
- Gera modelos esparsos e interpretáveis (faz seleção automática de features).
- Não possui fórmula analítica fechada; é resolvido numericamente (ex.: descida por coordenadas).

Regularização

Quando usar Ridge?

Use Ridge quando você acredita que **muitas variáveis contribuem** para explicar o problema.
É especialmente útil quando existem **variáveis correlacionadas**, pois tende a distribuir o efeito entre elas em vez de eliminar variáveis.

Quando usar Lasso?

Use Lasso quando você acredita que **poucas variáveis são realmente importantes**.
Como pode zerar coeficientes, também funciona como uma forma de **seleção de variáveis**, produzindo modelos mais esparsos.

E se eu quiser os dois?

O **Elastic Net** combina as penalizações do Ridge e do Lasso.

Leitura Recomendada

[1] Capitulo 3 (só o 3.1, não as subseções; 3.2 e 3.2.1); Seção 6.2, 6.2.1 e 6.2.2.

Referências I



Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani, and Jonathan Taylor.
An Introduction to Statistical Learning with Applications in Python.
Springer Texts in Statistics. Springer, Cham, 1st edition, 2023.