Aprendizado Bayesiano & Naive Bayes

Prof. Renan Gomes Vieira

Universidade Federal do Ceará - Campus Quixadá
Aprendizado de Máquina

2026.2

Sumário

1. Introdução ao Aprendizado Bayesiano

2. Naive Bayes

Introdução ao Aprendizado Bayesiano

Modelos Discriminativos vs. Modelos Generativos

Em tarefas de classificação com preditores X e classes $Y \in \{1, \ldots, K\}$:

- **Abordagem Discriminativa (ex: Regressão Logística):**
  - Modela diretamente a probabilidade posterior: $\Pr(Y = k \mid X = x)$.
  - Foca em encontrar a melhor fronteira de separação entre as classes.

- **Abordagem Generativa (Modelos Bayesianos):**
  - Modela como os dados foram gerados para cada classe separadamente:
    $$f_k(x) = \Pr(X = x \mid Y = k)$$
  - Usa o **Teorema de Bayes** para inverter a relação e obter $\Pr(Y = k \mid X = x)$.

Por que Modelos Generativos?

Se já conhecemos a Regressão Logística, por que aprender modelos baseados no Teorema de Bayes?

- **Separação substancial entre as classes:** Na regressão logística, quando as classes estão bem separadas, as estimativas dos parâmetros tornam-se instáveis. Os métodos generativos não sofrem desse problema.
- **Amostras pequenas:** Se a suposição de distribuição para X em cada classe for razoável, modelos generativos tendem a ser mais precisos que a regressão logística com poucos dados.
- **Extensão natural para $K > 2$ classes:** A formulação matemática lida com múltiplas classes de maneira direta e intuitiva.

O Teorema de Bayes para Classificação

O Teorema de Bayes afirma que

$$\Pr(Y = k \mid X = x) = \frac{\pi_k f_k(x)}{\sum_{l=1}^{K} \pi_l f_l(x)}$$

onde:

- $\Pr(Y = k \mid X = x)$ é a **probabilidade a posteriori** de que uma observação $X = x$ pertence à classe k. Usaremos a abreviação $p_k(x)$.
- $\pi_k = \Pr(Y = k)$ é a **probabilidade a priori** da classe k. É fácil de estimar: basta computar a proporção de dados de treino que pertencem à classe k ($\hat{\pi}_k = n_k/n$).
- $f_k(x) \equiv \Pr(X = x \mid Y = k)$ é a função de **verossimilhança** (ou função de densidade de probabilidade de X na classe k).

Estimando os Componentes do Teorema

Em vez de calcular $p_k(x)$ diretamente, estimamos π_k e $f_k(x)$:

- **Estimando π_k (Direto):** Se tivermos uma amostra aleatória da população, basta calcular a fração de observações de treino pertencentes à classe k:

$$\hat{\pi}_k = \frac{n_k}{n}$$

- **Estimando $f_k(x)$ (Desafiador):** Estimar a função de densidade é mais difícil e exige a adoção de **hipóteses simplificadoras** sobre a distribuição dos dados.

Modelos Generativos Alternativos

O que muda entre eles?

Todos usam o Teorema de Bayes. O que diferencia cada algoritmo é a **hipótese simplificadora** usada para estimar a verossimilhança $f_k(x) = \Pr(X = x \mid Y = k)$.

- **Naive Bayes:** Assume que as variáveis preditoras são **independentes** entre si dentro de cada classe.
- **LDA (Análise Discriminante Linear):** Assume distribuição Normal e que todas as classes têm a **mesma dispersão/variabilidade**.
  - Resulta em **fronteiras retas** (lineares).
- **QDA (Análise Discriminante Quadrática):** Também assume distribuição Normal, mas permite que cada classe tenha sua **própria dispersão/variabilidade**.
  - Resulta em **fronteiras curvas** (quadráticas).

Naive Bayes

A Premissa do Naive Bayes

A Hipótese Ingênua (Naive)

Dentro de uma classe k qualquer, todos os preditores são condicionalmente independentes entre si.

Portanto, a densidade conjunta decompõe-se no produtório das marginais:

$$f_k(x) = f_{k1}(x_1) \times f_{k2}(x_2) \times \cdots \times f_{kp}(x_p) = \prod_{j=1}^{p} f_{kj}(x_j)$$

Substituindo na fórmula de Bayes:

$$\Pr(Y = k \mid X = x) = \frac{\pi_k \prod_{j=1}^{p} f_{kj}(x_j)}{\sum_{l=1}^{K} \pi_l \prod_{j=1}^{p} f_{lj}(x_j)}$$

Por que a Independência? O Caso Discreto

Considere p preditores binários $X_1, X_2, \ldots, X_p \in \{0, 1\}$ (2^p configurações):

- Para a conjunta real $\Pr(X \mid Y = k)$, precisamos estimar $2^p - 1$ **parâmetros**/classe.

Preditores (p)	Conjunta Real	Com Independência
$p = 3$	$2^3 - 1 = 7$	$3 \times 1 = 3$
$p = 10$	$2^{10} - 1 = 1.023$	$10 \times 1 = 10$
$p = 20$	$\approx 10^6$	$20 \times 1 = 20$
$p = 100$	$\approx 1{,}26 \times 10^{30}$	$100 \times 1 = 100$

Consequência: Sem uma quantidade massiva de dados, quase todas as probabilidades seriam nulas no treino.

Como Estimar $f_{kj}(x_j)$?

A premissa simplifica o problema: estimamos apenas distribuições unidimensionais a partir do conjunto de treino:

- **Se X_j for quantitativo:**
  - Modelo paramétrico: assumir normalidade $X_j \mid Y = k \sim \mathcal{N}(\mu_{jk}, \sigma^2_{jk})$.
  - Modelo não-paramétrico: estimar via histograma ou por Densidade de Kernel (KDE).

- **Se X_j for qualitativo:**
  - Computamos a frequência relativa observada de cada categoria de X_j para a classe k.

Naive Bayes: Exemplo

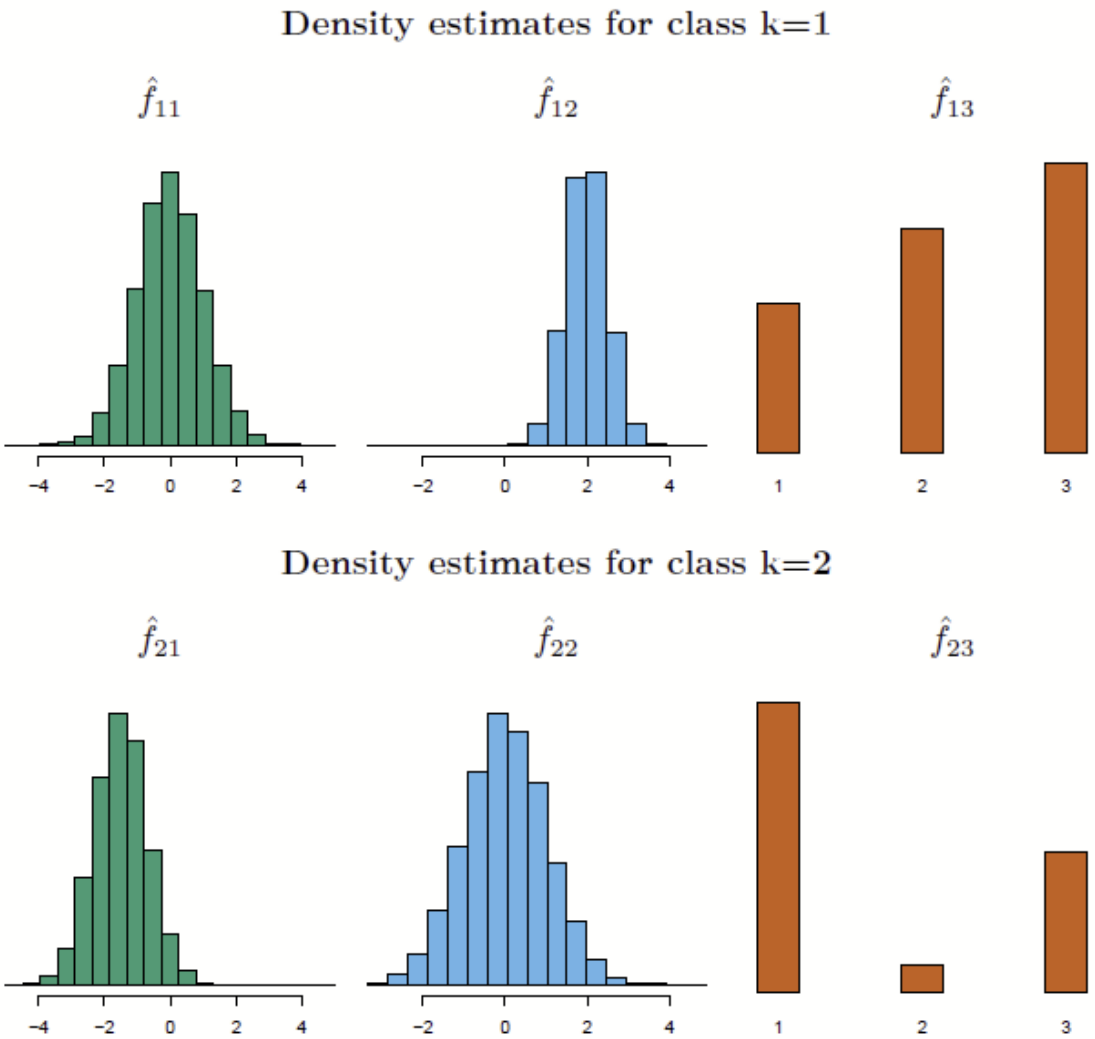


Figura 1: Exemplo hipotético com $p = 3$ e $K = 2$. X_1 e X_2 são quantitativos e X_3 é qualitativo com três categorias. Consideramos $\hat{\pi}_1 = \hat{\pi}_2 = 0{,}5$.

Naive Bayes: Exemplo (Valores Estimados)

Queremos classificar uma nova observação:

$$x^* = (x_1^* = 0{,}4,\ x_2^* = 1{,}5,\ x_3^* = 1)^T$$

Das densidades e proporções estimadas no gráfico, temos:

- $\hat{\pi}_1 = 0{,}5$ e $\hat{\pi}_2 = 0{,}5$
- Para a Classe 1 ($k = 1$):

$$\hat{f}_{11}(0{,}4) = 0{,}368, \quad \hat{f}_{12}(1{,}5) = 0{,}484, \quad \hat{f}_{13}(1) = 0{,}226$$

- Para a Classe 2 ($k = 2$):

$$\hat{f}_{21}(0{,}4) = 0{,}032, \quad \hat{f}_{22}(1{,}5) = 0{,}130, \quad \hat{f}_{23}(1) = 0{,}616$$

Resolução: Passo a Passo

Passo 1: Calcular a verossimilhança conjunta sob independência

$$\hat{f}_1(x^*) = 0{,}368 \times 0{,}484 \times 0{,}226 = 0{,}04025$$

$$\hat{f}_2(x^*) = 0{,}032 \times 0{,}130 \times 0{,}616 = 0{,}00256$$

Resolução: Passo a Passo

Passo 1: Calcular a verossimilhança conjunta sob independência

$$\hat{f}_1(x^*) = 0{,}368 \times 0{,}484 \times 0{,}226 = 0{,}04025$$

$$\hat{f}_2(x^*) = 0{,}032 \times 0{,}130 \times 0{,}616 = 0{,}00256$$

Passo 2: Multiplicar pelas probabilidades a priori $\hat{\pi}_k$

$$\hat{\pi}_1 \hat{f}_1(x^*) = 0{,}5 \times 0{,}04025 = 0{,}020125$$

$$\hat{\pi}_2 \hat{f}_2(x^*) = 0{,}5 \times 0{,}00256 = 0{,}001280$$

Resolução: Passo a Passo

Passo 1: Calcular a verossimilhança conjunta sob independência

$$\hat{f}_1(x^*) = 0{,}368 \times 0{,}484 \times 0{,}226 = 0{,}04025$$

$$\hat{f}_2(x^*) = 0{,}032 \times 0{,}130 \times 0{,}616 = 0{,}00256$$

Passo 2: Multiplicar pelas probabilidades a priori $\hat{\pi}_k$

$$\hat{\pi}_1 \hat{f}_1(x^*) = 0{,}5 \times 0{,}04025 = 0{,}020125$$

$$\hat{\pi}_2 \hat{f}_2(x^*) = 0{,}5 \times 0{,}00256 = 0{,}001280$$

Passo 3: Calcular a evidência (denominador comum)

$$\sum_{l=1}^{2} \hat{\pi}_l \hat{f}_l(x^*) = 0{,}020125 + 0{,}001280 = 0{,}021405$$

Resolução: Conclusão

Passo 4: Obter as probabilidades a posteriori normalizadas

$$p_1(x^*) = \Pr(Y = 1 \mid X = x^*) = \frac{0{,}020125}{0{,}021405} \approx \mathbf{0{,}9402} \quad (94{,}02\%)$$

$$p_2(x^*) = \Pr(Y = 2 \mid X = x^*) = \frac{0{,}001280}{0{,}021405} \approx \mathbf{0{,}0598} \quad (5{,}98\%)$$

Pergunta

Qual a classe prevista para a nova observação x^*?

Como $p_1(x^*) > p_2(x^*)$, a predição do classificador Naive Bayes é categoricamente a **Classe 1**.

Exemplo: Spam e Não spam (Bernoulli) Naive Bayes

gratis	promocao	reuniao	projeto	classe
1	1	0	0	spam
1	1	0	0	spam
1	1	0	1	spam
1	1	0	0	spam
1	1	0	0	spam
1	1	0	0	spam
0	0	1	1	nao_spam
0	1	1	1	nao_spam
0	0	1	1	nao_spam
1	0	1	1	nao_spam
0	1	1	1	nao_spam
0	0	1	1	nao_spam
0	1	1	1	nao_spam
1	0	1	1	nao_spam
0	1	1	1	nao_spam

Tabela 1: Nesse caso, modelamos o problema como presença ou ausência de cada palavra no e-mail.

O Problema da Probabilidade Zero

Imagine que recebemos um novo e-mail:

$$x_{\text{novo}} = (\text{gratis} = 1, \text{promocao} = 1, \text{reuniao} = 1, \text{projeto} = 0)$$

Observando a tabela de treino:

- Em 6 e-mails de spam, a palavra **reuniao** apareceu 0 vezes.
- Logo: $\Pr(\text{reuniao} = 1 \mid \text{spam}) = \frac{0}{6} = 0$.

Efeito Multiplicativo

$$\Pr(X = x_{\text{novo}} \mid \text{spam}) = \Pr(X_1 = 1)\Pr(X_2 = 1) \times \mathbf{0} \times \Pr(X_4 = 0) = 0$$

Um único atributo nunca visto zera toda a verossimilhança da classe, ignorando todas as outras evidências!

Solução: Suavização de Laplace (Laplace Smoothing)

Para evitar probabilidades nulas, adicionamos uma contagem fictícia ($\alpha = 1$):

$$\hat{\Pr}(X_j = 1 \mid Y = k) = \frac{N_{kj} + \alpha}{N_k + 2\alpha}$$

onde:

- N_{kj} é o número de e-mails da classe k com a palavra j.
- N_k é o total de e-mails da classe k.

Agora, para a palavra **reuniao** no spam:

$$\hat{\Pr}(\text{reuniao} = 1 \mid \text{spam}) = \frac{0+1}{6+2} = \frac{1}{8} = 0{,}125 > 0$$

Implementação

- Conferir implementação feita em sala (disponível no notebook no SIGAA)
- Implementar as variações usando preditores binários (Bernoulli) e de contagem (Multinomial).

Naive Bayes: viés e variância

Ao impor que os preditores são independentes condicionalmente, o modelo toma uma decisão deliberada:

Alto Viés

- Ignora correlações reais entre atributos.
- As probabilidades calculadas podem ficar descalibradas.

Baixíssima Variância

- Reduz a estimativa de $O(2^p)$ para apenas $O(p)$ parâmetros.
- Quase imune ao *overfitting*, funcionando bem mesmo com pouquíssimos dados de treino.

Como Estimamos cada Atributo $f_{kj}(x_j)$?

A escolha de como modelar cada variável univariada também controla o balanço viés-variância local:

Aproximação Grosseira (Ex: Normal ou Poucos Bins)

- **Maior Viés:** Perde detalhes se os dados forem multimodais ou assimétricos.
- **Menor Variância:** Poucos parâmetros $(\mu, \sigma^2) \implies$ estimativa muito estável.

Aproximação Granular (Ex: Muitos Bins ou KDE Fino)

- **Menor Viés:** Adapta-se ao formato exato dos dados observados.
- **Maior Variância:** Caixas vazias ou ruído de amostragem $\implies$ risco alto de *overfitting*.

Desafio/Exercício: Spam e Não spam (Multinomial)

gratis	promocao	reuniao	projeto	classe
3	2	0	0	spam
4	1	0	0	spam
2	3	0	1	spam
5	1	0	0	spam
3	2	0	0	spam
1	4	0	0	spam
0	0	3	2	nao_spam
0	1	2	3	nao_spam
0	0	4	2	nao_spam
1	0	3	3	nao_spam
0	1	2	4	nao_spam
0	0	5	1	nao_spam
0	2	2	3	nao_spam
1	0	1	4	nao_spam
0	1	3	2	nao_spam

Tabela 2: Nesse caso, modelamos o problema como a contagem de cada palavra no e-mail. Como seria a implementação? **PESQUISE!**

Leitura Recomendada

[1] *An Introduction to Statistical Learning (ISLR)*:

- Seção 4.4: *Generative Models for Classification*
- Seção 4.4.4: *Naive Bayes*

Referências I


Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani, and Jonathan Taylor.
An Introduction to Statistical Learning with Applications in Python.
Springer Texts in Statistics. Springer, Cham, 1st edition, 2023.